



**UNIVERSIDAD DE BUENOS AIRES**  
**FACULTAD DE CIENCIAS EXACTAS Y NATURALES**  
Departamento de Computación

**Aprendizaje automático a partir de cuerpos de datos ralos: un  
enfoque basado en la inferencia bayesiana**

Tesis presentada para optar por el título de Doctor de la Universidad de  
Buenos Aires en el área Ciencias de la Computación

**SERGIO ROMANO**

**Director de Tesis:** Santiago Figueira

**Co-Director de Tesis:** Mariano Sigman

**Consejero de Estudios:** Diego Fernández Slezak

**Lugar de trabajo:** Instituto de Ciencias de la Computación, UBA / CONICET.

Buenos Aires, 2021

*Esta tesis está dedicada a...*

# **Agradecimientos**

En este trabajo agradezco a...

## **Resumen**

Por acá

**Palabras Clave:**

## **Abstract**

# Índice

<b>1. Introducción</b>	<b>2</b>
1.1. Teoría computacional de la mente . . . . .	3
1.2. Lenguaje del pensamiento . . . . .	5
1.2.1. Gramáticas . . . . .	6
1.2.2. Composición . . . . .	7
1.2.2.1. Longitud Mínima de Descripción . . . . .	9
1.2.2.2. Ciencia Cognitiva Bayesiana . . . . .	10
<b>2. Lenguaje del pensamiento en secuencias binarias</b>	<b>11</b>
2.1. Trabajos Previos . . . . .	11
2.2. Modelo . . . . .	11
2.3. Experimento . . . . .	11
2.4. Resultados . . . . .	11
2.5. Discusión . . . . .	11
<b>3. Validación bayesiana de gramáticas para el lenguaje del pensamiento</b>	<b>12</b>
3.1. Método . . . . .	12
3.2. Aplicación al lenguaje de geometría . . . . .	12

3.3. Resultados . . . . .	12
3.4. Discusión . . . . .	12
3.5. Anexo: Probando el teorema de codificación . . . . .	12
<b>4. Actualización bayesiana de gramáticas para el lenguaje del pensamiento</b>	<b>13</b>
4.1. Método . . . . .	14
4.1.1. Lenguaje lógico . . . . .	14
4.1.2. Modelo libre . . . . .	14
4.1.3. Modelo estático . . . . .	14
4.1.4. Modelo dinámico . . . . .	14
4.2. Experimento . . . . .	14
4.3. Resultados . . . . .	14
4.4. Discusión . . . . .	14
<b>5. Un nuevo marco para estudiar los sesgos de aprendizaje de conceptos en el lenguaje del pensamiento</b>	<b>15</b>
5.1. Método . . . . .	16
5.1.1. Experimento . . . . .	16
5.1.2. Representación . . . . .	16
5.1.3. Hipótesis . . . . .	16
5.2. Resultados . . . . .	16
5.3. Discusión . . . . .	16
<b>6. BORRAR: Validación Bayesiana de producciones gramaticales para el lenguaje del pensamiento</b>	<b>18</b>
6.1. Introducción . . . . .	18

6.2.	Inferencia Bayesiana para las producciones del LoT . . . . .	22
6.3.	El lenguaje de geometría: <i>Geo</i> . . . . .	26
6.3.1.	Experimento original de <i>Geo</i> . . . . .	29
6.3.2.	Extendiendo la gramática de <i>Geo</i> . . . . .	31
6.3.3.	Resultados de inferencia para <i>Geo</i> . . . . .	32
6.4.	Teorema de codificación . . . . .	36
6.4.1.	La definición formal . . . . .	37
6.4.2.	Probando el teorema de codificación para <i>Geo</i> . . . . .	38
6.4.3.	Resultados del Teorema de Codificación . . . . .	40
6.5.	Discusión . . . . .	42
6.6.	Información de soporte . . . . .	44
<b>7.</b>	<b>BORRAR: Towards a more flexible Language of Thought: Bayesian grammar updates after each concept exposure</b> . . . . .	<b>47</b>
7.1.	Introduction . . . . .	47
7.2.	The logical setting . . . . .	51
7.3.	Experiment . . . . .	53
7.4.	Model-Free Results . . . . .	57
7.5.	Model . . . . .	59
7.5.1.	Static Model . . . . .	59
7.5.2.	Dynamic Model . . . . .	62
7.6.	Results . . . . .	64
7.7.	Discussion . . . . .	68
7.8.	Conclusion . . . . .	70

<b>8. Un marco lógico para estudiar aprendizaje de conceptos en presencia de explicaciones múltiples</b>	<b>71</b>
8.1. Experimento . . . . .	6
8.1.1. Participantes . . . . .	6
8.1.2. Configuración del experimento . . . . .	7
8.1.3. Ensayos experimentales . . . . .	12
8.2. Metodología . . . . .	16
8.2.1. Pre-registro y datos . . . . .	16
8.2.2. Detalles de representación . . . . .	17
8.2.3. Detalles de la estructura del experimento . . . . .	20
8.2.3.1. Introducción y explicación . . . . .	22
8.2.3.2. La fase de aprendizaje . . . . .	23
8.2.3.3. La fase de entrenamiento– <i>feedback</i> . . . . .	24
8.2.3.4. La fase de generalización . . . . .	24
8.2.4. Notas sobre el diseño del experimento . . . . .	25
8.3. Resultados . . . . .	27
8.3.1. Hipótesis I . . . . .	27
8.3.2. Hipótesis II . . . . .	29
8.3.3. Hipótesis III . . . . .	32
8.3.4. Hipótesis IV . . . . .	33
8.3.5. El sesgo de MDL . . . . .	34
8.4. Discusión . . . . .	34
<b>9. BORRAR: A theory of memory for binary sequences: Evidence for a mental compression algorithm in humans</b>	<b>45</b>

<b>A. Apéndice del Capítulo 8</b>	<b>125</b>
A.1. Criterios de exclusión y tratamiento de datos . . . . .	125
A.2. Prueba piloto . . . . .	126
A.3. Resultados técnicos . . . . .	127
<b>Bibliografía</b>	<b>143</b>

# Capítulo 1

## Introducción

En las últimas dos décadas distintas técnicas de ingeniería reversa del aprendizaje en humanos han inspirado con éxito distintos algoritmos de inteligencia artificial [Russell and Norvig, 2002]. Los avances recientes en las técnicas de aprendizaje profundo han logrado resultados notables en numerosos dominios como reconocimiento visual de objetos, el reconocimiento automático del habla, la búsqueda de respuestas y las traducciones automáticas [LeCun et al., 2015]. En la mayoría de estos enfoques, el resultado y el objeto del proceso de aprendizaje es una función estadística de reconocimiento de patrones específicos en los datos. Sin embargo, en muchas situaciones, el aprendizaje humano implica la construcción de modelos estructurados de conocimiento abstracto a partir de pocos datos, y este tipo de sistemas no han sido capaces de imitar esa habilidad [Lake et al., 2017].

¿Cómo pueden las personas adquirir un vasto universo de conceptos con muy poca exposición aparente? Una posible solución a este enigma, conocida como el problema de Platón [Chomsky, 1986, Chomsky et al., 2006], surge del aprendizaje automático probabi-

lístico. Este enfoque está arrojando algo de luz sobre cómo los humanos pueden construir modelos y abstracciones bajo incertidumbre y a partir de datos escasos [Tenenbaum et al., 2011, Ghahramani, 2015], y está renovando la hipótesis de Jerry Fodor que afirma que el pensamiento toma forma en una especie de lenguaje mental del pensamiento (LoT, por sus siglas en inglés) compuesto por un conjunto limitado de símbolos atómicos que se pueden combinar para formar estructuras más complejas siguiendo reglas combinatorias [Fodor, 1975].

Nuestra investigación se suscribe a uno de las líneas actuales del aprendizaje automático probabilístico conocido como programación probabilística, un esquema general para expresar modelos probabilísticos y métodos de inferencia como programas informáticos [Ghahramani, 2015]. Esto significa que en nuestros modelos asumimos que el LoT es un lenguaje de programación capaz de generar programas para modelar conceptos en el mundo. Con nuestro trabajo pretendemos mejorar nuestro entendimiento del proceso de aprendizaje a partir de cuerpos ralos de datos y desarrollar nuevos métodos y algoritmos de programación probabilística para replicar esta notable capacidad humana.

En la sección..... (acá se explicaría capítulo por capítulo)

## 1.1. Teoría computacional de la mente

**Explicar critica conexiónismo y surgimiento teoría computacional de la mente.**

**Breve mención a críticas del conectivismo a partir del 80 (Fodor y Steven Pinker).**

**Reversión al asociacionismo.**

**Explicar Simbólico**

"The infinite use of finite means"(Humboldt's sobre el lenguaje)

- 1) How does abstract knowledge guide learning and inference from sparse data? Bayesian inference in probabilistic generative models
- 2) What form does that knowledge take, across different domains and tasks? Probabilities defined over richly structured symbolic representations: spaces, graphs, grammars, logical predicates
- 3) How is that knowledge itself constructed / updated / validated? Hierarchical models, transfer learning, herramientas papers

Los investigadores han modelado estas categorías mentales o clases conceptuales con dos enfoques clásicos: en términos de similitud con un ejemplo genérico o prototipo [Rosch, 1999, Nosofsky, 1986, Rosch et al., 1976, Rosch and Mervis, 1975] o basándose en una representación simbólica de reglas [Boole, 1854, Fodor, 1975, Gentner, 1983].

Enfoques simbólicos como la hipótesis del *lenguaje del pensamiento* (LoT, por sus siglas en inglés) [Fodor, 1975], afirman que el pensamiento toma forma en una especie de lenguaje mental, compuesto por un conjunto limitado de símbolos atómicos que pueden combinarse para formar estructuras más complejas. siguiendo reglas combinatorias.

**Explicar críticas a simbólico** [Blackburn, 1984, Loewer and Rey, 1991, Knowles, 1998, Aydede, 1997]

## 1.2. Lenguaje del pensamiento

### Profundizar Fodor y Cognición. Aparición de Probabilistic Language of Thought

A pesar de las críticas y objeciones, los enfoques simbólicos en general — y la hipótesis de LoT en particular — han ganado una atención renovada con resultados recientes que podrían explicar el aprendizaje a través de diferentes dominios como inferencia estadística sobre un espacio de hipótesis estructurado composicionalmente [[Tenenbaum et al., 2011](#), [Piantadosi and Jacobs, 2016](#)].

El LoT no es necesariamente único. De hecho, la forma que adopta se ha modelado de muchas formas diferentes según el dominio del problema: aprendizaje de conceptos numéricos [[Piantadosi et al., 2012](#)], aprendizaje de secuencias [[Amalric et al., 2017a](#), [Yildirim and Jacobs, 2015](#), [Romano et al., 2013](#)], aprendizaje de conceptos visuales [[Ellis et al., 2015](#)], aprendizaje de teorías [[Ullman et al., 2012](#)], etc.

Si bien los marcos pueden diferir en cómo se puede implementar un LoT computacionalmente, todos comparten la propiedad de estar construidos a partir de un conjunto de símbolos y reglas atómicos mediante los cuales se pueden combinar para formar expresiones nuevas y más complejas.

La mayoría de los estudios de LoT se han centrado en el aspecto compositivo del lenguaje, que se ha modelado dentro de un [[Tenenbaum et al., 2011](#)] bayesiano o un marco [[Amalric et al., 2017a](#), [Goldsmith, 2002](#), [Romano et al., 2013](#), [Goldsmith, 2001](#)] de longitud mínima de descripción (MDL).

El método común es definir una gramática con un conjunto de producciones basadas en

operaciones que son intuitivas para los investigadores y luego estudiar cómo diferentes procesos de inferencia coinciden con patrones regulares en el aprendizaje humano. Un estudio reciente [Piantadosi et al., 2016] pone el foco en el proceso de cómo elegir empíricamente el conjunto de producciones y cómo diferentes definiciones de LoT pueden crear diferentes patrones de aprendizaje.

### 1.2.1. Gramáticas

**Explicar gramáticas**

**Explicar diferencia entre sintaxis y semántica**

El proyecto de análisis bayesiano del aprendizaje de conceptos de modelos LoT utilizando inferencia bayesiana en un espacio de hipótesis estructurado gramaticalmente [Goodman et al., 2008]. Cada propuesta de LoT suele formalizarse mediante una gramática libre de contexto  $\mathcal{G}$  que define las funciones o programas válidos que se pueden generar, como en cualquier otro lenguaje de programación. Un programa es un árbol de derivación de  $\mathcal{G}$  que debe interpretarse o ejecutarse de acuerdo con una semántica determinada para obtener una descripción real del concepto en la tarea cognitiva en cuestión. Por lo tanto, cada concepto es luego representado por cualquiera de los programas que lo describen y se define un proceso de inferencia bayesiano para inferir de los datos observados la distribución de programas válidos en  $\mathcal{G}$  que describen los conceptos.

## 1.2.2. Composición

Los lenguajes combinatorios pueden describir un vasto conjunto de conceptos a partir de un pequeño conjunto de primitivas. Esto se puede entender en un ejemplo relativamente simple en el dominio de las formas. Un lenguaje combinatorio y simbólico similar a Logo [Abelson et al., 1974] puede combinar operaciones como "mover", "pluma arriba", "pluma abajo.<sup>º</sup> rotar" para generar un conjunto infinito de expresiones (o programas) que, cuando se evalúa, puede transmitir todo tipo de formas.

Un lenguaje que describe conceptos (como formas) también proporciona una noción natural de su complejidad [Kolmogorov, 1968]. Un concepto es simple, relativo a ese lenguaje, cuando puede describirse mediante un programa corto. Por el contrario, es complejo cuando todas sus descripciones requieren una larga secuencia de instrucciones. Por ejemplo, en el caso del lenguaje Logo, un cuadrado puede simplemente instruirse como un bucle de cuatro desplazamientos seguidos de rotaciones de 90 grados. En este lenguaje, el ícono de un rostro se implementará mediante un programa mucho más largo y, por lo tanto, será más complejo. Sin embargo, este concepto sería más sencillo cuando se describiera en un lenguaje en el que el ícono de un rostro (o los símbolos de nariz, boca, etc.) estén disponibles como primitivos en el lenguaje.

En el dominio de los conceptos booleanos, se estudió una amplia gama de variedades lógicas de conceptos en [Feldman, 2003], revelando una ley sorprendentemente simple: la dificultad subjetiva de un concepto booleano para un aprendiz humano es directamente proporcional a la longitud del programa compatible más corto en el lenguaje de la lógica proposicional (es decir, variables booleanas combinadas con los operadores *and*, *or* y *not*). Este resultado puede sugerir que el LoT humano está equipado con reglas y símbolos

similares a los que se encuentran en la lógica proposicional. De hecho, la correlación entre la dificultad subjetiva de los conceptos y su complejidad se ha utilizado como vehículo general para estudiar el LoT humano en varios dominios [Piantadosi et al., 2016, Leeuwenberg, 1971, Amalric et al., 2017b, Romano et al., 2018, Lupyan et al., 2007]. Aunque a menudo está implícito, la estrategia general es (1) asumir un idioma; (2) encontrar el programa compatible más corto para algunos conceptos en ese idioma; (3) comparar la duración de estos programas con la dificultad subjetiva de los conceptos; y finalmente (4) repetir este proceso para varios idiomas dentro de un universo de posibles candidatos y elegir el idioma que mejor se ajuste en (3). Como se mencionó anteriormente, la longitud del programa depende de las primitivas del lenguaje en el que está escrito este programa, por lo que diferentes lenguajes hacen diferentes predicciones.

Una pregunta natural, sin embargo, es si las primitivas de una LoT son universales –tanto a través de diferentes individuos como a lo largo del desarrollo– o si, en cambio, el repertorio semántico de un lenguaje es dinámico y está moldeado por la experiencia. De hecho, es probable que nuestra capacidad para representar automáticamente conceptos booleanos de manera sucinta no se deba a un lenguaje proposicional eficiente innato en nuestra mente. En cambio, proponemos que esta capacidad surge como un subproducto de nuestro cerebro que aprende rápidamente representaciones eficientes de los conceptos que generalmente encontramos en la vida cotidiana.

Nuestra pregunta de investigación es: ¿con qué rapidez podemos adaptar nuestros mecanismos de aprendizaje cuando nos encontramos con un nuevo dominio en el que nuestras representaciones a priori ya no son eficientes? Examinamos la hipótesis de que los humanos tienen la capacidad de recombinar rápidamente proposiciones en su LoT, agregando nuevas primitivas a su lenguaje. En otras palabras, ese aprendizaje conduce a un

proceso de compilación de rutinas en funciones dentro de el LoT.

En el ejemplo del lenguaje Logo se puede imaginar que si las producciones que dibujan cuadrados son muy frecuentes, sería eficaz dedicar un nuevo símbolo a esta producción. El nuevo símbolo cuadrado.<sup>es</sup> una construcción jerárquica de "segundo orden" de las primitivas de "primer orden" del lenguaje. Tiene un costo (de incrementar el léxico del lenguaje) pero en el nuevo lenguaje, dibujar un cuadrado puede ser instanciado con un programa muy corto (es decir, cuadrado") y por lo tanto usa menos memoria. De hecho, un lenguaje de nivel superior nos permite alcanzar un nivel superior de abstracción al liberar la memoria y el poder de procesamiento, haciendo así pensables pensamientos más complejos [Minsky, 1967, Murphy, 1988].

La mayor parte del trabajo en la literatura sobre LoT, aunque incluye naturalmente un mecanismo de aprendizaje, tiende a acercarse al LoT como un sistema estable que deben descubrir los experimentadores, que prueban diferentes plantillas candidatas y seleccionan la que mejor se ajusta a los datos después del entrenamiento [Goodman et al., 2008, Kemp, 2012, Piantadosi et al., 2016]. Aún así, queda por descubrir cómo las diferentes trayectorias de la experiencia pueden dar forma a la adquisición de manera diferente y pueden cambiar constantemente el repertorio de un LoT después de cada exposición.

### **1.2.2.1. Longitud Mínima de Descripción**

#### **MDL**

##### **Complejidad de kolmogorov**

### **1.2.2.2. Ciencia Cognitiva Bayesiana**

**Rational analysis y plot**

## **Capítulo 2**

# **Lenguaje del pensamiento en secuencias binarias**

**2.1. Trabajos Previos**

**2.2. Modelo**

**2.3. Experimento**

**2.4. Resultados**

**2.5. Discusión**

# **Capítulo 3**

## **Validación bayesiana de gramáticas para el lenguaje del pensamiento**

**3.1. Método**

**3.2. Aplicación al lenguaje de geometría**

**3.3. Resultados**

**3.4. Discusión**

**3.5. Anexo: Probando el teorema de codificación**



# **Capítulo 4**

## **Actualización bayesiana de gramáticas para el lenguaje del pensamiento**

### **4.1. Método**

#### **4.1.1. Lenguaje lógico**

#### **4.1.2. Modelo libre**

#### **4.1.3. Modelo estático**

#### **4.1.4. Modelo dinámico**

### **4.2. Experimento**

### **4.3. Resultados**

### **4.4. Discusión**



# **Capítulo 5**

## **Un nuevo marco para estudiar los sesgos de aprendizaje de conceptos en el lenguaje del pensamiento**

### **5.1. Método**

#### **5.1.1. Experimento**

#### **5.1.2. Representación**

#### **5.1.3. Hipótesis**

### **5.2. Resultados**

### **5.3. Discusión**



# **Capítulo 6**

## **BORRAR: Validación Bayesiana de producciones gramaticales para el lenguaje del pensamiento**

### **6.1. Introducción**

No sólo le costaba comprender que el símbolo genérico perro abarcara tantos individuos dispares de diversos tamaños y diversa forma; le molestaba que el perro de las tres y catorce (visto de perfil) tuviera el mismo nombre que el perro de las tres y cuarto (visto de frente) (...) Había aprendido sin esfuerzo el inglés, el francés, el portugués, el latín. Sospecho, sin embargo, que no era muy capaz de pensar. Pensar es olvidar diferencias, es generalizar, abstraer. En el abarrotado mundo de Funes no había sino detalles, casi inmediatos. [Borges, 1944]

En su cuento, el escritor Jorge Luis Borges describió a un personaje de ficción, Fines, capaz de recordar cada detalle de su vida, pero sin ser capaz de generalizar ninguna de esa información en categorías mentales y, por tanto –recalcó Borges–, incapaz de pensar.

Los investigadores han modelado estas categorías mentales o clases conceptuales con dos enfoques clásicos: en términos de su similitud con un ejemplo genérico o prototipo [Rosch, 1999, Nosofsky, 1986, Rosch et al., 1976, Rosch and Mervis, 1975] o basados en una representación simbólica a través de reglas [Boole, 1854, Fodor, 1975, Gentner, 1983].

Enfoques simbólicos como la hipótesis del *lenguaje del pensamiento* (LoT, por sus siglas en inglés) [Fodor, 1975], afirman que el pensamiento toma forma en una especie de lenguaje mental compuesto por un conjunto limitado de símbolos atómicos que se pueden combinar para formar estructuras más complejas siguiendo reglas combinatorias.

A pesar de las críticas y objeciones [Blackburn, 1984, Loewer and Rey, 1991, Knowles, 1998, Aydede, 1997], los enfoques simbólicos —en general— y la hipótesis LoT —en particular— han ganado una atención renovada con resultados recientes que podrían explicar el proceso de aprendizaje en diferentes dominios como un proceso de inferencia estadística sobre un espacio de hipótesis estructurado y componible [Tenenbaum et al., 2011, Piantadosi and Jacobs, 2016].

El LoT no es necesariamente único. De hecho, la forma que toma ha sido modelada de muchas formas diferentes dependiendo del dominio del problema: aprendizaje de conceptos numéricos [Piantadosi et al., 2012], aprendizaje de secuencias [Amalric et al., 2017a, Yildirim and Jacobs, 2015, Romano et al., 2013], aprendizaje visual de conceptos [Ellis et al., 2015], aprendizaje de teorías [Ullman et al., 2012], etc.

Si bien los trabajos pueden diferir en cómo se puede implementar un LoT computacio-

nalmente, todos comparten la propiedad de estar construidos a partir de un conjunto de símbolos atómicos y reglas por las que se los pueden combinar para formar expresiones nuevas y más complejas.

La mayoría de los estudios de LoT se han centrado en el aspecto compositivo del lenguaje, modelando la composición a través de técnicas de probabilidad Bayesiana [Tenenbaum et al., 2011] o de longitud mínima de descripción (MDL, por sus siglas en inglés) [Amalric et al., 2017a, Goldsmith, 2002, Romano et al., 2013, Goldsmith, 2001].

El método más común es definir una gramática con un conjunto de producciones basadas en operaciones que son intuitivas para los investigadores y luego estudiar cómo diferentes procesos de inferencia coinciden con los patrones del aprendizaje humano. Un estudio reciente [Piantadosi et al., 2016] pone el foco en el proceso de cómo elegir empíricamente el conjunto de producciones y cómo diferentes definiciones del LoT pueden crear diferentes patrones de aprendizaje. En este trabajo, nos vemos en esa dirección pero utilizando la inferencia Bayesiana para seleccionar el LoT en lugar de seleccionarlo a partir de la comparación empírica de las distintas versiones con los patrones a replicar.

En términos generales, nuestro objetivo es proponer un método para seleccionar el conjunto de símbolos atómicos en un proceso de inferencia seleccionando y recortándolos de un repertorio más amplio. Más precisamente, nos interesa probar si la inferencia Bayesiana puede utilizarse para decidir el conjunto adecuado de producción en un LoT definido por una gramática libre de contexto, derivando las producciones a elegir de los datos experimentales de los sujetos del experimento. Para hacer esto, un investigador debería construir un lenguaje más amplio con dos conjuntos de producciones: 1) aquellas para las que tiene una fuerte convicción previa de que podrían ser utilizadas en la tarea cognitiva a estudiar, y 2) otras producciones que podrían utilizarse para estructurar los datos y extraer

regularidades incluso si cree que no son parte del repertorio de razonamiento humano para la tarea. Con el nuevo lenguaje más amplio, debería convertir la gramática libre de contexto que lo define en una gramática probabilística libre de contexto (PCFG, por sus siglas en inglés) y utilizar en análisis Bayesiano para inferir probabilidad de cada producción y el conjunto que mejor explique los datos.

En la siguiente sección, formalizaremos este procedimiento y luego lo aplicaremos en el *lenguaje de geometría* presentado por Amalric et al. en un reciente estudio sobre el aprendizaje de secuencias geométricas [Amalric et al., 2017a]. Este LoT define un lenguaje con algunos elementos geométricos básicos, con instrucciones como las producciones gramaticales y luego modela su composición dentro del marco de MDL. Nuestro método, sin embargo, se puede aplicar a cualquier modelo de LoT que defina una gramática, independientemente de si su aspecto compositivo se modela utilizando un enfoque de probabilidad Bayesiana o de MDL.

Finalmente, incluso con el reciente aumento de popularidad de la inferencia Bayesiana y el MDL en la ciencia cognitiva, no hay — hasta donde sabemos—, intentos prácticos de cerrar la brecha entre ambos enfoques.

La teoría de la computabilidad, a través del Teorema de Codificación de Levin [Levin, 1974], expone una notable relación entre la *complejidad de Kolmogorov* de una secuencia (que es la base del cálculo del MDL) y su *probabilidad universal*, la cual es ampliamente utilizada en la teoría algorítmica de la información. Aunque ambas métricas resultan no computables y se encuentran definidas sobre una Máquina Universal de Turing libre de prefijos, podemos aplicar estas ideas a otras Máquinas de Turing no universales de la misma manera que el concepto de complejidad es utilizado para el cálculo de MDL en lenguajes específicos no universales.

En este trabajo también examinamos hasta qué punto esta predicción teórica para secuencias infinitas se preserva empíricamente para un LoT específico, el *lenguaje de geometría*. Aunque la relación logarítmica inversa entre ambas métricas está probada para lenguajes universales en el Teorema de Codificación, probar esta misma propiedad para un lenguaje no universal particular muestra que el lenguaje comparte algunas propiedades interesantes con los lenguajes generales. Esto constituye un primer paso hacia un vínculo formal entre el modelado de probabilidad y el de complejidad para el LoT.

## 6.2. Inferencia Bayesiana para las producciones del LoT

El proyecto de análisis Bayesiano del LoT modela el aprendizaje de conceptos utilizando la inferencia Bayesiana en un espacio de hipótesis estructurado a partir de una gramática [Goodman et al., 2008]. Cada propuesta de LoT suele formalizarse mediante una gramática libre de contexto  $\mathcal{G}$  que define las funciones o programas válidos que se pueden generar, como en cualquier otro lenguaje de programación. Aquí, un programa es un árbol de derivación de  $\mathcal{G}$  que necesita ser interpretado o ejecutado de acuerdo a una semántica dada para obtener una descripción real del concepto en la tarea cognitiva en cuestión. Por lo tanto, cada concepto puede ser representado por cualquiera de los programas que lo describen al ejecutarse, y un proceso de inferencia Bayesiana es definido para calcular la distribución de los programas válidos de  $\mathcal{G}$  que describen los conceptos a explicar.

Como se explicó anteriormente, nuestro objetivo es derivar las producciones de  $\mathcal{G}$  a partir de los datos, en lugar de sólo conjeturarlas utilizando un conocimiento a priori sobre la tarea. Otros trabajos previos en LoT ajustaron las probabilidades de las producciones de las gramáticas libres de contexto utilizando inferencia Bayesiana [Piantadosi et al., 2016],

sin embargo, han puesto el foco en la integración de las probabilidades de producción para predecir mejor los datos y no en cambiar la definición de las gramáticas. Aquí queremos estudiar si el proceso de inferencia podría permitirnos decidir qué producciones de la gramática pueden podarse con seguridad. Para esto, introducimos un método genérico que puede utilizarse en cualquier gramática para seleccionar y probar el conjunto adecuado de producciones. En lugar de usar una gramática fija y ajustar las probabilidades de las producciones para predecir los datos, utilizamos la inferencia Bayesiana para remover las producciones con una probabilidad inferior a cierto umbral. Esto permite al investigador validar lo adecuado de las producciones que ha elegido para la gramática o incluso definir una que sea lo suficientemente amplia como para expresar diferentes regularidades y dejar que el método seleccione el mejor conjunto a partir de los datos observados.

Para inferir la probabilidad de cada producción a partir de los datos observados, necesitamos agregar un vector de probabilidades  $\theta$  asociado con cada producción para convertir a la gramática libre de contexto  $\mathcal{G}$  en una gramática probabilística libre de contexto (PCFG) [Manning and Schütze, 1999].

Sea  $D = (d_1, d_2, \dots, d_n)$  la lista de conceptos producidos por los sujetos en un experimento. Esto significa que cada  $d_i$  es un concepto producido por un sujeto en cada ensayo. Luego,  $P(\theta | D)$ , la probabilidad a posteriori de los pesos de cada producción después de observar los datos, se puede calcular marginalizando sobre los posibles programas que computan  $D$ :

$$P(\theta | D) = \sum_{\text{Prog}} P(\text{Prog}, \theta | D), \quad (6.1)$$

donde cada  $\text{Prog} = (p_1, p_2, \dots, p_n)$  es un posible conjunto de programas tales que cada  $p_i$

computa el correspondiente concepto  $d_i$ .

Podemos usar la inferencia Bayesiana para aprender los programas correspondientes Prog y el vector  $\theta$  para cada producción de la gramática, aplicando la regla de Bayes de la siguiente manera:

$$P(\text{Prog}, \theta | D) \propto P(D | \text{Prog}) P(\text{Prog} | \theta) P(\theta), \quad (6.2)$$

Muestrear el conjunto de programas de  $P(\text{Prog} | \theta)$  fuerza un sesgo inductivo que es necesario para manejar la incertidumbre frente a datos escasos. Aquí usamos un estándar previo para los programas que es común en la literatura de LoT para introducir un sesgo de complejidad sintáctica que favorece programas más cortos [Goodman et al., 2008, Overlan et al., 2017]. Intuitivamente, la probabilidad de muestreo de un determinado programa es proporcional al producto de las reglas de producción que se utilizaron para generar dicho programa y, por lo tanto, inversamente proporcional al tamaño del árbol de derivación. Formalmente, se define como:

$$P(\text{Prog} | \theta) = \prod_{i=1}^n P(p_i | \theta), \quad (6.3)$$

donde  $P(p_i | \theta) = \prod_{r \in G} \theta_r^{f_r(p_i)}$  es la probabilidad del programa  $p_i$  en la gramática, y  $f_r(p_i)$  es el número de ocurrencias de la producción  $r$  en el programa  $p_i$ .

En (6.2),  $P(\theta)$  es una Dirichlet que se utiliza como distribución a priori sobre las producciones de la gramática. Al utilizar el término  $P(\theta)$  estamos abusando de la notación por simplicidad. El término adecuado sería  $P(\theta | \alpha)$  para expresar la distribución a priori con  $\alpha \in \mathbb{R}^\ell$  su hiperparámetro que actúa como vector de concentración asociado donde  $\ell$

es el número de producciones de la gramática. Esta distribución a priori ha sido también reemplazada por una distribución uniforme, ya que no muestra diferencias significativas en resultados de predicción [Piantadosi et al., 2012, Yildirim and Jacobs, 2015]. Sin embargo, aquí utilizaremos la distribución Dirichlet para poder inferir las probabilidades de producción a partir de este modelo más flexible.

La función de verosimilitud es sencilla. No utiliza ningún parámetro libre para contabilizar errores de percepción en la observación. Esto obliga a que sólo los programas que computan el concepto exacto se tengan en cuenta, y puede ser fácilmente calculada de la siguiente manera:

$$P(D \mid \text{Prog}) = \prod_{i=1}^n P(d_i \mid p_i), \quad (6.4)$$

donde  $P(d_i \mid p_i) = 1$  si el programa  $p_i$  computa  $d_i$ , y 0 en caso contrario.

Sin embargo, calcular  $P(\theta \mid D)$  de manera directa no es manejable ya que requiere sumar todas las posibles combinaciones de programas Prog para cada uno de los posibles valores de  $\theta$ . Para este objetivo, utilizamos entonces el algoritmo de muestreo de Gibbs [Geman and Geman, 1984] para PCFGs a través del Método de Monte Carlo basado en cadenas de Markov (MCMC, por sus siglas en inglés) similar al propuesto en [Johnson et al., 2007], el cual alterna en cada paso de la cadena entre las dos distribuciones condicionales:

$$P(\text{Prog} \mid \theta, D) = \prod_{i=1}^n P(p_i \mid d_i, \theta). \quad (6.5)$$

$$P(\theta \mid \text{Prog}, D) = P_D(\theta \mid f(\text{Prog}) + \alpha). \quad (6.6)$$

Aquí,  $P_D$  es la distribución Dirichlet donde las posiciones del vector  $\alpha$  fueron actualizadas contando las ocurrencias de las producciones correspondientes para todos los programas  $p_i \in \text{Prog}$ .

En la siguiente sección, aplicamos este método a un LoT específico. Agregamos un nuevo conjunto ad-hoc de producciones a la gramática original que puedan explicar regularidades pero que no están relacionadas con la tarea cognitiva. Intuitivamente, estas producciones ad-hoc no deberían formar parte del repertorio del LoT, aún así, todas ellas pueden usarse en muchos programas posibles para expresar cada uno de los conceptos.

Hasta ahora, los enfoques probabilísticos del LoT han tenido éxito para modelar el aprendizaje de conceptos a partir de pocos ejemplos [[Tenenbaum et al., 2011](#), [Piantadosi and Jacobs, 2016](#)]. Sin embargo, esto no significa que los modelos Bayesianos puedan inferir la sintaxis de la gramática a partir de datos escasos. Aquí probamos esta hipótesis. Si el método es eficaz, debería asignar una probabilidad baja las producciones ad-hoc y en su lugar favorecer el conjunto original de producciones seleccionadas por los investigadores para la tarea cognitiva. Esto no sólo proporcionaría evidencia empírica adicional sobre la idoneidad de la elección original de producciones para el LoT, sino que —más importante— brindaría evidencia sobre la utilidad de la inferencia Bayesiana para validar el conjunto de producciones involucradas en diferentes LoTs.

### 6.3. El lenguaje de geometría: $\mathcal{G}eo$

El *lenguaje de geometría*,  $\mathcal{G}eo$  [[Amalric et al., 2017a](#)], es un generador probabilístico de secuencias de movimientos en un octágono regular como el de la figura Fig 6.1. Se ha usado para modelar predicciones de secuencias humanas en adultos y preescolares de Francia y miembros adultos de un grupo indígena en la Amazonía. Como en otros dominios de LoT, se han propuesto para el dominio de secuencias espaciales diferentes modelos como el de [[Yildirim and Jacobs, 2015](#)]. Aunque ambos modelan con éxito las secuencias

en sus experimentos, proponen diferentes gramáticas para sus modelos (en particular, [Amalric et al., 2017a] contiene producciones para expresar reflexiones o simetrías). Esta diferencia se puede explicar por las particularidades de cada experimento. Por un lado, en [Amalric et al., 2017a] categorizaron secuencias en 12 grupos en función de su complejidad, mostrándolos en un octágono y evaluando el desempeño en una población diversa para extrapolar las secuencias. Por otro lado, en [Yildirim and Jacobs, 2015] categorizaron las secuencias en 4 grupos, mostrándolos en un heptágono y evaluando el desempeño de adultos no sólo para predecir cómo continúan las secuencias, sino también para transferir el conocimiento de la secuencia aprendida a través de estímulos visuales y auditivos. A pesar de que los dominios no son iguales, las diferencias en las gramáticas refuerzan la necesidad para métodos automáticos que permitan probar y validar múltiples gramáticas para el mismo dominio en la comunidad que estudia el LoT.

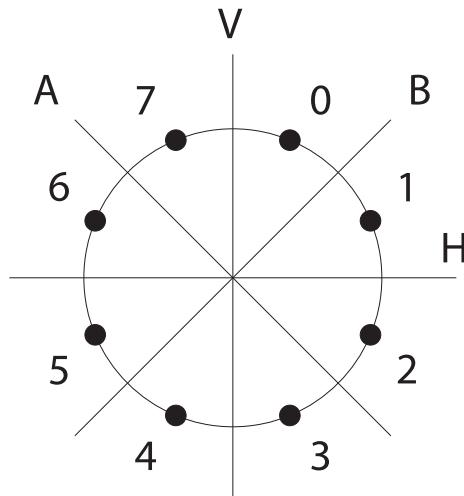


Figura 6.1: **Possibles posiciones de la secuencia y ejes de reflexión**  $\Sigma$  apunta alrededor de un círculo para mapear la posición actual en el octágono y los ejes de reflexión

Las reglas de producción de la gramática  $\mathcal{G}_{\text{eo}}$  fueron seleccionadas en base a afirmaciones previa de la universalidad de cierto conocimiento geométrico humano [Izard et al.,

2011, Dehaene et al., 2006, Dillon et al., 2013] como nociones espaciales [Landau et al., 1981, Lee et al., 2012] y detección de geometrías [Westphal-Fitch et al., 2012, Machilsen et al., 2009].

Con estas reglas de producción, las secuencias se describen concatenando o repitiendo secuencias de movimientos en el octágono. El conjunto original de producciones se muestra en la Tabla 6.1 y –además de los operadores de concatenación y repetición– incluye la siguiente familia de producciones atómicas de transición geométrica: movimientos en sentido antihorario, permanecer en la misma ubicación, movimientos en sentido horario y movimientos de simetría.

Cuadro 6.1: **Gramática original**

<b>Producción inicial</b>		
START	$\rightarrow$ [INST]	símbolo inicial
<b>Producciones básicas</b>		
INST	$\rightarrow$ ATOMIC	producción atómica
INST	$\rightarrow$ INST,INST	concatenación
INST	$\rightarrow$ REP[INST] <sup>n</sup>	familia repetir con $n \in [2, 8]$
REP	$\rightarrow$ REPO	repetición simple
REP	$\rightarrow$ REP1<ATOMIC>	repetir con variación del punto de inicio usando ATOMIC
REP	$\rightarrow$ REP2<ATOMIC>	repetir con variación de la secuencia resultante usando ATOMIC
<b>Atomic productions</b>		
ATOMIC	$\rightarrow$ -1	siguiente elemento en sentido antihorario (ACW)
ATOMIC	$\rightarrow$ -2	segundo elemento ACW
ATOMIC	$\rightarrow$ -3	tercer elemento ACW
ATOMIC	$\rightarrow$ +0	permanecer en la misma posición
ATOMIC	$\rightarrow$ +1	siguiente elemento en sentido horario (CW)
ATOMIC	$\rightarrow$ +2	segundo elemento CW
ATOMIC	$\rightarrow$ +3	tercer elemento CW
ATOMIC	$\rightarrow$ A	simetría alrededor de un eje diagonal
ATOMIC	$\rightarrow$ B	simetría alrededor del otro eje diagonal
ATOMIC	$\rightarrow$ H	simetría horizontal
ATOMIC	$\rightarrow$ V	simetría vertical
ATOMIC	$\rightarrow$ P	simetría rotacional

El lenguaje en realidad admite no sólo una simple repetición  $n$  veces de un bloque de producciones, también admite dos producciones más complejas en la familia de repeticiones:

repetiendo con un cambio en el punto de inicio después de cada ciclo y repitiendo con un cambio en la secuencia resultante después de cada ciclo. Más detalles sobre la sintaxis formal y la semántica se pueden encontrar en [Amalric et al., 2017a], aunque no son necesarios aquí.

Cada programa  $p$  generado por la gramática describe un mapeo  $\Sigma \rightarrow \Sigma^+$ , para  $\Sigma = \{0, \dots, 7\}$ . Aquí,  $\Sigma^+$  representa el conjunto de todas las secuencias finitas (no vacías) sobre el alfabeto  $\Sigma$ , que puede entenderse como una secuencia finita de puntos en el octágono. Estos programas luego deben ejecutarse o interpretarse desde un punto de partida para obtener como resultado la secuencia de puntos. Sea  $p = [+1,+1]$  un programa, entonces  $p(0)$  es el resultado de ejecutar  $p$  a partir del punto 0 (es decir, la secuencia 1, 2) y  $p(4)$  es el resultado de ejecutar el mismo programa a partir del punto 4 del octágono (es decir, la secuencia 5, 6).

Cada secuencia se puede describir con muchos programas diferentes: desde una simple concatenación de producciones atómicas a formas más comprimidas utilizando repeticiones. Por ejemplo, para moverse a través de todo el octágono en el sentido de las agujas del reloj, un punto a la vez comenzando desde el punto 0, uno puede utilizar  $[+1,+1,+1,+1,+1,+1,+1,+1](0)$  o  $[\text{REP}[+1]^8](0)$  o  $[\text{REP}[+1]^7, +1](0)$ , etc. Para alternar 8 veces entre los puntos 6 y 7, uno puede utilizar una producción de reflexión como  $[\text{REP}[A]^8](6)$ , o  $[\text{REP}[+1,-1]^4](6)$ .

### 6.3.1. Experimento original de $\mathcal{G}eo$

Para inferir las producciones a partir de los datos observados, utilizamos los datos originales del experimento en [Amalric et al., 2017a]. En el experimento, los voluntarios

fueron expuestos a una serie de secuencias espaciales definidas en un octágono y se les pidió que pronosticaran ubicaciones futuras. Las secuencias se seleccionaron de acuerdo con su MDL en el *lenguaje de geometría* para que cada secuencia pueda ser descripta fácilmente con pocas producciones.

**Participantes:** Los datos utilizados en este trabajo provienen, salvo que se indique lo contrario, del Experimento 1 en el que los participantes eran 23 adultos franceses (12 mujeres, edad media = 26,6, rango de edad = 20 – 46) con educación de nivel universitario. Los datos del Experimento 2 se utilizan más adelante cuando se comparan los resultados de adultos y niños. En el último, los participantes fueron 24 niños en edad preescolar (edad mínima = 5,33, edad máxima = 6,29, media =  $5,83 \pm 0,05$ ).

**Procedimiento:** En cada prueba, los dos primeros puntos de la secuencia se muestran con un destello de manera secuencial en el octágono y el usuario tiene que hacer clic luego en la siguiente ubicación. Si el sujeto selecciona la ubicación correcta, se le pide que continúe con el siguiente punto hasta que los ocho puntos de la secuencia se completen. Si hubo un error en algún momento, se corrige el error, la secuencia vuelve a mostrarse desde el primer punto hasta el punto corregido y se le solicita al usuario predecir la siguiente ubicación. Cada  $d_i \in \Sigma^8$  de nuestro conjunto de datos  $D$  es, por tanto, la secuencia de las ocho posiciones que hizo clic en cada prueba cada sujeto. El procedimiento detallado se puede encontrar en el citado trabajo.

### 6.3.2. Extendiendo la gramática de $\mathcal{G}eo$

Ahora ampliaremos el conjunto original de producciones en  $\mathcal{G}eo$  con un nuevo conjunto de producciones que también pueden expresar regularidades pero que no están relacionadas con ninguna intuición geométrica para probar nuestro modelo de inferencia Bayesiano.

En la Tabla 6.2 mostramos el nuevo conjunto de producciones que incluye instrucciones tales como moverse al punto cuya ubicación es el cuadrado de la ubicación actual, o utilizar el punto actual  $i$  para seleccionar el  $i^{\text{th}}$ dígito de un número conocido como  $\pi$  o el número de Chaitín (calculado para una máquina universal de Turing particular y programas de hasta 84 bits [Calude et al., 2002]). Todos los dígitos se devuelven en módulo aritmético 8 para obtener una posición válida. Por ejemplo,  $\text{PI}(0)$  retorna el primer dígito de  $\pi$ , es decir  $\text{PI}(0) = 3 \text{ mód } (8) = 3$ ; y  $\text{PI}(1) = 1$ .

Cuadro 6.2: Producciones ad-hoc

ATOMIC	$\rightarrow$	DOUBLE	$(\text{ubicación} * 2) \text{ mód } 8$
ATOMIC	$\rightarrow$	-DOUBLE	$(\text{ubicación} * -2) \text{ mód } 8$
ATOMIC	$\rightarrow$	SQUARE	$(\text{ubicación}^2) \text{ mód } 8$
ATOMIC	$\rightarrow$	GAMMA	$\Gamma(\text{ubicación}+1) \text{ mód } 8$
ATOMIC	$\rightarrow$	PI	ubicación-ésimo dígito de $\pi$
ATOMIC	$\rightarrow$	EULER	ubicación-ésimo dígito de $e$
ATOMIC	$\rightarrow$	GOLD	ubicación-ésimo dígito de $\phi$
ATOMIC	$\rightarrow$	PYTH	ubicación-ésimo dígito de $\sqrt{2}$
ATOMIC	$\rightarrow$	KHINCHIN	ubicación-ésimo dígito de la constante de Khinchin
ATOMIC	$\rightarrow$	GLAISHER	ubicación-ésimo dígito de la constante de Glaisher
ATOMIC	$\rightarrow$	CHAITIN	ubicación-ésimo dígito de la constante de Chaitín Omega

### 6.3.3. Resultados de inferencia para $\mathcal{G}_{eo}$

Para permitir que la MCMC converja más rápido (y luego comparar la probabilidad del concepto con su correspondiente MDL), generamos todos los programas que explican cada una de las secuencias observadas del experimento. De esta manera, podemos tomar muestras de la distribución  $P(p_i | d_i, \theta)$  por muestreo de una distribución multinomial de todos los posibles programas  $p_i$  que computan  $d_i$ , donde cada  $p_i$  tiene una probabilidad de ocurrencia igual a  $P(p_i | \theta)$ .

Para tener una intuición de la expresividad de la gramática para generar diferentes programas para una secuencia y el costo de calcularlos, vale la pena mencionar que hay más de 159 millones de programas que computan las 292 secuencias únicas generadas por los sujetos en el experimento y que, para cada secuencia, hay un promedio de 546,713 programas (mín = 10,749, máx = 5,500,026,  $\sigma = 693,618$ ).

La Fig 6.2 muestra el  $\theta$  inferido para las secuencias observadas de los sujetos, con el hiperparámetro de la Dirichlet inicial en  $\alpha = (1, \dots, 1)$ . Cada barra muestra la probabilidad media y el error estándar de cada una de las producciones atómicas después de 50 pasos de la MCMC, dejando fuera los primeros 10 pasos como iteraciones de *burn-in*.

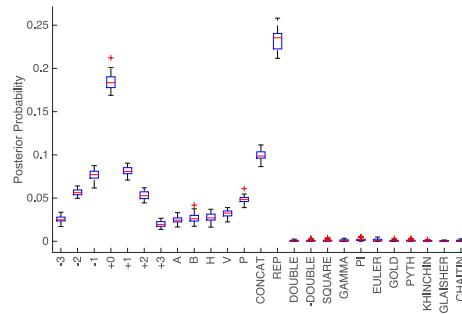


Figura 6.2:  $\theta_i$  inferido Probabilidad inferida para cada producción de la gramática

Aunque 50 pasos puedan parecer bajos para que converja un algoritmo de MCMC,

nuestro método calculó  $P(p_i \mid d_i, \theta)$  de manera exacta para acelerar la convergencia y para poder luego comparar la probabilidad con la complejidad del modelo MDL original. En la Fig 6.3, mostramos una traza de ejemplo para cuatro ejecuciones de MCMC para  $\theta_{+0}$ , que corresponde al valor atómico de la producción +0, pero es representativo del comportamiento de todos los  $\theta_i$ . (consulte los [Pasos de MCMC para las producciones de Geo](#) [Pasos de MCMC para el resto de las producciones de la gramática Geo](#) para las trazas del conjunto entero de producciones).

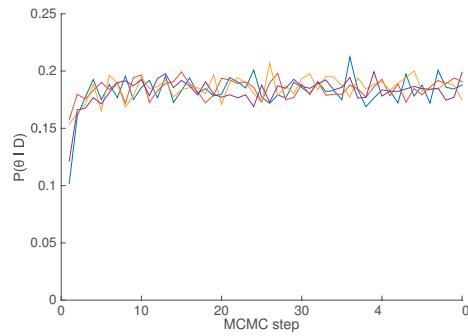


Figura 6.3:  $\theta_{+0}$  inferido. Probabilidad inferida para +0 en cada paso para cuatro cadenas de MCMC.

La Fig 6.2 muestra una diferencia notable entre la probabilidad de las producciones que se utilizaron originalmente sobre la base de intuiciones geométricas y las producciones ad-hoc. El gráfico muestra también que cada producción en el sentido horario tiene casi la misma probabilidad que su correspondiente producción en sentido antihorario, y una relación similar aparece entre la simetría horizontal y la vertical (H y V) y las simetrías alrededor de los ejes diagonales (A y B). Esto es importante porque el experimento original fue diseñado para equilibrar tal comportamiento y la gramática inferida lo refleja también.

La Fig 6.4 muestra el mismo  $\theta$  inferido pero agrupado según su familia de producción. El agrupamiento destaca la baja probabilidad de todas las producciones ad-hoc, pero también muestra una diferencia importante entre REP y el resto de las producciones, particularmente

respecto de la simple concatenación de producción (CONCAT). Esto indica que el lenguaje de geometría es capaz de reutilizar estructuras más simples que captura el significado geométrico para explicar los datos observados, un aspecto clave de un modelo exitoso de LoT que también se ve reflejado en la gramática inferida.

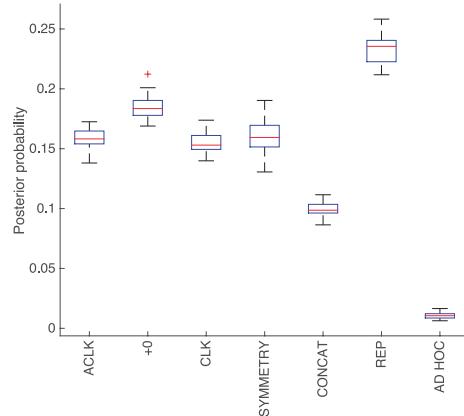


Figura 6.4:  $\theta_i$  **inferido agrupado por familia**. Probabilidad inferida para cada producción en la gramática, agrupada por familia.

Luego ejecutamos el mismo método de inferencia utilizando las secuencias observadas en otros experimentos, pero sólo con las producciones gramaticales originales (es decir, dejando de lado las producciones ad-hoc). Comparamos el resultado de inferir sobre nuestras secuencias previamente analizadas (que habían sido generadas por adultos) con aquellas generadas por niños (el Experimento 2 de [Amalric et al., 2017a]) y con las secuencias esperadas para un jugador ideal.

La Fig 6.5 muestra las probabilidades para cada producción atómica que se infieren de los datos de cada población. La figura denota que diferentes poblaciones pueden converger a diferentes probabilidades y, por tanto, a diferentes LoT. Específicamente, vale la pena mencionar que el sujeto ideal de hecho utiliza más producciones de repetición que simples concatenaciones en comparación con los adultos. Del mismo modo, los adultos utilizan más

repeticiones que los niños. Esto podría significar que el sujeto ideal es capaz de reproducir las secuencias reutilizando de manera recursiva otros programas más pequeños, mientras que los adultos y los niños tienen más problemas para comprender o aprender el programa más pequeño que puede explicar cada una de las secuencias de los experimentos, lo cuál es consistente con los resultados del modelo de MDL en [Amalric et al., 2017a].

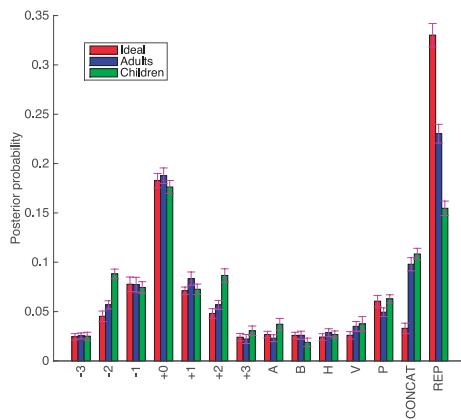


Figura 6.5:  $\theta_i$  inferido para el sujeto ideal, adultos y niños Probabilidad inferida para cada producción de la gramática para las diferentes poblaciones.

Cabe mencionar que en [Amalric et al., 2017a] la gramática completa para el *lenguaje de geometría* podía explicar el comportamiento de los adultos, pero tenía problemas para reproducir los patrones de los niños para algunas secuencias. Sin embargo, también demostraron que penalizar a la simetría rotacional (P) podría explicar adecuadamente el comportamiento de los niños. En la Fig 6.5, vemos que el valor medio de (P) para niños es 0.06 mientras que en adultos es 0.05 (una prueba-t de dos muestras revela que  $t = -12.6$ ,  $p = 10-19$ ). Esto puede no ser necesariamente contradictorio, ya que el modelo para niños en [Amalric et al., 2017a] se utilizó para predecir el siguiente símbolo de una secuencia después de ver su prefijo agregando una penalización para extensiones que usan la simetría rotacional (P) en el programa mínimo de cada secuencia. Por otro lado, el modelo Bayesiano en este trabajo intenta explicar las secuencias observadas producidas

por los niños considerando la probabilidad de una secuencia a partir de sumar todos los posibles programas que la pueden generar *y no sólo en los de tamaño mínimo*. Así, una producción como ( $P$ ) que podría no ser parte del programa mínimo para una secuencia, puede no ser necesariamente menos probable cuando se considera la distribución total de programas para esa misma secuencia.

## 6.4. Teorema de codificación

Para cada fenómeno siempre puede haber un número extremadamente grande, posiblemente infinito, de explicaciones. En un modelo de LoT, este espacio está limitado por la gramática  $\mathcal{G}$  que define las hipótesis válidas en el lenguaje. Aún así, hay que definir cómo se elige una hipótesis entre todas las posibles. Siguiendo el principio de la navaja de Ockham, se debe elegir la hipótesis más simple entre todas las posibles que explican un fenómeno. En ciencia cognitiva, y en el lenguaje de geometría en particular, la MDL se suele utilizar para modelar tal sesgo en la cognición humana. La MDL se basa sobre las ideas de la teoría de la información [Shannon, 1948], la complejidad de Kolmogorov [Kolmogorov, 1968] y la inducción de Solomonoff [Solomonoff, 1964].

El principio de la navaja de Ockham fue formalizado por Solomonoff [Solomonoff, 1964] en su teoría universal de la inferencia inductiva, que propone un método de predicción universal que aproxima cualquier distribución  $\mu$  a partir de observaciones previas, con el único supuesto de que  $\mu$  sea computable. En resumen, la teoría de Solomonoff utiliza todos los programas (en la forma de máquinas de Turing libre de prefijos) que pueden describir las observaciones previas de una secuencia para calcular la probabilidad de los siguientes símbolos de una manera óptima, dando más peso a los programas más cortos.

Intuitivamente, las teorías más simples, con baja complejidad, tienen mayor probabilidad que las teorías de mayor complejidad. Formalmente, esta relación es descrita en el Teorema de codificación [Levin, 1974], que cierra la brecha entre los conceptos de complejidad de Kolmogorov y la teoría de probabilidad. Sin embargo, los modelos de LoT que definen una distribución probabilística para sus hipótesis no han intentado compararla con una medida de complejidad de las hipótesis como las que se usan en MDL, ni al revés.

A continuación, formalizamos el Teorema de Codificación (para obtener más información, consulte [Li and Vitányi, 2013]) y lo probamos experimentalmente. Hasta donde sabemos, este es el primer intento para validar estas ideas para un lenguaje particular (no universal). El lector debe tener en cuenta que no estamos validando el teorema en sí, dado que ya ha sido probado para Máquinas de Turing universales. Aquí estamos probando si la relación logarítmica inversa entre la probabilidad y la complejidad podría mantenerse cuando se definen para un lenguaje específico no universal.

#### 6.4.1. La definición formal

Sea  $M$  una Máquina de Turing libre de prefijos –por *prefijo* nos referimos a que si  $M(x)$  está definida, entonces  $M$  está indefinida para cualquier extensión de  $x$ . Sea  $P_M(x)$  la probabilidad de que la máquina  $M$  compute la salida  $x$  cuando la entrada se llena con los resultados de los lanzamientos de una moneda justa, y sea  $K_M(x)$  la *complejidad de Kolmogorov de  $x$  relativa a  $M$* , que se define como la longitud del programa más corto que genera  $x$ , cuando se ejecuta en  $M$ . El Teorema de Codificación establece que, por cada cadena  $x$  tenemos:

$$\log \frac{1}{P_U(x)} = K_U(x) \quad (6.7)$$

hasta una constante aditiva, siempre que  $U$  sea una Máquina Universal de Turing de libre prefijos –por *Universal* nos referimos a una máquina que es capaz de simular cualquier otra máquina de Turing; puede entenderse como el lenguaje de programación elegido subyacente (Turing-completo)–. Es importante señalar que ni  $P_U$ , ni  $K_U$  son computables, lo que significa que tal mapeo no puede obtenerse por medios efectivos. Sin embargo, para máquinas específicas (no universales)  $M$ , uno puede –de hecho– calcular tanto  $P_M$  como  $K_M$ .

#### 6.4.2. Probando el teorema de codificación para $\mathcal{G}_{eo}$

A pesar de que  $P_M$  y  $K_M$  están definidas sobre una máquina de Turing  $M$ , el lector debe tener en cuenta que un LoT no se suele formalizar con una máquina de Turing, sino como un lenguaje de programación con su propia sintaxis de programas válidos y su propia semántica de ejecución que estipula cómo calcular un concepto a partir de un programa válido. Sin embargo, uno puede entender los lenguajes de programación como la definición de una máquina de Turing equivalente (no necesariamente universal), y a un LoT como un lenguaje que define a su equivalente máquina de Turing  $\mathcal{G}$  (no necesariamente universal). En resumen, las máquinas y los lenguajes son intercambiables en este sentido: ambas especifican los programas / términos, los cuales son objetos simbólicos que –a su vez– describen objetos semánticos (a saber, cadenas).

**La complejidad de Kolmogorov relativa a  $\mathcal{G}_{eo}$ :** En [Amalric et al., 2017a], la longitud mínima de descripción (MDL) se utilizó para modelar la combinación de las producciones del *lenguaje de geometría* en conceptos mediante la definición de una complejidad de Kolmogorov relativa al *lenguaje de geometría*, la cual denotamos como  $K_{\mathcal{G}_{eo}}$ .  $K_{\mathcal{G}_{eo}}(x)$  es

el tamaño mínimo de una expresión en la gramática de  $\mathcal{G}eo$  que describe  $x$ . La definición formal de ‘tamaño’ se puede encontrar en el trabajo citado, pero en resumen: cada una de las producciones atómicas agrega un costo fijo de 2 unidades; utilizando cualquiera de las producciones de repetición para iterar  $n$  veces una lista de otras producciones agrega el costo de esta lista más  $\lfloor \log(n) \rfloor$ ; y unir dos listas con una concatenación cuesta lo mismo que la suma de los costos de ambas listas.

**La probabilidad relativa  $\mathcal{G}eo$ :** Por otro lado, con el modelo Bayesiano especificado en este trabajo, podemos definir  $P(x | \mathcal{G}eo, \theta)$  que es la probabilidad de una cadena  $x$  relativa a  $\mathcal{G}eo$  y el vector de probabilidades para cada una de las producciones.

En aras de la simplicidad, usaremos  $P_{\mathcal{G}eo}(x)$  para denotar  $P(x | \mathcal{G}eo, \theta)$  cuando  $\theta$  es la probabilidad inferida de las secuencias de adultos observadas en el experimento.

$$P_{\mathcal{G}eo}(x) = P(x | \mathcal{G}eo, \theta) \quad (6.8)$$

$$= \sum_{\text{prog}} P(x | \text{prog}, \theta) \quad (6.9)$$

$$\propto \sum_{\text{prog}} P(x | \text{prog}) P(\text{prog} | \theta). \quad (6.10)$$

Aquí, calculamos tanto  $P_{\mathcal{G}eo}(x)$  como  $K_{\mathcal{G}eo(x)}$  de una manera exacta (tenga en cuenta que  $\mathcal{G}eo$ , visto como un lenguaje de programación, no es Turing-completo). En esta sección, mostramos un experimento de equivalencia entre tales medidas que es consistente con el Teorema de Codificación. Queremos enfatizar, una vez más, que el teorema no predice que esta relación deba mantenerse para una máquina de Turing específica no universal.

Para calcular  $P_{\mathcal{G}eo}(x)$  no nos interesa el factor de normalización de  $P(x | \text{prog})P(\text{prog} | \theta)$

$\theta$ ) porque sólo estamos tratando de medir la relación entre  $P_{Geo}$  y  $K_{Geo}$  en términos del Teorema de Codificación. Sin embargo, tenga en cuenta que el cálculo de  $P_{Geo}(x)$  implica calcular todos los programas que computan cada una de las secuencias como en nuestro experimento anterior. Para hacer esto tratable, calculamos  $P_{Geo}(x)$  para 10,000 secuencias aleatorias únicas para cada una de las posibles longitudes de las secuencias del experimento (es decir, hasta ocho). Cuando la longitud de la secuencia no permitió 10,000 combinaciones únicas, utilizamos todas las posibles secuencias de esa longitud.

#### 6.4.3. Resultados del Teorema de Codificación

La Fig 6.6 muestra la probabilidad media  $P_{Geo}(x)$  para todas las secuencias  $x$  con el mismo valor de  $K_{Geo(x)}$  y una longitud entre 4 y 8 ( $|x| \in [4, 8]$ ) para todas las secuencias generadas  $x$ . Los datos se trazan con una escala logarítmica para el eje x, ilustrando la relación logarítmica inversa entre  $K_{Geo}(x)$  y  $P_{Geo}(x)$ . El ajuste es muy bueno, con  $R^2 = ,99$ ,  $R^2 = ,94$ ,  $R^2 = ,97$ ,  $R^2 = ,99$  y  $R^2 = ,98$  para Fig 6.6A, Fig 6.6B, Fig 6.6C, Fig 6.6D y Fig 6.6E, respectivamente.

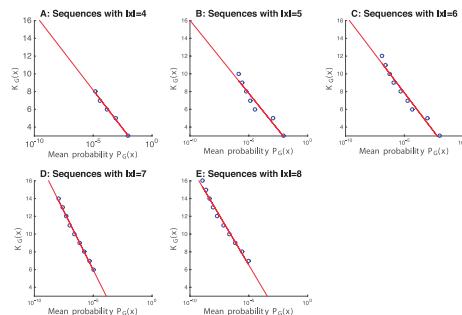


Figura 6.6: **Probabilidad media  $P_{Geo}(x)$ .** Probabilidad media  $P_{Geo}(x)$  para todas las secuencias  $x$  con la misma complejidad. Subfigura A: Secuencias con  $|x| = 4$ . Subfigura B: Secuencias con  $|x| = 5$ . Subfigura C: Secuencias con  $|x| = 6$ . Subfigura D: Secuencias con  $|x| = 7$ . Subfigura E: Secuencias con  $|x| = 8$ .

Esta relación entre la complejidad  $K_{Geo}$  y la probabilidad  $P_{Geo}$  definidas para secuencias finitas en el *lenguaje de geometría*, coincide con la predicción teórica para secuencias infinitas en lenguajes universales descrita en el Teorema de Codificación. Al mismo tiempo, captura la intuición de la navaja de Ockham por la cual las secuencias más simples que uno puede producir o explicar en este idioma son también las más probables.

En Fig 6.7 y Fig 6.8 se muestra el histograma de  $P_{Geo}(x)$  y  $K_{Geo}(x)$ , respectivamente, para secuencias de longitud = 8 para obtener una mejor idea de ambas distribuciones. El histograma del resto de las longitudes de la secuencia se incluyen en **Histogramas de complejidad  $K_{Geo}(x)$ . Histogramas de complejidad para secuencias con longitud entre 4 y 8.** y **Histogramas de probabilidad  $P_{Geo}(x)$ . Histogramas de probabilidad para secuencias con longitud entre 4 y 8.** por completitud, y todos muestran el mismo comportamiento.

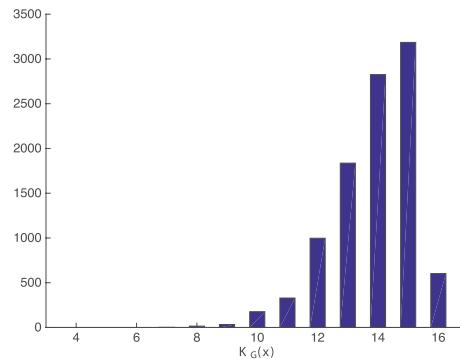


Figura 6.7: **Histograma de complejidad de  $K_{Geo}(x)$ .** Histograma de complejidad para secuencias  $x$  con  $|x| = 8$ .

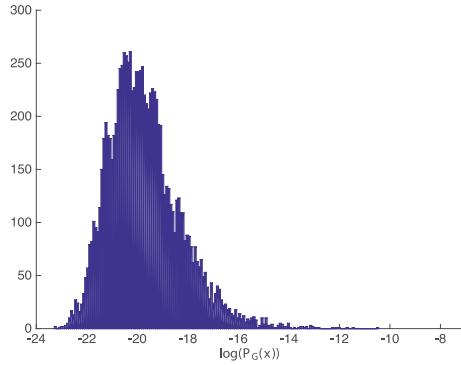


Figura 6.8: **Histograma de probabilidad  $P_{Geo}(x)$ .** Histograma de probabilidad para secuencias  $x$  con  $|x| = 8$ .

## 6.5. Discusión

Hemos presentado un método de inferencia Bayesiano para seleccionar el conjunto de producciones para un LoT y probado su eficacia en el dominio de una tarea de cognición geométrica. Mostramos que este método es útil para distinguir entre producciones ad-hoc arbitrarias y producciones que fueron seleccionadas intuitivamente para imitar las habilidades humanas en ese dominio.

La propuesta de utilizar modelos Bayesianos vinculados a gramáticas PCFG en un LoT no es nueva. Sin embargo, trabajos anteriores no han utilizado las probabilidades inferidas para obtener más información sobre la definición de la gramática y modificarla. En cambio, han integrado usualmente las probabilidades de producción para predecir mejor los datos e incluso se mostró que el uso de distribuciones a priori jerárquicas para las producciones gramaticales no muestran diferencias significativas en los resultados de predicción que al utilizar distribuciones a priori uniformes [Piantadosi et al., 2012, Yildirim and Jacobs, 2015].

Creemos que inferir probabilidades de producción puede ayudar a demostrar lo ade-

cuado de una gramática para un dominio, y puede conducir a un mecanismo formal para seleccionar el conjunto correcto de producciones cuando no está claro cuál debería ser el conjunto correcto. Los investigadores podrían utilizar un conjunto de producciones más amplios que aquellas que parezcan intuitivas o relevantes para el dominio y dejar que la inferencia Bayesiana seleccione el mejor subconjunto.

La selección de un conjunto más amplio de producciones todavía deja algunas decisiones arbitrarias por tomar. Sin embargo, puede ayudar a construir una metodología más sólida que –combinada con otras ideas como probar gramáticas con diferentes producciones para la misma tarea [Piantadosi et al., 2016]– podría proporcionar más evidencia de la idoneidad del LoT propuesto.

Tener un método basado en principios para definir gramáticas en LoTs es un aspecto crucial para su éxito porque gramáticas ligeramente diferentes pueden conducir a resultados muy diversos como se ha demostrado en [Piantadosi et al., 2016].

Los datos experimentales utilizados en este trabajo fueron diseñados en [Amalric et al., 2017a] para comprender cómo los humanos codifican secuencias visuales como expresiones estructuradas. Como investigaciones futuras, debería realizarse experimentos específicos para probar estas ideas en un rango de dominios más amplios. Además, se necesitan aún más experimentos para probar la efectividad del método para ver si permite individualizar las diferencias de las producciones de los LoTs para distintas poblaciones como se describió en Fig 6.5.

Finalmente, mostramos una equivalencia empírica entre la complejidad de una secuencia en un modelo de longitud de descripción mínima (MDL) y la probabilidad de la misma secuencia en un modelo de inferencia Bayesiano, lo cual es consistente con la relación

teórica descrita en el Teorema de Codificación. Esto abre una oportunidad para cerrar la brecha entre estos dos enfoques que han sido descritos como complementarios por algunos autores [MacKay, 2003].

## 6.6. Información de soporte

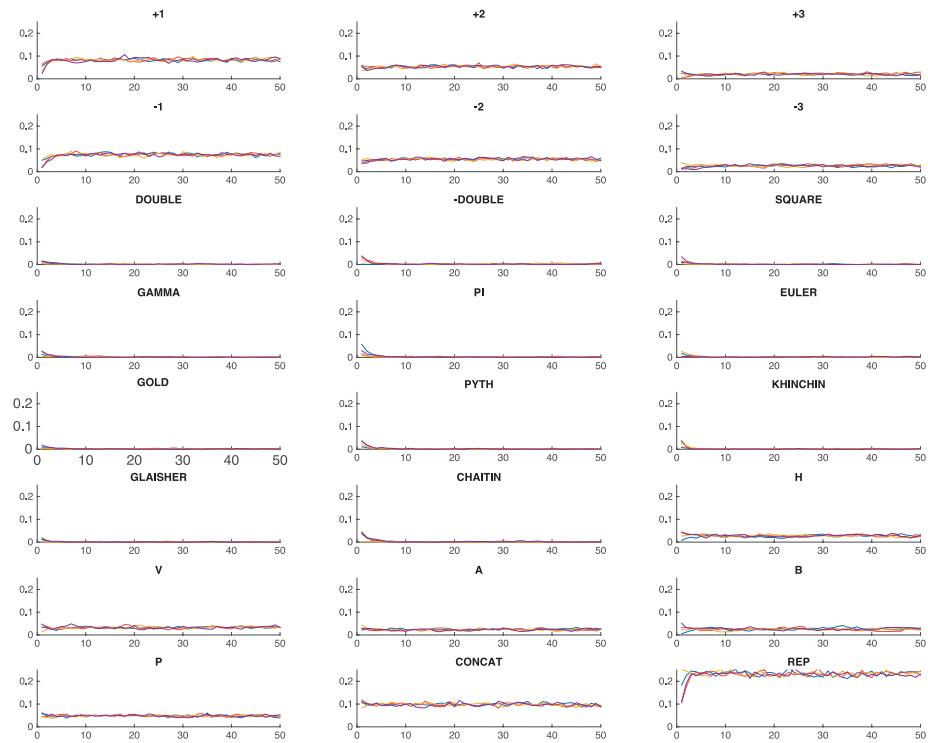
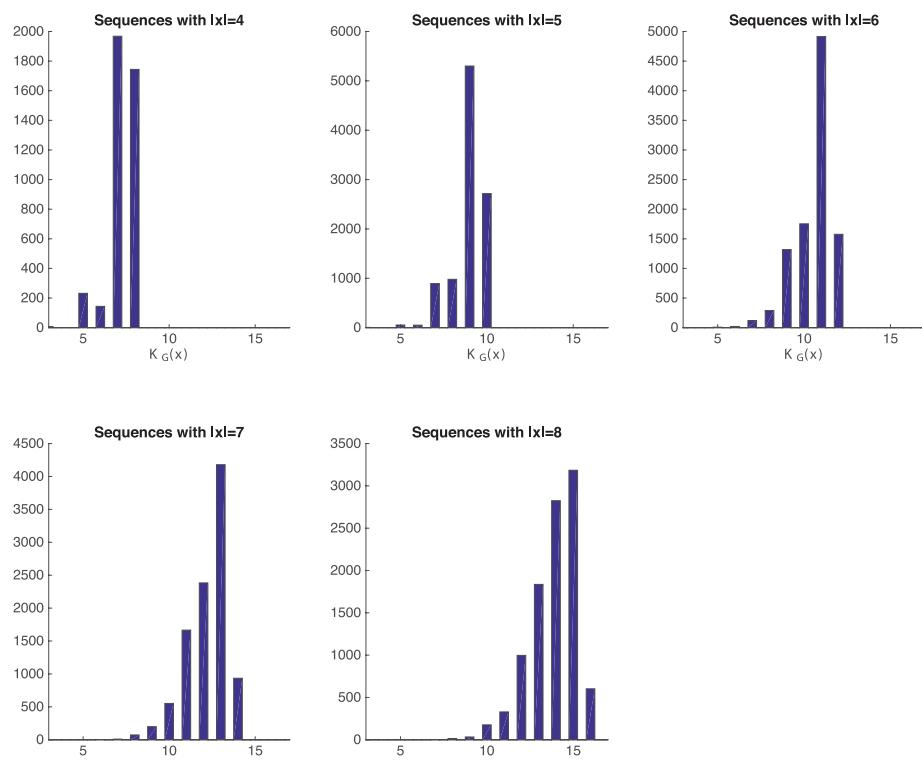
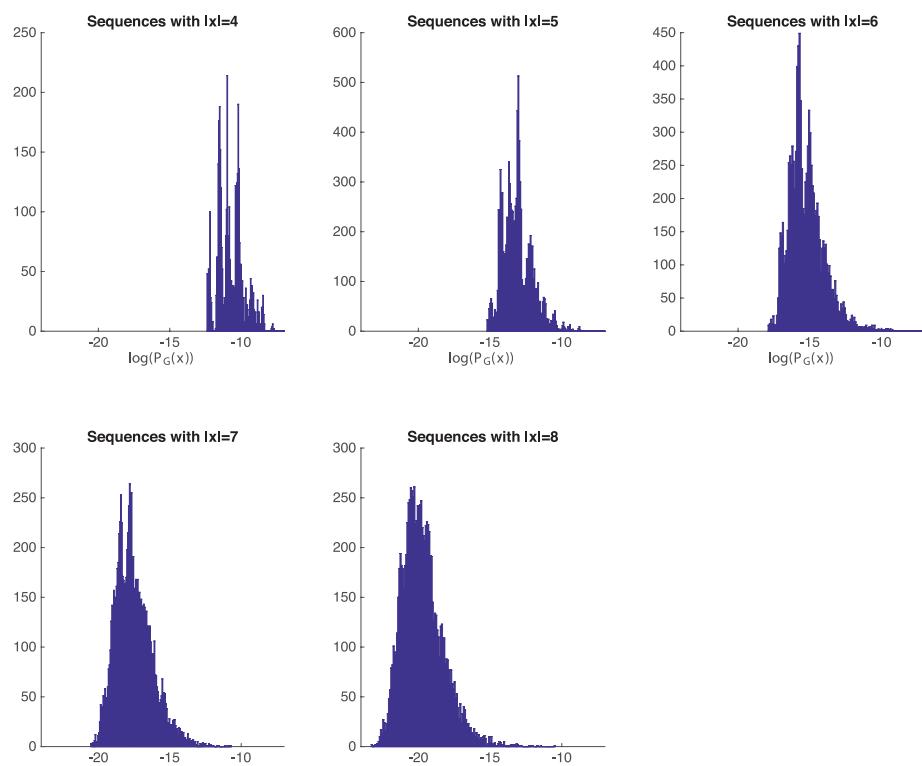


Figura 6.9: Pasos de MCMC para las producciones de  $\mathcal{G}_o$  Pasos de MCMC para el resto de las producciones de la gramática  $\mathcal{G}_o$



**Figura 6.10: Histogramas de complejidad  $K_{Geo}(x)$ . Histogramas de complejidad para secuencias con longitud entre 4 y 8.**



**Figura 6.11: Histogramas de probabilidad  $P_{Geo}(x)$ . Histogramas de probabilidad para secuencias con longitud entre 4 y 8.**

# **Capítulo 7**

**BORRAR: Towards a more flexible  
Language of Thought: Bayesian  
grammar updates after each concept  
exposure**

## **7.1. Introduction**

How can children acquire a vast universe of concepts with seemingly very little exposure? One possible solution to this conundrum, known as the Plato Problem [[Chomsky, 1986](#), [Chomsky et al., 2006](#)], builds on the human capacity to describe concepts –and more generally of all elements of thought– through the use of a symbolic and combinatorial mental language [[Newell, 1980](#)], referred as *language of thought* (LoT) [[Fodor, 1975](#)].

Combinatorial languages can describe a vast set of concepts from a small set of primitives. This can be understood in a relatively simple example in the domain of shapes. A combinatorial and symbolic language similar to Logo [Abelson et al., 1974] can combine operations such as “move”, “pen up”, “pen down.” or “rotate” to generate an infinite set of expressions (or programs) which, when evaluated, can convey all sort of shapes.

A language describing concepts (like shapes) also provides a natural notion of their complexity [Kolmogorov, 1968]. A concept is simple, relative to that language, when it can be described by a short program. On the contrary, it is complex when all its descriptions require a long sequence of instructions. For example, in the case of the Logo language, a square can simply be instructed as a loop of four displacements followed by rotations of 90 degrees. In this language, the icon of a face will be implemented by a significant lengthier program and hence will be more complex. However, this concept would be simpler when described in a language in which the icon of a face (or the symbols for nose, mouth, etc.) are available as primitives in the language.

In the domain of Boolean concepts, a wide range of logical varieties of concepts was studied in [Feldman, 2003], revealing a surprisingly simple ‘law’: the subjective difficulty of a Boolean concept for a human learner is directly proportional to the length of the shortest compatible program in the language of propositional logic (i.e. Boolean variables combined with the operators *and*, *or* and *not*). This result may suggest that human LoT is equipped with rules and symbols similar to those found in propositional logic. Indeed, the correlation between the subjective difficulty of concepts and their complexity has been used as a general vehicle to study human LoT in various domains [Piantadosi et al., 2016, Leeuwenberg, 1971, Amalric et al., 2017b, Romano et al., 2018, Lupyan et al., 2007]. Although often implicit, the general strategy is to (1) assume a language; (2) find the

shortest compatible program for some concepts in that language; (3) compare the length of these programs with the subjective difficulty of the concepts; and finally (4) repeat this process for various languages within a universe of possible candidates and choose the language that gives the best match in (3). As mentioned before, the length of the program depends on the primitives of the language in which this program is written, so different languages make different predictions.

A natural question, however, is whether the primitives of a LoT are universal –both across different individuals and also throughout development– or if instead the semantic repertoire of a language is dynamic and shaped by experience. Indeed, it is likely that our ability to automatically represent Boolean concepts in a succinct manner is not due to an innate efficient propositional language in our mind. Instead, we propose that this ability arises as a byproduct of our brain rapidly learning efficient representations for the concepts we usually encounter in everyday life. Our research question is: how rapidly can we adapt our learning mechanisms when we encounter a new domain in which our a priori representations are no longer efficient? We examine the hypothesis that humans have the ability to rapidly recombine propositions in their LoT, adding new primitives to their language. In other words, that learning leads to a process of compiling routines into functions within the LoT.

In the example of the Logo language one can imagine that if productions which draw squares are very frequent, it would be efficient to devote a new symbol to this production. The new symbol ‘square’ is a hierarchical ‘second order’ construction of the ‘first order’ primitives of the language. It has a cost (of increasing the lexicon of the language) but in the new language, drawing a square can be instantiated with a very short program (namely, ‘square’) and hence uses less memory. Indeed, a higher level language allows us to reach a

higher level of abstraction by freeing memory and processing power, thus making more complex thoughts thinkable [Minsky, 1967, Murphy, 1988].

Most work in the LoT literature, while naturally including a learning mechanism, tends to approach the LoT as a stable system to be unearthed by experimenters, who try different candidate templates and select the one which best fits the data after training [Goodman et al., 2008, Kemp, 2012, Piantadosi et al., 2016]. Still, how different tracks of experience can shape acquisition differently and can constantly change the repertoire of a LoT after each exposure remains to be discovered.

Here, we perform a Boolean concept learning experiment to show that humans can change very rapidly –in the course of an experiment– the repertoire of symbols they use to identify concepts. We also provide a dynamic model that is flexible enough to update its underlying language after each concept exposure.

In our experiment, participants are divided in two groups, in such a way that each group is presented with a different sequence of concepts. One of the two groups is presented with concepts that are succinctly described only if the logical operator ‘exclusive or’ (xor, notated  $\oplus$ ) is used, which we presume does not form part of the natural repertoire of LoT in this specific domain [Piantadosi et al., 2016]. However, these concepts can also be described with a sensibly lengthy combination of primitives excluding  $\oplus$ . We show how the exposure to this set of concepts ‘compiles’ the  $\oplus$  operator in a way that, after exposure, subjective difficulty is described by an extended language in which  $\oplus$  has been incorporated to the set of primitives. Furthermore, we show that the subjective difficulty of concepts throughout the task is consistent with that of a Bayesian agent that rationally updates the probability of compiling  $\oplus$  according to how useful it has been to compress concepts so far.

## 7.2. The logical setting

We consider two propositional logics, both containing only four propositional variables  $\text{Vars} = \{x_1, x_2, x_3, x_4\}$ .  $P$  is defined over the signature  $\wedge, \vee$  and  $\neg$ , and  $P^\oplus$  is defined over the signature  $\wedge, \vee, \neg$  and  $\oplus$ . As one can see from the grammars defined in Fig. 7.1, the only difference between  $P$  and  $P^\oplus$  is that the latter has an additional operator  $\oplus$ .

$$\begin{array}{ll} \text{START} \rightarrow \text{BOOL} & \text{For } i = 1, 2, 3, 4 \\ \text{BOOL} \rightarrow (\text{BOOL} \wedge \text{BOOL})_{\text{ATOM}} & \rightarrow x_i \\ \text{BOOL} \rightarrow (\text{BOOL} \vee \text{BOOL})_{\text{ATOM}} & \rightarrow \neg x_i \\ \text{BOOL} \rightarrow \text{ATOM} & \end{array}$$

Figura 7.1: The context free grammar for language  $P$ . Language  $P^\oplus$  has an extra rule:  $\text{BOOL} \rightarrow (\text{BOOL} \oplus \text{BOOL})$

The semantics of  $\wedge, \vee$  and  $\neg$  are standard: conjunction, disjunction and negation, respectively. We let  $\oplus$  denote the exclusive disjunction. As usual,  $v \models \varphi$ , represents that the formula  $\varphi$  is true for the valuation  $v : \text{Vars} \rightarrow \{0, 1\}$  and we denote the *semantics* of  $\varphi$  by  $[\![\varphi]\!] = \{v : v \models \varphi\}$ . A *concept* **Con** is a set of valuations  $\text{Vars} \rightarrow \{0, 1\}$ . The complement of **Con** is denoted  $\overline{\text{Con}}$  and is defined as  $\overline{\text{Con}} = \{0, 1\}^{\text{Vars}} \setminus \text{Con}$ . Observe that  $\#\text{Con} + \#\overline{\text{Con}} = 16$ . We say that a formula  $\varphi$  is *compatible* with concept **Con** if  $[\![\varphi]\!] = \text{Con}$ . We regard logics as languages for describing concepts. Any concept **Con** has infinitely many descriptions, namely, all formulas  $\varphi$  such that  $[\![\varphi]\!] = \text{Con}$ .

**Santi:** toda esta parte de semantica y MDL puede ir en intro. Es comun con el trabajo de BRM. Acá está con más detalle que en BRM

**Example.** In Fig. 7.2 we depict a concept **Con** (variables are represented by colors) such that  $\#\text{Con} = 4$ . One can see that the formula  $x_3$  is not compatible with **Con** but  $x_1 \wedge x_2$ , or  $x_1 \wedge x_2 \wedge (x_3 \vee \neg x_3)$ , are compatible with **Con**.  $\overline{\text{Con}}$  may be described by  $\neg x_1 \vee \neg x_2$ .

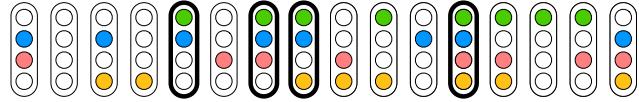
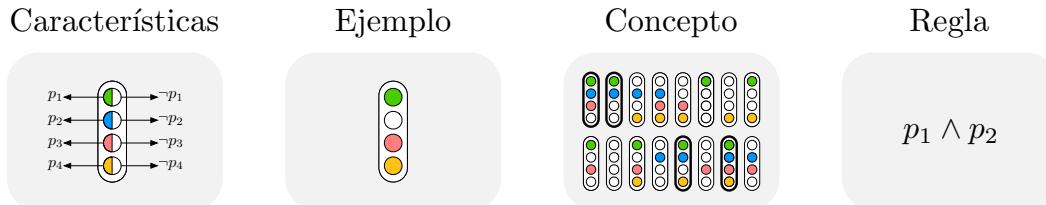


Figura 7.2: Example of a concept **Con**, as shown in the experiment. Variables in  $\text{Vars} = \{x_1, x_2, x_3, x_4\}$  correspond to the presence of a color light in the object ( $x_1 = \text{green}$ ,  $x_2 = \text{blue}$ ,  $x_3 = \text{red}$ ,  $x_4 = \text{orange}$ ). Items (valuations) belonging to **Con** are highlighted with bold border. **Con** may be described by  $x_1 \wedge x_2$ . As in a traffic light, each color is fixed to each position.

We will often identify concepts with any formula compatible with it, so we will talk of “concept  $\varphi$ ” to refer to “concept  $[\![\varphi]\!]$ ”. However, it should be noted that a concept is a semantic object that has many descriptions in the logical language.



**Santi:** Sergio, esta imagen es nueva. Pienso que puede dar coherencia con BRM. Hay que actualizar notacion en el texto.

A lower bound for the complexity of a concept in a given logic corresponds to the shortest description of that concept, that is, its minimum description length (MDL).

The *size* of a formula  $\varphi$  is denoted  $|\varphi|$  and it is defined as the number of operators plus the number of atoms (i.e. possibly negated propositional symbols), that is:  $|x_i| = |\neg x_i| = 1$  for  $i = 1 \dots 4$  and  $|\varphi_1 * \varphi_2| = |\varphi_1| + |\varphi_2| + 1$  for  $* \in \{\wedge, \vee, \oplus\}$ . For  $L \in \{P, P^\oplus\}$  and a concept **Con** we define the *minimum description length of Con with respect to L* as

$$MDL_L(\mathbf{Con}) = \min\{|\varphi| : \varphi \in \mathcal{L}, [\![\varphi]\!] = \mathbf{Con}\}.$$

Since  $P$  is a sublanguage of  $P^\oplus$ , we have  $MDL_{P^\oplus}(\mathbf{Con}) \leq MDL_P(\mathbf{Con})$  for any concept **Con**.

**Example.** The concept  $\mathbf{Con} = \{v: v(x_1) + v(x_2) = 1\}$ , which expresses that  $x_1$  is true or  $x_2$  is true but not both can be described in  $P^\oplus$  as  $\varphi = x_1 \oplus x_2$ , of length 3. In fact, one can check that this is the shortest formula compatible with  $\mathbf{Con}$ , and so  $MDLP^\oplus(\mathbf{Con}) = 3$ . If we now switch to  $P$ , we can no longer describe  $\mathbf{Con}$  as  $x_1 \oplus x_2$ , since  $\oplus$  is not part of its signature. However, in  $P$ , the concept  $\mathbf{Con}$  may be described by formula  $\psi = (x_1 \wedge \neg x_2) \vee (x_2 \wedge \neg x_1)$ , of size 7. Since this formula has minimal size, we have that  $MDLP(\mathbf{Con}) = 7$ .

### 7.3. Experiment

	Target group	$MDLP^\oplus(\mathbf{Con})$	$MDLP(\mathbf{Con})$	Control group	$MDLP^\oplus(\mathbf{Con})$
Training	$\mathbf{Con}^1 x_i$	1	1		← Idem
	$\mathbf{Con}_t^2 x_i \oplus x_j$	3	7	$\mathbf{Con}_c^2 x_i \vee x_j$	3
	$\mathbf{Con}_t^3 x_i \oplus x_j \oplus x_k$	5	19	$\mathbf{Con}_c^3 x_i \vee (x_j \wedge x_k)$	5
	$\mathbf{Con}_t^4 x_k \oplus x_l$	3	7	$\mathbf{Con}_c^4 x_k \vee x_l$	3
Test	$\mathbf{Con}^5 x_i \wedge (x_j \oplus x_k)$	5	9		← Idem
	$\mathbf{Con}^6 x_i \wedge (x_j \vee x_k)$	5	5		← Idem

Cuadro 7.1: Sequence of concepts presented in the experiment:  $\mathbf{Con}^1, \mathbf{Con}_t^2, \mathbf{Con}_t^3, \mathbf{Con}_t^4, \mathbf{Con}^5, \mathbf{Con}^6$  for target group and  $\mathbf{Con}^1, \mathbf{Con}_c^2, \mathbf{Con}_c^3, \mathbf{Con}_c^4, \mathbf{Con}^5, \mathbf{Con}^6$  for control group. Each concept  $\mathbf{Con}$  is represented by a minimal formula  $\varphi$  such that  $\llbracket \varphi \rrbracket = \mathbf{Con}$ .

**Santi:** Llamemos  $C^1, C^2$  a los conceptos, en analogía con BRM (o bien cambiemos BRM)

55 participants participated in the experiment over the world wide web using the Amazon Mechanical Turk crowd sourcing platform. All were US residents over the age of 18 and had more than 95 % of past tasks successfully approved by other requesters. 44 participants completed the experiment through all the stages and declared not cheating (using pen, screenshots or a similar method to copy the answers) at the end of the experiment.

Only data from these participants were used in the analyses reported below.<sup>1</sup>

Participants were divided randomly into a control group ( $N = 21$ ) and a target group ( $N = 23$ ). Both groups were presented with different sequences of six concepts. For each concept, there was a learning phase, a testing phase and a feedback phase. The average time spent in each concept was  $167 \pm 20$  s.e.m. seconds, and the average duration of the task was  $21 \pm 4$  s.e.m. minutes. After moving through the learning, testing and feedback phase of each of the six concepts, participants were asked if they used a pen or recorded the screen information in any way. They were also told that the answer to this question will not affect their payment, but that it was crucial for the experimenters to know.

During the learning phase, all 16 items were presented in the screen (in random order), and items belonging to the concept were identified with bold boundaries, as shown in Fig. 7.2. Participants were told that only the items with bold boundaries were ‘blickets’ (or ‘tufas’, etc.: we used different words for each concept in the sequence), and asked them to try to identify what a blicket was. During the testing phase, the 16 items were shuffled in the screen, and participants were asked to click on items that were blickets. If they made mistakes after submitting their answer, they were directed to the feedback phase, in which items that were incorrectly classified were indicated with a red cross. After having studied the feedback, participants were redirected to the testing screen, where items were reshuffled. When every item was correctly classified, participants were asked to give a verbal description of the concept and then continued on to the following concept after a resting period. We characterize the subjective difficulty of each concept as the time the participant spent in learning, testing and feedback phases for that concept (excluding the time spent in the verbal description).

---

<sup>1</sup>The learning times of all participants can be found in <https://figshare.com/s/04d338adbbe4b1e83bf0>.

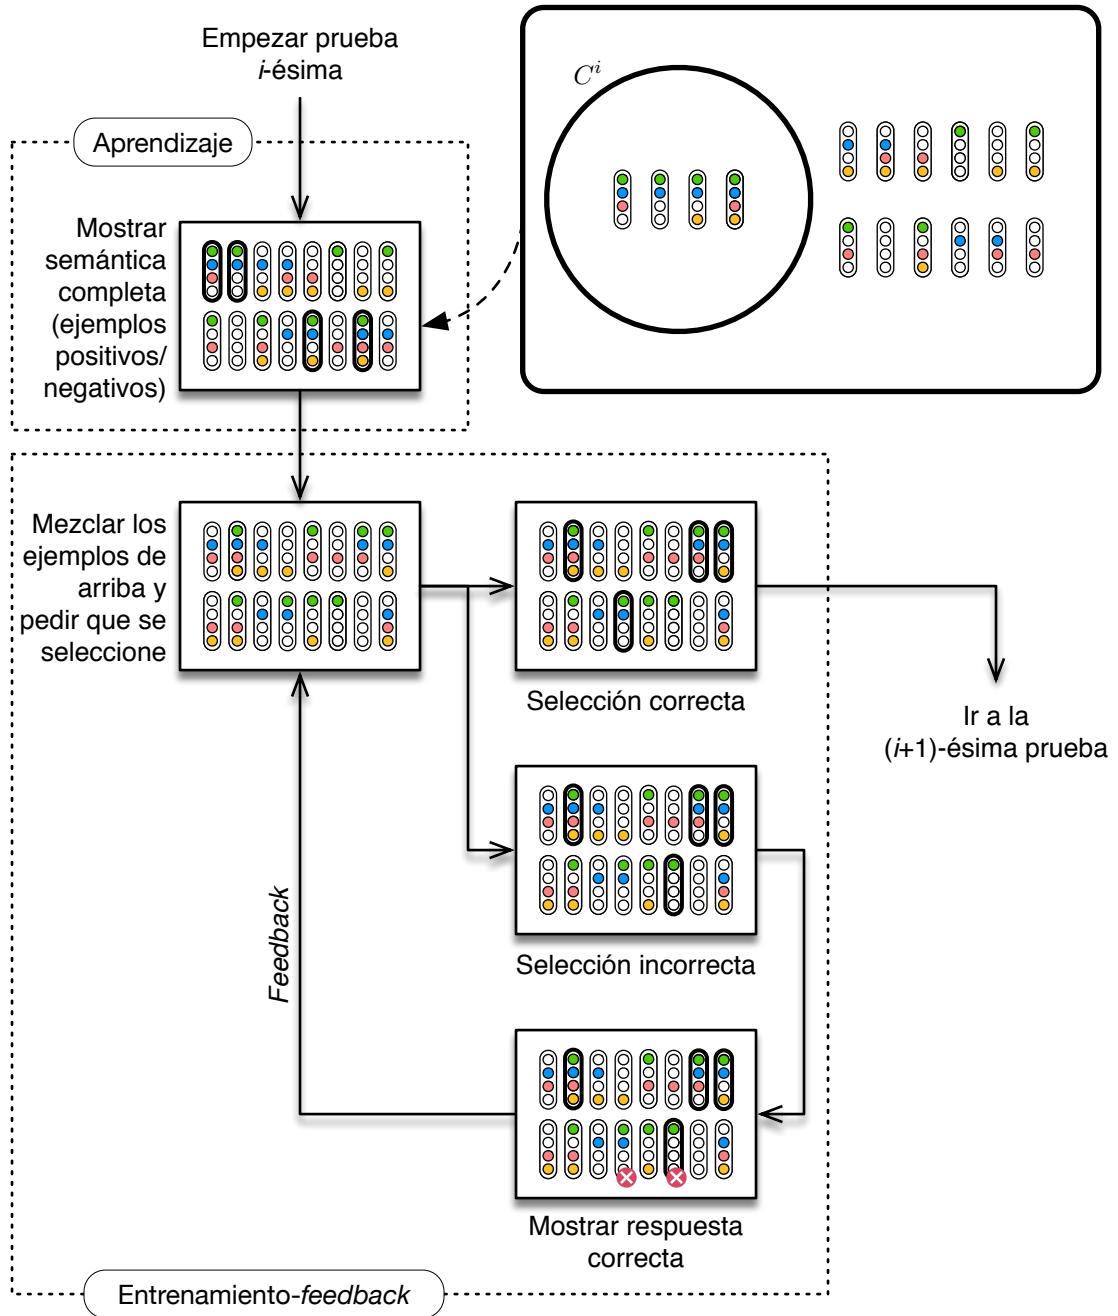


Figura 7.3

**Santi:** Sergio, esta figura es nueva. Es una adaptación de la de BRM, más simple y con los ejemplos de semáforos. Pienso que puede dar más coherencia a la tesis. Podés referenciarla desde el capítulo de BRM y decir que en BRM es más complejo: (a) mostramos semántica INCOMPLETA (b) hay 2 conceptos en vez de 1 y (c) hay una etapa de GENERALIZACION

Both groups (target and control), were exposed to 6 concepts. The second, third and fourth concepts are *training* concepts, and were different between both groups. The last two concepts are the *test* concepts, and were the same for both groups. The first concept was the trivial concept  $x_i$  for both groups, which was aimed to get participants started in the task. Importantly, variables (i.e. color lights inside objects in Fig. 7.2) were randomized for every concept, so paying selective attention to a specific variable across subsequent concepts was not beneficial for learning the concept sequence.

As shown in Table 7.1, we presented the target group with training concepts which are succinctly described when  $\oplus$  is part of the language, but necessarily described with lengthier formulas if  $\oplus$  is absent; more technically, concepts for which  $MDLP^\oplus$  is much smaller than  $MDLP$ . We also corroborated that for  $\mathbf{Con}_t^2$ ,  $\mathbf{Con}_t^3$ ,  $\mathbf{Con}_t^4$  and  $\mathbf{Con}_t^5$  the number of formulas in  $P^\oplus$  with length strictly smaller than  $MDLP$  was at least 10 times greater than the number of formulas in  $P$  with length equal to  $MDLP$ .

Participants in the control group, on the other hand, experienced a sequence of concepts that could be easily described using the language given by  $P$ . After these training concepts, both groups were presented with the same pair of test concepts: one which could be only succinctly described in  $P^\oplus$ , and one for which the MDL did not depend on the underlying language  $P^\oplus$  or  $P$ . We compared learning times between the two groups for these last two concepts.

As shown in Table 7.1, training concepts for the target (xor) group were:  $x_i$ ,  $x_i \oplus x_j$ ,  $x_i \oplus x_j \oplus x_k$ , and  $x_k \oplus x_l$ , called  $\mathbf{Con}_t^1$ ,  $\mathbf{Con}_t^2$ ,  $\mathbf{Con}_t^3$  and  $\mathbf{Con}_t^4$  respectively. Training

concepts for the control group were:  $x_i$ ,  $x_i \vee x_j$ ,  $x_i \vee (x_j \wedge x_k)$ , and  $x_k \vee x_l$  called **Con**<sup>1</sup>, **Con**<sup>2</sup>, **Con**<sup>3</sup> and **Con**<sup>4</sup> respectively. We use the indexes  $i, j, k, l$  instead of numbers because variables were randomized in each trial.  $x_i$  could stand for  $x_1, x_2, x_3$  or  $x_4$ , that is, for any of the four colors. After these four concepts, both groups were presented with the same test concepts:  $x_i \wedge (x_j \oplus x_k)$ , and  $x_i \wedge (x_j \vee x_k)$ , called **Con**<sup>5</sup> and **Con**<sup>6</sup> respectively.

Choosing which concepts to show the target group in order for them to ‘learn’ the  $\oplus$  operator is critical in our experiment. Crucially, the learner must have an option between two alternatives that describe the concept: one that is succinct but uses  $\oplus$ , or necessarily a much longer one in the absence of  $\oplus$ . In other words, these concepts must be compatible with short logical formulas if and only if we take  $P^\oplus$  as the language of description. To ensure that this was the case, we enumerated, for each concept, all formulas compatible with it and produced by the  $P$  and  $P^\oplus$  grammars up to length 19. For all training concepts of the target group, the shortest compatible formula without  $\oplus$  is much longer than the shortest compatible formula with  $\oplus$ . This is shown in Table 7.1.

## 7.4. Model-Free Results

We measure the subjective difficulty of a given concept as the total time needed by the participant to successfully encode the concept, which indicates that they can reliably express which exemplars belong to the concept and which do not.

Participants from the target group spent almost half the time than participants from the control group in **Con**<sup>5</sup>, which could be succinctly described only in  $P^\oplus$  ( $111 \pm 16$  s.e.m. seconds versus  $214 \pm 37$  s.e.m. seconds, a two-sample t-test reveals  $t_{42} = 2,6, P < 0,01$ ), as shown in Fig. 7.4 (a). We also found that the control group learned much faster **Con**<sup>6</sup>

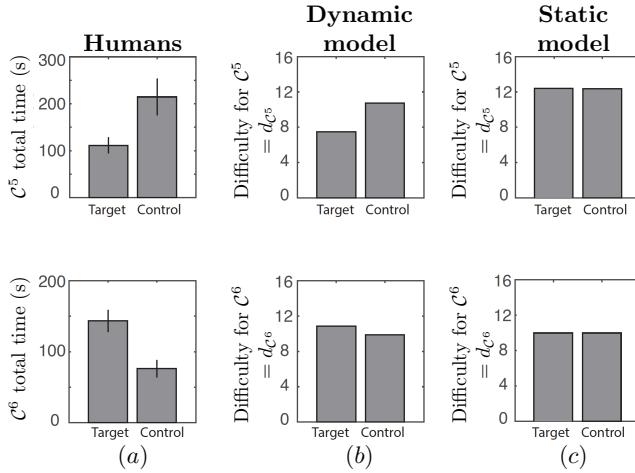


Figura 7.4: Concept learning time (a) and difficulty predicted (b), (c) for the two test concepts (**Con**<sup>5</sup> and **Con**<sup>6</sup>). Error bars are s.e.m. across subjects.

( $143 \pm 14$  s.e.m. seconds for the target group versus  $76 \pm 10$  s.e.m. seconds for the control group,  $t_{42} = 3,5$ ,  $P < 0,01$ ). A mixed ANOVA with **Con**<sup>5</sup>-**Con**<sup>6</sup> as within subject factor and target-control groups as between subject factor reveals a strong interaction between group and **Con**<sup>5</sup>-**Con**<sup>6</sup> ( $F = 15,3$ ,  $P < 0,001$ ), indicating that the differences in learning times for **Con**<sup>5</sup> and **Con**<sup>6</sup> were very different between the two groups.

The target group encoded **Con**<sup>5</sup> more efficiently than the control group. We propose that the control group expected to find in **Con**<sup>5</sup> and **Con**<sup>6</sup> structures that could be easily built in P. The target group, on the other hand, became biased towards the  $\oplus$  structure, and they expected to find it in **Con**<sup>5</sup> and **Con**<sup>6</sup>. This caused **Con**<sup>5</sup> to be encoded more rapidly by the target group and **Con**<sup>6</sup> more rapidly by the control group. Assuming that the subjective difficulty of learning a concept is proportional to the complexity of its internal representation, we conclude that after exposure to the training concepts, participants in the target group represented the  $\oplus$  more efficiently than the control group, and expected to find this structure in **Con**<sup>5</sup> and **Con**<sup>6</sup>.

## 7.5. Model

When presented with a concept (e.g. Fig. 7.2), our model generates logical formulas and evaluate them to true or false for that concept, keeping the formula only if it is true. To generate formulas, the model uses a symbolic language in which each rule (symbols and operators) is associated with a probability of being used. The probability of generating a formula is proportional to the product of the probabilities of the rules required for building it, and therefore it decreases exponentially with its length. Furthermore, if one of the rules has a very low probability of being used, formulas that require it will also have very low probability.

The *Static model* maintains the rules' probabilities fixed throughout the concept sequence (the 6 concepts in Table 7.1). The *Dynamic model* updates the probabilities after each concept, in order to minimize the expected description length of future concepts, assuming they have similar structure to the concepts learnt so far. We include in this model the  $\oplus$  rule a priori in the language, but with vanishing probability of being used. Changes in this probability can be analogously interpreted as the probability that a rational agent without the compiled symbol a priori decides to add the compiled expression as a new primitive into her language.

### 7.5.1. Static Model

Under the LoT assumption, given a concept **Con** (e.g. Fig. 7.2), the probability that an agent uses formula  $\varphi$  to explain this concept is defined by Bayes theorem:

$$P(\varphi \mid \mathbf{Con}) \propto P(\mathbf{Con} \mid \varphi)P(\varphi).$$

The likelihood  $P(\mathbf{Con} \mid \varphi)$  of a logical statement  $\varphi$  can be simply defined as 1 if  $\llbracket \varphi \rrbracket = \mathbf{Con}$  and 0 otherwise. In other words, for any given concept, only explanations that describe this concept are considered as possible explanations. The likelihood term has been defined more flexibly in the literature [Goodman et al., 2008, Piantadosi et al., 2016], allowing for mislabeled elements. We keep this simpler definition in order to reduce the number of free parameters of the model, as we do not intend to account for mislabeling errors in our experiment.

The prior  $P(\varphi)$  is defined by augmenting the context-free grammars shown in Fig. 7.1 into a probabilistic context-free grammars (PCFG). In the PCFG, each rule has associated a parameter indicating the probability of using that rule. A PCFG can be used to produce logical statements similar to a CFG. Each non-terminal remaining in the statement is expanded using a rule of the PCFG with probability proportional to that rule's associated parameter, until no non-terminals remain in the statement.

We assume that the probability that a subject uses formula  $\varphi$  to explain concept **Con** is proportional to the posterior  $P(\varphi \mid \mathbf{Con})$ , and the subjective difficulty  $d_{\mathbf{Con}}$  of a concept **Con** to a participant is proportional to the length of the formula that the participant is using to explain that concept. However, there is no way to know directly which internal formula  $\varphi$  the participant is using (and therefore we do not know  $|\varphi|$ ). Hence, the most parsimonious approach is to consider the entire posterior distribution  $\mathbf{P}(\varphi \mid \mathbf{Con})$  over possible formulas.<sup>2</sup>

Given a concept **Con**, the expected length  $E_{\mathbf{Con}}$  of the formulas used by the participant

---

<sup>2</sup>This is equivalent to the Sampling Hypothesis described in [Denison et al., 2013], by which participants represent distributions through samples. Similar results are obtained if each participant carries entire probability distributions.

is simply

$$E_{\mathbf{Con}} = \sum_{[\varphi]=\mathbf{Con}} |\varphi| P(\varphi \mid \mathbf{Con}), \quad (7.1)$$

where the sum is over all formulas  $\varphi$  compatible with **Con**. We define the difficulty  $d_{\mathbf{Con}}$  of a concept experienced by the participant as

$$d_{\mathbf{Con}} \propto E_{\mathbf{Con}} + \alpha N_{\mathbf{Con}},$$

where we added a term that accounts for the cardinality of the concept:  $N_{\mathbf{Con}}$  is the cardinality of the concept or its complement, the one being smaller, i.e.  $N_{\mathbf{Con}} = \min\{\#\mathbf{Con}, \#\overline{\mathbf{Con}}\}$  (e.g.  $N_{\mathbf{Con}} = 4$  for the concept **Con** of Fig. 7.2), and  $\alpha$  is a free parameter fitted globally for all concepts and participants to its maximum likelihood value of 0.9. In this way, we remove the asymmetry between positive and negative examples, while accounting for the toil taken by considering a larger number of items simultaneously.

In practice, to approximate  $E_{\mathbf{Con}}$  for each concept **Con**, we calculated the posterior probability  $P(\varphi \mid \mathbf{Con})$  of all compatible formulas  $\varphi$ s up to size 19 with  $P(\varphi \mid \mathbf{Con})$  and then use (7.1). Since the space of all possible  $\varphi$ s grows exponentially with  $|\varphi|$ , normative procedures for estimating  $P(\varphi \mid \mathbf{Con})$  in this space involve stochastic search algorithms. However, in our case, we were able to exhaustively enumerate and calculate the posterior probability of *all* formulas generated by the PCFG up to a sufficiently high size  $M$  such that all formulas with  $|\varphi| > M$  have vanishing probabilities when compared to shorter compatible formulas for the current concept (because the prior  $P(\varphi)$  decreases exponentially with the size of the formula).

### 7.5.2. Dynamic Model

Up to this point, we assumed that, given a concept **Con**, the posterior distribution over formulas  $P(\varphi \mid \mathbf{Con})$  was independent of the other concepts presented in the sequence. However, if the LoT (i.e. the PCFG) updates with experience, the prior  $P(\varphi)$  in  $P(\varphi \mid \mathbf{Con})$  will change, and so will  $E_{\mathbf{Con}}$  in (7.1) and finally the subjective difficulty  $d_{\mathbf{Con}}$ . Therefore,  $d_{\mathbf{Con}}$  will depend on the sequence of concepts that were previously presented to the participant.

In other words, since now  $P(\varphi)$  depends on the sequence of concepts experienced by the participant, instead of  $P(\varphi \mid \mathbf{Con})$ , we have

$$P(\varphi \mid \mathbf{Con}^t, \dots, \mathbf{Con}^1) \propto P(\mathbf{Con}^t \mid \varphi) P(\varphi \mid \mathbf{Con}^1, \dots, \mathbf{Con}^{t-1})$$

, where  $\mathbf{Con}^t$  is the concept presented at trial  $t$ , and  $P(\varphi \mid \mathbf{Con}^1, \dots, \mathbf{Con}^{t-1})$  depends on the state of the PCFG at trial  $t$ , which in turn depends on how the PCFG gets updated from trial to trial.

Intuitively, the update process increases the probability of using a certain rule in the PCFG accordingly to how useful this rule was to compress compatible formulas for the concepts previously learned in the same domain. Specifically, we model the update process in a normative manner: the probability of using a rule of the PCFG at trial  $t$  is equal to the Bayesian posterior probability that this rule will enable the learner to find compressed explanations at trial  $t$ , according to how useful it was to compress explanations in trials  $1, \dots, t-1$ .

To formalize the update of the PCFG, we define  $P(\varphi)$  similarly to [Goodman et al.,

[2008]. Specifically, the prior probability of a logical statement at trial  $t$  in the concept sequence uses a single Dirichlet-multinomial for the set of rule expansions. The Dirichlet is parameterized by a set of positive real numbers  $D_i^t$ , one for each rule  $i$  in the PCFG, which in turn determine the probability of using rule  $i$  at trial  $t$ : a higher  $D_i$  indicates a higher probability of using rule  $i$ .

The prior is specified by the set Dirichlet parameters  $\mathbf{D}^0$  with which we start the experiment ( $\mathbf{D}^0$  represents a vector containing the prior parameters of all rules in the grammar at trial 0). In our experiment, we set the prior Dirichlet parameters of all rules equal to 1, and the parameter of the rule that expands the target operator to a value several orders of magnitude smaller ( $\approx 10^{-4}$ ). This means that the target operator was practically absent at the beginning of the experiment, but it was technically possible to ‘learn it’ by increasing its probability as the experiment developed.

Under the Dirichlet model, the prior  $P(\varphi \mid \mathbf{Con}^1, \dots, \mathbf{Con}^{t-1})$  can be rewritten using the Dirichlet parameters as  $P(\varphi \mid \mathbf{D}^t)$ . Therefore, to know how  $P(\varphi \mid \mathbf{Con})$  updates from trial to trial, we only need to know how  $\mathbf{D}$  updates from trial to trial.

The Dirichlet parameter of rule  $i$  at trial  $t + 1$  is equal to its parameter at trial  $t$  plus the amount of times the production  $i$  was used in generating all formulas compatible with the concept at trial  $t$  (we note  $M_i(\varphi)$  as the number of times that rule  $i$  is used in generating formula  $\varphi$ ), weighted by each formula’s posterior probability at trial  $t$ :

$$D_i^{t+1} = D_i^t + \sum_{\llbracket \varphi \rrbracket = \mathbf{Con}^t} P(\varphi \mid \mathbf{D}^t) M_i(\varphi). \quad (7.2)$$

This Bayesian learning mechanism increases the probability of using rules that allow concepts to be succinctly described. This happens because these formulas have higher

probability  $P(\varphi \mid \mathbf{D})$  than longer formulas, so the Dirichlet parameters of the rules that build these formulas increase more strongly than those of the rules that build longer formulas.

## 7.6. Results

The Bayesian agent that minimizes the expected complexity of future concepts by optimally adapting its LoT to the inferred structure of the task accurately captures the dynamics of human learning across concepts. If we did not allow the model to update the probability of the operators after each concept, and particularly the compiled operator  $\oplus$ , the control group and the target group would be indistinguishable to the model as it would predict equal average formula length for both groups (see Fig. 7.4, *Static Model*). Instead, as shown in Fig. 7.5, by adjusting the prior probabilities based on concept exposure the dynamic model is able to capture learning time patterns in the target groups ( $R^2 = 0,96$  compared to  $R^2 = 0,73$  for the static model). Expectedly, both models perform similarly in the control groups as they were designed to not encourage the use of any particular operator ( $R^2 = 0,72$ ;  $R^2 = 0,71$  for the static model). The impact of the learning capability of the model is most evident in the target group concept sequence, which was designed to this effect. If the structure of the concepts does not bias the LoT primitives one way or the other, it is expected that a static model will provide a reasonable fit. However, it is difficult to tell a priori how unbiased a set of concepts really is, so experiments relying on repeated concept exposure should always take between-concept learning into account.

Allowing the model to constantly update its beliefs from concept to concept is a requisite to capture human learning times. We now explain how the pattern of subjective difficulties in Fig. 7.5 emerged in the *Dynamic model*. In this scenario, learning for the model is

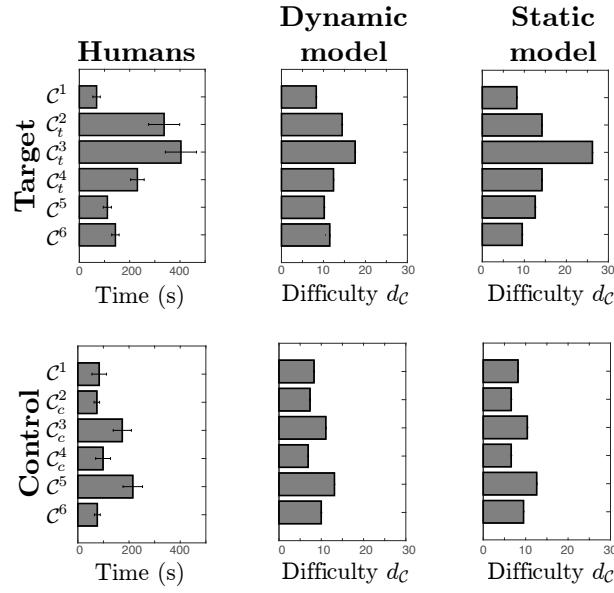


Figura 7.5: Learning times and model predictions for target and control groups (see Table 7.1 for concept details). The predicted difficulties of each model were calculated using  $d_{\text{Con}}$ . Error bars are s.e.m.

formalized by the update of rule parameters from concept  $t$  to concept  $t + 1$  according to (7.2). In Fig. 7.6 we show how this learning takes place in the concept sequence for the target group. There are mainly two competing formulas when  $\mathbf{Con}_t^2$  is presented:  $x_i \oplus x_j$  and  $(x_i \wedge \neg x_j) \vee (\neg x_i \wedge x_j)$ . Given the low a priori value of the parameter of the  $\oplus$  rule, the posterior of the formulas of type  $(x_i \wedge \neg x_j) \vee (\neg x_i \wedge x_j)$ , which do not use the  $\oplus$  operator, is much higher than the posterior of  $x_i \oplus x_j$ . Therefore, in Fig. 7.5 we see a large predicted difficulty by the dynamic model for this concept (since the posterior lies mainly over these longer formulas without  $\oplus$ , see (7.1)).

However, the little increment in the  $\oplus$  rule after  $\mathbf{Con}_t^2$  (see Fig. 7.6) is sufficient for making the formula  $x_k \oplus x_l$  to have higher relative posterior in the next concepts, making

Santi: aca hay alguna diferencia de nomenclatura de conceptos. Prefier llamarlos  $C^1, C^2, \dots$  o lo que sea igual a BRM

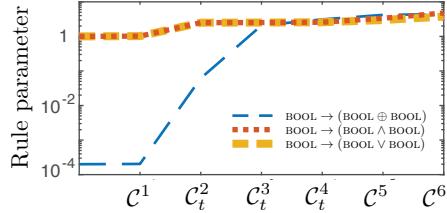


Figura 7.6: Evolution of Dirichlet parameters of different rules after each concept experienced by the target group.

the increment in the parameter of the  $\oplus$  rule much greater than before. Additionally, the difficulty inferred by the model is much smaller the second time the concept is presented (compare  $\mathbf{Con}_t^4$  and  $\mathbf{Con}_t^2$  concepts in Fig. 7.5), since now the posterior is more evenly distributed between long (without  $\oplus$ ) and short (with  $\oplus$ ) formulas (see Eq. (7.1)). Finally, when the concept  $\mathbf{Con}^5$  is presented, the learner has completely compiled the  $\oplus$  rule into her language, ascribing the formulas that use the  $\oplus$  operator a much higher posterior probability relative to the long formulas that do not use the  $\oplus$  operator. Therefore, the inferred difficulty for  $\mathbf{Con}^5$  is much smaller than those describing previous concepts, almost as simple as concept  $\mathbf{Con}^1$  (see Fig. 7.5).

Finally, the strong  $\oplus$  acquired by the target group increases the difficulty of  $\mathbf{Con}^6$  relative to the control group (see Fig. 3). This occurs because there are several formulas of length 9 that use the  $\oplus$  operator (around 6000), significantly increasing the expected difficulty of the concept (see Eq. (7.1)). For the control group, the posterior probability of these formulas is very low, causing a smaller increase in the expected difficulty.

The previous results point to a competition between different rules in the grammar. In our model, competition between  $\oplus$  and the other operators is modulated by the initial relative value of the Dirichlet prior of the  $\oplus$  rule, and the overall magnitude of the priors of all rules. The initial  $\oplus$  prior measures how useful  $\oplus$  should be (relative to the other rules)

in order to increase the likelihood of using it in the future. If the  $\oplus$  prior is too low relative to the priors of other rules, then formulas with  $\oplus$  must be much shorter than formulas without  $\oplus$  in order for them to have appreciable posterior and increase the  $\oplus$  parameter in Eq. (7.2). In our experiment, if the prior is smaller  $10^{-12}$  (and 1 for all other rules), then the predictions of the dynamic and static model for the target group are approximately equal: the advantage of using  $\oplus$  in the target concepts is not enough to increase the likelihood of using  $\oplus$ . On the other hand, if the  $\oplus$  prior is too high, we cannot model the high difficulty of  $\mathbf{Con}_t^2$  for the target group and the high difficulty of  $\mathbf{Con}^5$  for the control group. For example, if the  $\oplus$  prior is higher than 0.05 (and 1 for all other rules), the difficulty of  $\mathbf{Con}_t^2$  and  $\mathbf{Con}_t^4$  are approximately equal (corresponding to the short formula with  $\oplus$ ) and also the difficulties of  $\mathbf{Con}^5$  for control and target groups.

The other free parameter that modulates competition is the overall magnitude of the Dirichlet priors, which determines how many times an efficient rule should be encountered before incorporating it. If the magnitude is too high, then observing a useful rule does not significantly change its Dirichlet parameter relative to the others, eliminating from the model the rapid rule acquisition clearly showed by participants. This happens because in Eq. (7.2) the magnitude of the updates from  $t$  to  $t + 1$  are at most of order  $M$ , the number of times that operators appear in formulas with high posterior. In our experiment, if all rules have prior equal to 1 and  $\oplus$  has 1/1000 we get similar results to the ones in Fig. 7.5, but if all rules have prior equal to 10000 and  $\oplus$  has 10 the additions to the  $\oplus$  parameter are insignificant, so the dynamic and static models make the same predictions for the target group.

In our model a large enough exposure to a concepts will increase the Dirichlet parameters without bounds, progressively decreasing learning flexibility. Although our experiment

is not long enough to test it, such inflexibility is very unlikely to be true. For example, in the LoT fitting experiment from [Piantadosi et al., 2016] they found that human Dirichlet priors for most propositional operators are between 0.3 and 3, instead of orders of magnitude higher (as expected by Eq. (7.2) after exposure to a large number of concepts). Therefore, a more complete model of lifelong language acquisition should include an extra normalization or forgetting parameter that decreases the overall magnitude of the Dirichlet parameters, preserving the high learning flexibility that we observed in our experiment.

## 7.7. Discussion

We measured the subjective difficulty that participants experience when learning a sequence of concepts. To explain this subjective difficulty, we resource to propositional logic as a base description language. In the target group we experimented with concepts which can be succinctly described in the base language *that also contains an extra operator*  $\oplus$  for exclusive disjunction but that needed necessarily longer descriptions over the base language (where this operator is absent). On the contrary, the control group is exposed to concepts where  $\oplus$  does not help to achieve succinctness.

Learning times are consistent with the hypothesis that participants in the target group smoothly adopt the  $\oplus$  as a new primitive of their LoT in order to absorb the concepts they have been exposed to, with no more incentive than decreasing the expected complexity of future concepts. We do not claim that participants have learned the  $\oplus$  operator defined by any specific formula using the previous operators, however, their LoT seems to have constructed an operation that matches the semantics of the exclusive or in order to compress such patterns of data and identify them more efficiently.

Here, we focus on transfer learning effects when learning sequential concepts that share the same hierarchical structure. We acknowledge, however, that several other transfer learning effects are present in human sequential logical concept learning, such as when subsequent concepts differ in the relevant variables (e.g. color lights in our experiment) [Blair et al., 2009], when changing the relevant variables in subsequent exclusive disjunctions [Kruschke, 1996], or when two categories are learned in an interleaved or a focused manner [Carvalho and Goldstone, 2014]. However, unlike superficial knowledge about the task (like the frequency of appearance of different symbols and logical operators in the concept sequence), identifying the latent hierarchical structure of concepts have extremely important computational consequences: it allows for exponentially less complex representations [Bengio et al., 2013, Lake et al., 2015], maximizing the expected value of future computations within resource-bounded constraints [Gershman et al., 2015]. In our task, in order to focus primarily on the learning process of the  $\oplus$  structure, we randomize variables in each trial, such that other kinds of transitions are averaged out across participants.

Most LoT studies provide a language that is fixed once trained or inferred over a specific data. We claim that when a specific language beats a second one at fitting some experimental data, what we may be seeing is an effect of prior experience (including from the experiment itself), more than an intrinsic feature of the LoT. This leads to a fundamental difficulty in trying to experimentally uncover what the actual human symbolic substrate of thought is. Experimental results have shown for instance that a grammar with *and*, *or*, and *not* better explains Boolean concept learning than one with *nand*, despite both being expressively equivalent [Piantadosi et al., 2016]. In our view, this cannot be taken to mean anything more than that in the current state of affairs of the world, the *nand* operator is not very useful for compressing information. We have shown that participants can rapidly

compile new expressions in their LoT if they begin to be useful, which emphasizes that one cannot simply ignore the order in which concepts are presented to the participant when studying aspects of the LoT.

When Fodor proposed the Language of Thought hypothesis [Fodor, 1975], what he had in mind was a symbolic system we all came equipped with from birth. Stating that this language is in fact always flexible might seem in outright contradiction with Fodor's original idea. In fact, what studies in the LoT literature (including this one) are probably probing is one among many languages in a hierarchy of increasing abstraction. As we progress in life, we find some conceptual summaries useful, and compiled them in a more abstract token. It is even likely that there is no proper hierarchy with sharply defined boundaries between levels, but instead a less organized progression of concepts of increasing abstraction, with thought progressing seamlessly using constructs at different levels.

## 7.8. Conclusion

We defined a model to measure the subjective difficulty of learning a sequence of concepts. The model updates the grammar production probabilities between concepts and predicts difficulty as the size of compatible formulas weighted by their posterior probability. This learning mechanism allows to simulate the emergence of a new primitive in the language, as it becomes useful to encode the concepts presented so far. The predicted difficulties strongly resembles the pattern of human learning times in a sequence of concepts that required the  $\oplus$  operator in order to be efficiently represented.

## **Capítulo 8**

**Un marco lógico para estudiar  
aprendizaje de conceptos en presencia  
de explicaciones múltiples**

## **Resumen**

Cuando las personas buscan comprender conceptos a partir de un conjunto incompleto de ejemplos y contraejemplos, suele haber una cantidad exponencial de reglas de clasificación que pueden clasificar correctamente los datos observados, según las características de los ejemplos que se utilicen para construir estas reglas. Una aproximación mecanicista del aprendizaje de conceptos humanos debería ayudar a explicar cómo los humanos prefieren algunas reglas por sobre otras cuando hay muchas que pueden usarse para clasificar correctamente los datos observados. Aquí, explotamos las herramientas de la lógica proposicional para desarrollar un marco experimental que controle las reglas mínimas que son *simultáneamente* consistentes con los ejemplos presentados. Por ejemplo, nuestro marco nos permite presentar a los participantes conceptos consistentes con una disyunción y *también* con una conjunción, dependiendo de qué características se usen para construir la regla. Del mismo modo, nos permite presentar conceptos que son simultáneamente consistentes con dos o más reglas de diferente complejidad y que utilizan diferentes características. Es importante destacar que nuestro marco controla completamente qué reglas mínimas compiten para explicar los ejemplos y es capaz de recuperar las características utilizadas por el participante para construir la regla de clasificación, sin depender de mecanismos complementarios de seguimiento de la atención (por ejemplo, *eye-tracking*). Explotamos nuestro marco en un experimento con una secuencia pruebas competitivas como las mencionadas, e ilustramos la aparición de varios efectos de transferencia que sesgan la atención previa de los participantes a conjuntos específicos de características durante el aprendizaje.

La adquisición de conceptos es un aspecto clave y ampliamente estudiado de la cognición diaria humana [Cohen and Lefebvre, 2005, Ashby and Maddox, 2011]. Muchos investigadores han afirmado que un sistema de codificación y un conjunto de reglas subyacen a algunas de nuestras habilidades para adquirir conceptos [Nosofsky et al., 1994b, Tenenbaum et al., 2011, Maddox and Ashby, 1993], y se ha observado que parece que aprendemos conceptos de objetos con más facilidad cuando hay reglas ‘más simples’ que pueden explicar esas agrupaciones [Shepard et al., 1961, Nosofsky et al., 1994a, Rehder and Hoffman, 2005, Lewandowsky, 2011, Feldman, 2000, Blair and Homa, 2003, Minda and Smith, 2001].

En el mundo real, los humanos aprenden descripciones de conceptos mientras deciden simultáneamente a qué características atender [Schyns et al., 1998]; y el conjunto de características seleccionado generalmente determina la estructura y complejidad de las reglas mínimas que pueden describir el concepto. Por ejemplo, el concepto *perro* se puede explicar como *una mascota de cuatro patas que no es un gato* o como *un animal para caza, pastoreo, tira de trineos o compañía*. Ambas descripciones son totalmente compatibles con el concepto *perro*, pero nuestra experiencia nos induce a elegir diferentes características relevantes para definir el concepto. Mientras que la primera descripción de *perro* podría muy bien haber sido dada por un niño que tiene un perro en casa, la segunda podría haber sido presentada por un pastor o quizás un etólogo. Es probable que las características utilizadas para describir *perro* por cada agente les permitan describir de manera compacta el concepto, al mismo tiempo que lo separan de otros conceptos que se encuentran con frecuencia en su entorno. Aquí, preguntamos qué características usan los participantes para describir conceptos, dependiendo de la estructura lógica de la descripción que usa esas características y también de su exposición a conceptos anteriores. ¿Por qué alguien usaría

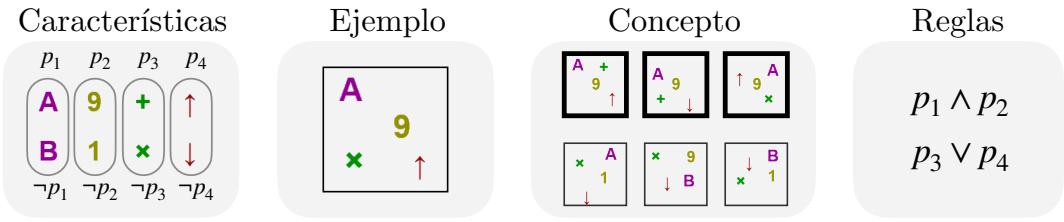


Figura 8.1: Ilustración de las características  $\{p_1, p_2, p_3, p_4\}$ , el ejemplo  $(1, 1, 0, 1)$ , y un concepto (los ejemplos positivos están marcados con marcos gruesos y los ejemplos negativos con marcos delgados). El concepto se puede explicar con las dos reglas mínimas  $p_1 \wedge p_2$  o  $p_3 \vee p_4$ , dependiendo de las características que se usen para construir la regla (las dos primeras características o las dos últimas características, respectivamente).

*gato* o *caza* para definir *perro*?

En los experimentos de aprendizaje de conceptos proposicionales, a los participantes se les presenta un conjunto de *ejemplos*, cada uno conformado por  $N$  *features* proposicionales, que pueden tomar valores positivos o negativos. Por ejemplo, para  $N = 4$  un ejemplo se puede representar lógicamente como el elemento  $(1, 1, 0, 1)$ , que toma valores positivos para la primera, segunda y cuarta características y negativos para la segunda, como ilustramos en la Figura 8.1. Un *concepto* puede entenderse intuitivamente como un conjunto de ejemplos, algunos de ellos marcados como pertenecientes al concepto y el resto marcados como no pertenecientes, es decir, ejemplos positivos y negativos. En la Figura 8.1 mostramos un ejemplo de un concepto *subdeterminado*, en el sentido de que, dado que no se muestra universo completo de ejemplos (es decir, las  $2^4$  posibilidades), diferentes conceptos determinados pueden ser coherentes con este conjunto más pequeño al extender el conjunto de ejemplos al universo completo.

Una *regla* consistente con el concepto es una fórmula lógica construida con las características y los operadores de conjunción ( $\wedge$ ), disyunción ( $\vee$ ) y negación ( $\neg$ ), que se evalúa

como verdadera para objetos que pertenecen al concepto y falsa en caso contrario (por ejemplo,  $p_1 \wedge p_2$ , donde  $p_i$  es la  $i$ -ésima característica, ver Figura 8.1). La *longitud mínima de descripción* (MDL por sus siglas en inglés) de un concepto es la longitud de la regla más corta consistente con el concepto [Grünwald and Grunwald, 2007] (aquí, la *longitud* de una fórmula se define como número de apariciones positivos o negativos de símbolos proposicionales, más el número de apariciones de los operadores  $\wedge$  o  $\vee$  contenidos en él; por ejemplo, la longitud de  $p_1 \wedge \neg p_3$  es 3, y la longitud de  $(p_1 \wedge \neg p_3) \vee p_2$  es 5). Es importante destacar que la mayoría de los estudios sobre la dificultad subjetiva en el aprendizaje de conceptos están diseñados de manera que se pueda usar una *única* regla mínima para describir el concepto (por ejemplo,  $p_1 \wedge p_2$ ) [Ashby and Maddox, 2005, Feldman, 2000], incluso cuando la dificultad de encontrar las características que componen esa regla ( $p_1$  y  $p_2$ ) se mide con mecanismos de seguimiento de atención (por ejemplo, [Blair et al., 2009, Hoffman and Rehder, 2010]). Esta limitación se debe posiblemente a la cantidad prohibitivamente grande de reglas que se pueden construir con un conjunto de características dado, lo que dificulta el control de las reglas que el participante podría usar al observar un conjunto de ejemplos. Por caso, para determinar la dificultad que tienen los participantes en aprender la regla lógica  $p_1 \vee p_2$ , es crucial controlar que ninguna otra regla de complejidad razonable pueda explicar el concepto (por ejemplo,  $p_1 \wedge p_3$ ). En este trabajo, utilizamos las herramientas de la lógica proposicional para construir un marco experimental que nos permita presentar ejemplos consistentes con dos (o más) reglas elegidas, dependiendo de qué características se observen. Por ejemplo, el concepto mostrado en la Figura 8.1 es consistente con la explicación  $p_1 \wedge p_2$  y *también* con la explicación  $p_3 \vee p_4$ , dependiendo de qué características se observen. En general, el experimentador puede elegir cualquier par de reglas que usen cualquier número de características (no superpuestas), y nuestro marco garantiza que los

ejemplos presentados solo son consistentes con las dos reglas mínimas elegidas por el experimentador. Luego, al presentar ejemplos novedosos que sean consistentes con solo una de las reglas anteriores, el experimentador puede determinar qué regla usaron los participantes internamente para aprender el concepto y, por lo tanto, a qué características atendieron.

Presentar las reglas  $A$  y  $B$  (por ejemplo,  $p_1 \wedge p_2$  y  $p_3 \vee p_4$ ) utilizando el mismo conjunto de ejemplos tiene varias ventajas experimentales sobre la presentación por separado de un conjunto de ejemplos coherentes con la regla  $A$  y luego un conjunto de ejemplos consistentes con la regla  $B$ . Algunas de las ventajas son:

- (1) Cuando comparamos la dificultad relativa de aprender  $A$  y  $B$  en el mismo participante, si presentamos los ejemplos por separado, se complica superar los efectos de transferencia que hacen que la dificultad subjetiva dependa de la historia de conceptos aprendidos previamente en la tarea, y provoquen diferentes dificultades relativas si  $A$  se aprende antes de  $B$  en comparación a si  $B$  se aprende antes de  $A$  (ver por ejemplo [Tano et al., 2020]). El experimentador podría comparar los tiempos de aprendizaje para  $A$  y  $B$  entre los participantes, pero para reglas razonablemente estrictas, existen diferencias idiosincrásicas muy grandes en las dificultades de aprendizaje que aumentan enormemente la variación de los tiempos de aprendizaje (ver, por ejemplo, [Feldman, 2000]). Además, el experimentador no puede normalizar la historia pasada de cada participante antes del experimento. Por otro lado, presentar  $A$  y  $B$  simultáneamente a través del mismo conjunto de ejemplos nos permite medir directamente cuál de las dos reglas encuentra más fácilmente el participante, cuando las dos se presentan exactamente bajo las mismas condiciones experimentales.

- (2) El hecho de que la regla  $A$  se aprenda más fácilmente que  $B$  cuando se presentan por separado no significa necesariamente que suceda lo mismo cuando se presenta en conjunto. Esto no podría ser válido si existiera una interacción entre los operadores lógicos que se están aprendiendo (que componen las reglas  $A$  y  $B$ ) y el mecanismo de búsqueda utilizado para encontrar las reglas correspondientes. Por ejemplo, el mecanismo de búsqueda que permite a los humanos encontrar una regla de disyunción consistente con los ejemplos podría interactuar con el mecanismo que permite encontrar conjunciones, interacción que solo podría caracterizarse cuando la conjunción y la disyunción se presentan al mismo tiempo.
- (3) Nuestro marco nos permite probar efectos de dificultad subjetiva de segundo orden (por ejemplo, la regla  $A$  se aprende más rápido si se presenta junto con la regla  $B$  que si se presenta junto con la regla  $C$ ), así como efectos de aprendizaje de transferencia de segundo orden (por ejemplo, los participantes aprenden más rápidamente la regla  $C$  si primero han observado la regla  $A$  presentada conjuntamente con una regla arbitraria  $B_1$ , en comparación con junto con una regla diferente  $B_2$ ).
- (4) Si uno está interesado en qué características observa preferentemente el participante en una prueba determinada (por ejemplo, las características  $\{p_1, p_2\}$  o  $\{p_3, p_4\}$ ), simplemente se podría elegir la misma estructura lógica por  $A$  y  $B$  (por ejemplo, haciendo que  $A$  y  $B$  sean iguales a  $p_1 \wedge p_2$  y  $p_3 \wedge p_4$ ) y comprobar si el participante aprende  $A$  o  $B$ . Entonces, cualquier preferencia por aprender  $A$  sobre  $B$  solo podría deberse a una preferencia sobre las características en sí mismas ( $\{p_1, p_2\}$ ), y no por la descripción lógica del concepto que usa esas características (esto es,  $\cdot \wedge \cdot$ ).

Ilustramos estas ventajas en un experimento en el que a los participantes se les presenta

una secuencia de 6 pruebas, observando en cada prueba un conjunto de ejemplos consistentes con dos reglas alternativas. Ilustramos la ventaja (1) y (2) discutida anteriormente presentando una conjunción junto con una disyunción; y una regla simple junto con una regla compleja. Luego, mostramos que después de observar en varias pruebas que un subconjunto de características es útil para encontrar reglas concisas, inducimos en los participantes un sesgo para describir conceptos usando preferentemente esas características; este sesgo se probó aprovechando la ventaja (4).

## 8.1. Experimento

### 8.1.1. Participantes

El experimento se llevó a cabo como una tarea de Human Intelligence Task (HIT) en Mechanical Turk [[Crump et al., 2013](#), [Buhrmester et al., 2011](#), [Stewart et al., 2015](#)] de Amazon. Hubo 100 participantes, trabajadores autoseleccionados que vieron, aceptaron y terminaron el HIT publicado. Requerimos que los trabajadores tuvieran una tasa de aprobación HIT de 95 % o más. Se informó a los trabajadores que el pago por completar el experimento sería de 1,5 dólares estadounidenses, y que a 1 de cada 20 participantes se le asignaría aleatoriamente una bonificación de 10 dólares, independientemente de su desempeño en las tareas del experimento, siempre que terminaran el experimento (pero tener en cuenta que las pruebas no terminaron hasta que aprendieron correctamente cada concepto).

Para conocer los criterios de exclusión, consultar el apéndice §[A.1](#).

### 8.1.2. Configuración del experimento

La idea principal de nuestro marco experimental se esquematiza en la Figura 8.2. Los participantes observan un concepto *indeterminado*. Este concepto se presenta a los participantes como un conjunto de elementos que le pertenecen (ejemplos positivos), y un conjunto de elementos que no (ejemplos negativos). En la Figura 8.2, los elementos marcados como ejemplos positivos son los que están en la intersección de los dos conceptos y los ejemplos negativos son los que están fuera de ambos conceptos. Es importante destacar que la lista es incompleta, en el sentido de que no se muestran todos los elementos del universo. La idea fundamental es que, al extender el conjunto de ejemplos al universo completo, hay más de un concepto posible que es consistente con los ejemplos observados. Por ejemplo, en la Figura 8.2, los ejemplos presentados son consistentes con la regla mínima de  $C_1$  (es decir,  $\varphi_1 = p_1 \vee p_2$ ) y también con la regla mínima de  $C_2$  (es decir,  $\varphi_2 = p_3 \wedge p_4$ ). Como explicamos en el resto de esta sección, la elección adecuada de  $C_1$  y  $C_2$  puede aprovecharse para controlar las reglas mínimas que son consistentes con los ejemplos que observan los participantes.

El experimento real que implementamos consiste en una secuencia de 6 pruebas, cada una de las cuales está construida de esta manera. Ahora expandimos las 3 etapas que componen la  $i$ -ésima prueba del experimento. Para una mejor comprensión, consultar la Figura 8.3, que consiste en una vista esquemática de una prueba. Tenga en cuenta que esta figura es meramente ilustrativa y no pretende describir los detalles de una prueba, sino más bien la secuencia de fases y el flujo lógico dentro de una prueba. En particular, tener en cuenta que el número de elementos A, B, C y D en la figura no son significativos, ya que varían de prueba en prueba a lo largo del experimento. Los conceptos reales utilizados en cada ensayo, así como el número de ejemplos positivos y negativos se enumeran en

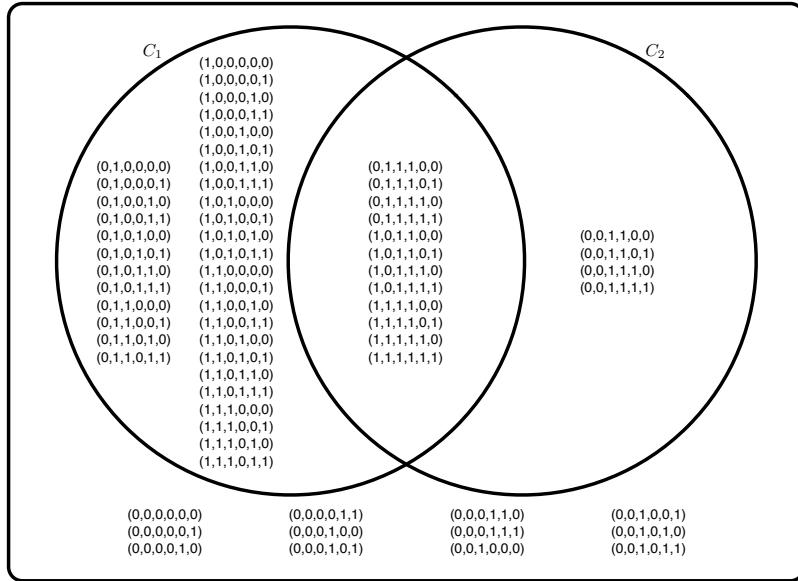


Figura 8.2: Un ejemplo de un par de conceptos  $C_1$  y  $C_2$  con 6 características. El concepto  $C_1$  puede ser descrito por  $\varphi_1 = p_1 \vee p_2$ , y  $C_2$  por  $\varphi_2 = p_3 \wedge p_4$ . Esta es solo una ilustración esquemática de dónde se coloca cada elemento (tupla) con respecto a los conceptos. Estos conceptos corresponden a los utilizados en la Prueba 1 del experimento real. Sin embargo, los elementos del experimento real no se representan de esta manera (es decir, como tuplas de ceros y unos).

la Tabla 8.1 (los grupos X, Y solo son relevantes para la Hipótesis III, por lo que pueden ignorarse por ahora), y se pueden encontrar más detalles de la implementación real en §8.2.2 y §8.2.3.

1. **Etapa de aprendizaje.** El participante se expone a un conjunto de elementos ‘adentro’ correspondientes a  $C_1^i \cap C_2^i$  (marcados como ‘sf A’ en la Figura 8.3), y un conjunto de Elementos ‘afuera’ correspondientes al *complemento* de  $C_1^i \cup C_2^i$  (marcados como ‘B’ en la Figura reffig:trials).

A estos elementos mostrados los llamamos ‘ejemplos positivos’ y ‘ejemplos negativos’, respectivamente. Hay que tener en cuenta que esta información es incompleta, en el sentido de que no todos los ejemplos posibles se muestran al participante (ya que los únicos ejemplos que se muestran de  $C_1^i \cup C_2^i$  son los de  $C_1^i \cap C_2^i$ ). En el ejemplo ilustrativo de la Figura 8.2 (correspondiente a los conceptos de la Prueba 1 del experimento real), se mostrarían 24 elementos: los 12 ejemplos positivos en la intersección de  $C_1$  y  $C_2$ , y los 12 ejemplos negativos fuera de  $C_1$  y fuera de  $C_2$ . Se pide al participante que aprenda el concepto representado por ejemplos positivos.

Como demostramos formalmente en el Apéndice A.3, el diseño experimental garantiza que solo hay dos reglas proposicionales ( $\varphi_1$  y  $\varphi_2$  en la Figura 8.2), mínimas sobre sus respectivos conjuntos de características, tales que: (1) son explicaciones *consistentes* con los ejemplos mostrados (esto es, satisfacen los ejemplos positivos pero no satisfacen los ejemplos negativos), (2) usan características diferentes entre sí (por ejemplo,  $\{p_1, p_2\}$  en  $\varphi_1$  y  $\{p_3, p_4\}$  en  $\varphi_2$ ) y, lo que es más importante, (3) *cualquier* regla consistente con los ejemplos debe usar un superconjunto del conjunto de características de al menos una de estas reglas mínimas. Por ejemplo, en la Figura 8.2 cualquier regla que solo use  $\{p_2, p_3\}$  no puede explicar los ejemplos, ya que

$(1, 0, 1, 1, 1)$  es un ejemplo positivo, pero  $(0, 0, 1, 0, 1, 1)$  es un ejemplo negativo. Cualquier regla que pueda explicar consistentemente los ejemplos debe mencionar un superconjunto de  $\{p_1, p_2\}$  (por ejemplo,  $\{p_1, p_2, p_3\}$ ) o un superconjunto de  $\{p_3, p_4\}$ . La prueba de esta condición se muestra en el Teorema 3, pero también lo esbozamos aquí. Observar que en la Figura 8.2 el ejemplo negativo  $(0, 0, 1, 0, 1, 1)$  se construyó a partir del ejemplo positivo  $(1, 0, 1, 1, 1)$  invirtiendo los valores de  $p_1$  y  $p_4$ , y hacerlo da como resultado un elemento que es inconsistente tanto con  $\varphi_1$  como con  $\varphi_2$ . Cuando una explicación alternativa deja sin usar algunas características  $p, q$  que aparecen en  $\varphi_1$  y  $\varphi_2$  respectivamente, debe haber algún elemento que satisfaga ambas reglas  $\varphi_1, \varphi_2$ , pero ninguna de ellas es satisfecha cuando se invierten los valores de  $p$  y  $q$ . Dado que el valor de verdad de la regla alternativa se mantiene cuando cambian características que no aparecen en ella, y dado que estamos mostrando como ejemplos positivos todos los elementos que satisfacen ambas reglas  $\varphi_1, \varphi_2$  y como ejemplos negativos todos aquellos que no satisfacen ninguno de ellos, dicha explicación alternativa debe ser inconsistente con los datos mostrados.

Estas tres condiciones garantizan que el procedimiento experimental ilustrado en la Figura 8.2 es un método lógicamente sólido para presentar un concepto consistente con dos reglas mínimas elegidas por el experimentador ( $\varphi_1$  y  $\varphi_2$ ), dependiendo sobre qué características se basa el participante para construir la regla.

2. **Etapa de entrenamiento-feedback.** Los *mismos* ejemplos de la etapa de aprendizaje se muestran al participante, pero esta vez sin indicar si son negativos o positivos y en orden aleatorio. Se le pide al participante que etiquete cada elemento como ‘adentro’ o ‘auera’, de la misma manera que se etiquetaron en el paso anterior. Si todos los elementos están clasificados correctamente, el participante pasa a la siguiente etapa.

De lo contrario, se informa al participante sobre los errores en su etiquetado, y después de eso, la etapa de capacitación-*feedback* comienza nuevamente.

3. **Etapa de generalización.** *Los elementos no vistos anteriormente* se muestran al participante<sup>1</sup>. Estos elementos se toman de  $C_1^i \setminus C_2^i$  y de  $C_2^i \setminus C_1^i$  (aquí, ‘\’ denota la diferencia de conjuntos). Estos elementos están marcados respectivamente como ‘C’ y ‘D’ en el esquema de la Figura 8.3. Se pide al participante que identifique aquellos elementos que corresponden al concepto aprendido en la etapa de aprendizaje. Después de hacerlo, comienza la siguiente prueba. Si el participante selecciona los de  $C_1^i \setminus C_2^i$ , el concepto aprendido en la etapa de Aprendizaje fue  $C_1^i$ , y si el participante selecciona los de  $C_2^i \setminus C_1^i$ , el concepto que aprendieron fue  $C_2^i$ . Continuando con el ejemplo de la Figura 8.2, este proceso nos permitiría determinar si el participante estaba pensando en una regla con las características  $\{p_1, p_2\}$  (es decir,  $\varphi_1$ ) o  $\{p_3, p_4\}$  (es decir,  $\varphi_2$ ) para explicar el concepto. Por supuesto, en la práctica, el participante puede seleccionar otros elementos, sin una justificación clara.

Una vez que el participante elige los elementos, se le pide que escriba una explicación de lo que constituye el concepto; esta respuesta no es parte del análisis de datos, excepto que nos permite excluir a los participantes que están usando métodos fuera del alcance del experimento (como tomar fotografías). Además, las respuestas escritas sirven como una *sanity check* adicional de si los participantes realmente están pensando de una manera consistente con el marco de la lógica proposicional (ver §A.1 para las observaciones sobre las explicaciones escritas obtenidas en el experimento).

---

<sup>1</sup>Con la excepción de la Prueba 6, donde un elemento se vuelve a mostrar para testear mejor la Hipótesis II. Ver §8.1.3.

Se pueden encontrar más detalles del experimento y su estructura en la Sección 8.2, particularmente en §8.2.2 y §8.2.3.

### 8.1.3. Ensayos experimentales

El conjunto de pruebas elegidas en el experimento (Tabla 8.1) tiene como objetivo revelar los sesgos que hacen que los participantes elijan un conjunto de características sobre otro en este marco donde ambos conjuntos de características tienen sus propias reglas mínimas consistentes con los ejemplos observados positivos y negativos. Por ejemplo, en la Figura 8.2, ¿qué hace que los participantes elijan  $\{p_1, p_2\}$  versus  $\{p_3, p_4\}$  para explicar el concepto? Nuestra hipótesis es que un sesgo inductivo clave es simplemente la frecuencia con la que se utilizó previamente un subconjunto de características para explicar conceptos pasados. Denominamos este sesgo como *característica adherente*.

A continuación presentamos las principales hipótesis de este trabajo y su relación con las distintas pruebas experimentales.

**Hipótesis I.** En la Prueba 1, exploramos si los mismos factores que determinan la dificultad en el aprendizaje de las reglas cuando se aprenden de forma aislada también determinan qué características usan los participantes al explicar un conjunto de ejemplos consistentes con dos reglas mínimas. En particular, es bien sabido que los conceptos que involucran conjunciones lógicas se aprenden más rápido que los conceptos que involucran disyunciones lógicas [Bourne, 1970].

En la Prueba 1, la regla mínima consistente es una disyunción si las características observadas son  $\{p_1, p_2\}$ , y una conjunción si las características observadas son  $\{p_3, p_4\}$ . Es importante destacar que, a diferencia de otros experimentos de aprendizaje de conceptos,

Prueba	Grupo	$\varphi_1^i$	$\varphi_2^i$	Caract. mostradas	Hipótesis testeadas				Ejemplos mostrados #Positivos (#Negativos)
					I	II	III	IV	
$i = 1$	X, Y	$p_1 \vee p_2$	$p_3 \wedge p_4$	$p_1 \text{ to } p_6$	•			•	12 (12)
$i = 2$	X, Y	$\neg p_1 \wedge p_2$	$p_3 \vee \neg p_4$					•	12 (12)
$i = 3$	X	$p_1 \wedge p_2$	MDL15				•		10 (18)
	Y	$p_5 \wedge p_6$	MDL15				•		10 (18)
$i = 4$	X, Y	$\neg p_5 \wedge p_6$	MDL15				•		10 (18)
$i = 5$	X, Y	$p_7 \wedge p_8$	MDL15	$p_3 \text{ to } p_8$		•			10 (18)
$i = 6$	X, Y	$\neg p_7 \wedge \neg p_8$	$p_3 \wedge p_4$			•			4 (36)

Cuadro 8.1: Las pruebas del experimento. Aquí  $\varphi_1^i$  y  $\varphi_2^i$  representan los dos conceptos en competencia  $C_1^i$  y  $C_2^i$  en la  $i$ -ésima prueba (denotamos cada concepto por la regla proposicional más corta cuya semántica describe el concepto). Por “MDL15” denotamos un concepto cuya regla más corta es de longitud 15 (y está compuesta por tres símbolos proposicionales distintos de la regla en competencia en el ensayo correspondiente, ver §8.3.5 para más detalles). En todas las pruebas, el tamaño total del universo es de  $2^6 = 64$ , correspondiente a todos los elementos posibles sobre 6 características proposicionales. Indicamos cómo se dividió a los participantes en los grupos X e Y, que se usó solo para la Hipótesis III. También indicamos qué características se muestran en los ejemplos, qué hipótesis se testearon y el número de ejemplos positivos y negativos que se muestran en las fases de aprendizaje y entrenamiento para cada ensayo.

tanto la disyunción como la conjunción de dos características son consistentes con el conjunto de ejemplos observado. Presumimos que el sesgo de aprendizaje que hace que la conjunción se aprenda más fácilmente que la disyunción también se trasladará a este marco si ambas explicaciones son posibles (utilizando características diferentes). Como se explicó antes, usamos la etapa de generalización de la Prueba 1 para determinar si los participantes entendieron el concepto usando  $\{p_1, p_2\}$  (correspondiente a una disyunción) o usando  $\{p_3, p_4\}$  (correspondiente a una conjunción).

Esta hipótesis fue pre-registrada como:

En un escenario de dos posibles explicaciones para un concepto, una de las cuales puede ser modelada por el  $\wedge$  lógico entre dos características y otra que puede ser modelada por el  $\vee$  lógico entre otras dos características, la mayoría de la gente encontrará la explicación de  $\wedge$  sobre la explicación de  $\vee$ .

**Hipótesis II.** El sesgo de *característica adherente* se testea en las Pruebas 5 y 6 del experimento. Una vez que los participantes han adquirido suficiente experiencia con la tarea, en la Prueba 5, los participantes encuentran un conjunto de ejemplos consistentes con dos explicaciones mínimas, una muy simple que usa las características  $\{p_7, p_8\}$  y otra muy compleja que usa  $\{p_4, p_5, p_6\}$ . Esto lleva a los participantes a explicar el concepto usando  $\{p_7, p_8\}$ , o de lo contrario tendrían que descubrir una explicación excesivamente compleja. Por lo tanto, planteamos la hipótesis de que en este caso la mayoría de los participantes seleccionarían las características  $\{p_7, p_8\}$ <sup>2</sup>.

En el siguiente concepto (Prueba 6), los participantes deben elegir entre explicaciones que utilizan las funciones previamente útiles  $\{p_7, p_8\}$  u otro conjunto nuevo de funciones  $\{p_3, p_4\}$ . Suponemos que es más probable que los participantes expliquen el concepto usando  $\{p_7, p_8\}$ , solo porque estas características fueron útiles en el concepto anterior. Además, recordemos que las explicaciones que utilizan un conjunto de características que contienen  $\{p_7, p_8\}$  o  $\{p_3, p_4\}$  también son compatibles. Por ejemplo, en la Prueba 6, la explicación  $p_3 \wedge p_4 \wedge \neg p_7$  es compatible con los ejemplos observados. También estamos interesados en estas reglas (por ejemplo, creemos que es más probable que los participantes usen  $\{p_7, p_8, p_3\}$  que  $\{p_3, p_4, p_7\}$ ). Los siete elementos elegidos para la etapa de generalización de la Prueba 6 nos permiten hacer precisamente esto: aparecen 7 elementos en la pantalla,

---

<sup>2</sup>Tener en cuenta que las características  $\{p_5, p_6\}$  que se utilizaron en la Prueba 4 también aparecen la formula MDL15 de la Prueba 5. Sin embargo, planteamos la hipótesis de que la extrema complejidad de la explicación MDL15 sobrepasa el posible efecto de adherencia de características de la Prueba 4 a la 5. De hecho, encontramos que ninguno de los participantes utilizó la fórmula MDL15 en la Prueba 5.

con  $p_3, p_4, p_7, p_8$  respectivamente iguales a  $(1, 1, 1, 1)$ ,  $(1, 1, 0, 1)$ ,  $(1, 1, 1, 0)$ ,  $(1, 1, 0, 0)$ ,  $(1, 0, 0, 0)$ ,  $(0, 1, 0, 0)$ ,  $(0, 0, 0, 0)$ . Estos elementos son respectivamente consistentes con las reglas mínimas  $p_3 \wedge p_4$ ,  $p_3 \wedge p_4 \wedge \neg p_7$ ,  $p_3 \wedge p_4 \wedge \neg p_7 \wedge \neg p_8$ ,  $p_3 \wedge \neg p_7 \wedge \neg p_8$ ,  $p_4 \wedge \neg p_7 \wedge \neg p_8$  y  $\neg p_7 \wedge \neg p_8$ . Es importante destacar que ninguno de los elementos es coherente con más de una de las dos reglas mínimas.

Esta hipótesis fue pre-registrada como:

Si una persona ha utilizado un conjunto de características en la construcción de una explicación para un concepto, es más probable que también encuentre una explicación que contenga esas características en la siguiente prueba.

**Hipótesis III.** Abordamos la cuestión de si el sesgo de adherencia de características representa una ventaja computacional en sí mismo. Más concretamente, preguntamos si los participantes encuentran una regla coherente *más rápido* cuando están reutilizando las mismas funciones que en la prueba anterior. Tenga en cuenta que este es un fenómeno distinto al de la Hipótesis II, que se ocupa de la selección preferencial y no de los tiempos. Testeamos esta pregunta, independientemente del efecto del sesgo de adherencia de la característica, en las Pruebas 3 y 4 del experimento. En la Prueba 3, sepáramos a los participantes en los grupos X e Y. De la misma manera que en la Prueba 5, en la Prueba 3 el grupo X está predispuesto a aprender la regla usando  $\{p_1, p_2\}$ , y el grupo Y usando  $\{p_5, p_6\}$ . En la siguiente prueba (Prueba 4), los participantes están predispuestos a aprender la regla usando  $\{p_5, p_6\}$ . Suponemos que los participantes del grupo Y aprenderán el concepto  $C_1^4$  más rápido que los participantes del grupo X, dado que están reutilizando las mismas características que usaron en la prueba anterior.

Esta hipótesis fue pre-registrada como:

Cuando un concepto solo puede describirse razonablemente mediante un conjunto de características dado, una persona encontrará esta descripción más rápido si ese mismo conjunto de características le fue útil en la prueba inmediatamente anterior.

**Hipótesis IV.** Otra pregunta, testeada con las Pruebas 1 y 2, examina la fuerza relativa del sesgo de característica versus el sesgo del operador. Es decir, queremos determinar si hay algún efecto fuerte que claramente desvíe la atención hacia las características (o, más bien, hacia los operadores) que previamente se han encontrado útiles para describir conceptos. Probamos esto cambiando el operador ( $\vee$  /  $\wedge$ ) que cada par de características puede usar para formar una regla útil en cada prueba, y luego comparando el número de participantes que explican los ejemplos mostrados de la Prueba 2 reutilizando las mismas funciones de la Prueba 1 frente a los que reutilizaron el operador pero utilizaron funciones diferentes.

Esta hipótesis fue pre-registrada como:

En un escenario en el que tanto las características como los operadores se repiten de una prueba a la siguiente, habrá un efecto de adherencia que favorecerá a uno de ellos sobre el otro.

## 8.2. Metodología

### 8.2.1. Pre-registro y datos

La metodología de este estudio, los procedimientos de recopilación de datos, el tamaño de la muestra, los criterios de exclusión y las hipótesis se registraron previamente en

el Open Science Framework (OSF) antes de la recopilación y el análisis de los datos. Se puede acceder a el pre-registro en <https://osf.io/mgex3>, mientras que los datos obtenidos y el experimento realizado por los participantes están disponibles en <https://osf.io/gtuwp/>.

En este trabajo también realizamos algunos análisis exploratorios (no pre-registrados): corregimos las explicaciones verbales que no eran consistentes con una interpretación positiva del concepto para la Hipótesis I, excluimos los valores atípicos del análisis en la Hipótesis III, y consideramos el efecto del historial de aprendizaje del participante más allá de la prueba inmediatamente anterior en la Hipótesis II. También analizamos explícitamente, en este marco de múltiples explicaciones consistentes, la diferencia en la dificultad revelada entre reglas de longitud mínima muy diferente.

### 8.2.2. Detalles de representación

La estructura matemática subyacente de las pruebas utiliza variables proposicionales, valuaciones y conjuntos de valuaciones. Sin embargo, estos no se muestran de forma abstracta, sino que se representan mediante correspondencias con características (símbolos), elementos (cajas) y conceptos (colecciones de elementos).

A continuación, describimos los detalles de las representaciones utilizadas para el experimento y sus conceptos en competencia.

**Características—variables proposicionales** El experimento abarca ocho variables proposicionales:  $p_1, \dots, p_8$ . Cada variable puede tomar uno de dos valores posibles, y estos valores están representados gráficamente por iconos. Por ejemplo, a  $p_1$  se le puede asignar

el ícono ‘A’ o el ícono ‘B’, que representan los valores 1 (positivo) y 0 (negativo) respectivamente, a  $p_3$  se le puede asignar un ícono ‘+’ o el ícono ‘×’ que representa 1 y 0 respectivamente, y así sucesivamente.

La Figura 8.4 muestra los pares de valores para cada una de las ocho variables proposicionales. La asignación de pares de íconos a las variables proposicionales es aleatoria al comienzo del experimento y no varía dentro del experimento. La razón para elegir íconos en lugar de valores (de color) 0, 1 es para evitar la posibilidad de aprender mentalmente un concepto usando ‘conteo’ u otros operadores que no están presentes en la lógica proposicional. Por ejemplo, mostrando valores  $\{0, 1\}$  explícitos, una posible explicación para un concepto podría ser *más de 3 unos*, pero tal descripción sería mucho más difícil en la representación basada en íconos, ya que diferentes variables proposicionales carecen de símbolos en común. En §8.2.4 discutimos más detalles sobre estas consideraciones.

**Elementos (cajas)—valuaciones.** Una valuación sobre las variables proposicionales se representa visualmente como un cuadrado/caja con los valores (íconos) de todas las variables proposicionales colocadas en posiciones aleatorias dentro de la caja. Llamamos a esta representación un ‘elemento’ (ver Figura 8.5 para ver un ejemplo de tal elemento). La razón para elegir esta representación es evitar sesgos direccionales que podrían influir en el aprendizaje y excluir el orden y otros operadores del lenguaje del pensamiento (consultar §8.2.4 para obtener más detalles). Cada vez que se muestra un elemento (en particular, dentro del ciclo en la etapa de entrenamiento-*feedback*) se elige una nueva posición aleatoria para las características proposicionales dentro de él.

**Conceptos indeterminados—conjuntos de valuaciones positivas/negativas.** El concepto que se muestra en la etapa de aprendizaje de una prueba corresponde a dos conjuntos de valuaciones que no se superponen, y estos dos conjuntos no cubren todas las valuaciones posibles. Esto se representa como una secuencia de elementos ‘adentro’ y ‘afuera’, sin información sobre los elementos que no se muestran. En la etapa de aprendizaje, los elementos ‘adentro’ (ejemplos positivos) se representan como una caja con borde verde y los elementos ‘afuera’ (ejemplos negativos) como una caja con borde rojo. Consultar la Figura 8.6 para ver un ejemplo de una secuencia etiquetada de elementos utilizados en la etapa de aprendizaje. Cada vez que se presenta el concepto, barajamos el orden en el que se muestran sus ejemplos positivos y negativos, pero siempre presentando todos los ejemplos positivos primero (además, a cada valuación se le asignan nuevas posiciones aleatorias para las características dentro de la caja correspondiente).

**Conceptos (ocultos)—fórmulas.** Sobre el conjunto completo de valuaciones, un concepto es simplemente el conjunto de valuaciones que lo describen positivamente. Los dos conceptos ocultos para cada prueba corresponden a las generalizaciones válidas y mínimas que se pueden hacer a partir de los conceptos incompletos. Pueden describirse como la semántica de las dos fórmulas proposicionales (reglas) que pueden usarse para explicar el concepto incompleto (ver Tabla 8.1); si bien estas reglas coinciden en el universo incompleto que se muestra en la etapa de aprendizaje, difieren en el conjunto de todas las valuaciones. Para obtener más detalles, recuerde el comienzo de §8.1.2 y su Item 1. Para obtener detalles técnicos, consultar §A.3.

En la Tabla 8.2 resumimos la principal terminología lógica usada para definir la semántica formal, y su contraparte representacional adoptada en nuestra configuración experi-

mental.

**Santi:** Parte (no toda) de esta tabla puede ser mandada al primer capítulo, dado que comparte mucho con el paper de PRE. Habría que unificar nomenclatura entre PRE y BRM.

### 8.2.3. Detalles de la estructura del experimento

Como explicamos en la Sección 8.1, cada instancia del experimento consta de 6 pruebas en las que los participantes deben aprender un concepto de un universo incompleto. Los ejemplos positivos y negativos presentados son tales que hay exactamente dos reglas mínimas (salvo equivalencia lógica) en la lógica proposicional que 1) son explicaciones consistentes para los ejemplos mostrados; 2) usan conjuntos de variables disjuntos entre sí; y 3) cualquier regla consistente con los ejemplos debe usar un superconjunto del conjunto de características de al menos una de estas reglas mínimas. Esta configuración experimental nos permitirá distinguir cuál de estas reglas representa mejor la forma en que el participante aprendió el concepto. Consultar §A.3 para los detalles técnicos.

Observar que el simple hecho de pedirle al participante que seleccione elementos ya vistos no nos da una idea obvia del proceso interno que derivó en el aprendizaje del concepto; incluso si internalizaran el concepto usando una de las dos reglas, sería incierto cuál usaron, ya que ambas reglas tienen la misma semántica sobre el universo mostrado. Para distinguir entre estos dos casos, utilizamos una etapa de generalización donde se muestran elementos del universo nunca antes vistos, y el participante debe seleccionar aquellos que crea que pertenecen al concepto aprendido. De estos nuevos elementos, algunos son consistentes con solo una de las reglas, y otros son consistentes solo con la otra regla<sup>3</sup>. Además, inmediatamente después pedimos una explicación por escrito de las

---

<sup>3</sup>La Prueba 6 es una excepción y tiene un elemento que es consistente con ambas reglas.

Terminología matemática	Terminología representacional
<b>Valuación:</b> una tupla $\bar{v} = (v_1, \dots, v_n)$ donde cada $v_i$ es 0 o 1.	<b>Elemento:</b> una caja con $n$ símbolos dentro (ver Figura 8.5). Hay un código implícito en la Figura 8.4 (por ejemplo, $v_1 = 1$ se representa por una ‘A’ y $v_1 = 0$ se representa por una ‘B’, $v_3 = 1$ se representa por un ‘+’ y $v_3 = 0$ se representa por un ‘×’, y así sucesivamente).
<b>Variable proposicional:</b> $p_i$ toma el valor $v_i$ bajo la valuación $\bar{v} = (v_1, \dots, v_n)$ .	<b>Característica:</b> $p_i$ se representa, vía la codificación implícita, por uno de los pares de la Figura 8.4 dentro de un elemento que representa $\bar{v}$ .
<b>Concepto:</b> un conjunto $U$ de valuaciones que representa aquellas que son ‘positivas’ (por ejemplo, $C_1$ en la Figura 8.2). Notar que las valuaciones negativas son simplemente todas las valuaciones que no están en $U$ .	<b>Concepto:</b> cualquier categorización que divide el espacio de todos los elementos posibles en positivos (todos aquellos elementos que pertenecen a $U$ ) o negativos (elementos que no pertenecen a $U$ ).
Observar que cualquier concepto $U$ tiene una correspondiente <b>formula/regla</b> minimal $\varphi_U$ que la caracteriza (es decir, $\varphi_U$ es verdadera para las valuaciones en $U$ , y es falsa sobre el complemento de $U$ ).	
<b>Concepto indeterminado:</b> un par $\langle U, V \rangle$ de conjuntos de valuaciones que representan los valores ‘positivos’ y ‘negativos’ respectivamente, de modo que $U \cap V = \emptyset$ y $U \cup V$ no es el conjunto de todas las valuaciones (por ejemplo, el par $\langle C_1 \cap C_2, \overline{C_1 \cup C_2} \rangle$ en la Figura 8.2).	<b>Concepto indeterminado:</b> una secuencia de elementos positivos (borde verde) que representan $U$ y elementos negativos (borde rojo) que representan $V$ (consultar la Figura 8.6 para un ejemplo). Es importante destacar que $U$ y $V$ no cubren todo el universo de posibilidades que abarcan las funciones.
Observar que un concepto indeterminado $\langle U, V \rangle$ puede generalizarse de más de una forma mediante fórmulas (mínimas) $\varphi_1$ y $\varphi_2$ tales que a) $\varphi_i$ ( $i = 1, 2$ ) es verdadera en todas las valuaciones en $U$ , y falsa en todas las valuaciones en $V$ , y b) el conjunto de <i>todas</i> las valuaciones positivas donde $\varphi_1$ es verdadera es diferente del conjunto de <i>todas</i> las valuaciones donde $\varphi_2$ es verdadera. Por ejemplo, el concepto indeterminado que se muestra en la $i$ -ésima prueba del experimento se puede generalizar mediante las dos fórmulas mínimas correspondientes $\varphi_1^i$ y $\varphi_2^i$	

características que el participante cree que describen el concepto.

Estructuralmente, el experimento comienza con la asignación (oculta) del participante a uno de los dos grupos X o Y (ver Tabla 8.1) y la exposición a una página con instrucciones. Posteriormente, se realizan 6 pruebas con la siguiente estructura: comienzan con una etapa de aprendizaje; continúan a una etapa de aprendizaje donde reciben *feedback* si no seleccionan correctamente los elementos que pertenecen al concepto; una etapa de generalización donde deben elegir entre elementos del universo que no fueron mostrados previamente; y, en todos menos en la última prueba, una etapa en la que los participantes pueden descansar entre ensayos.

A continuación, describimos cada etapa del experimento más la página de introducción, con mayor detalle que en §8.1.2.

#### **8.2.3.1. Introducción y explicación**

Esta es la página que se muestra a los sujetos al comienzo del experimento. Describe la tarea principal que se les pedirá que realicen: la de aprender de ejemplos para distinguir qué tipo de ‘cajas’ pertenecen a un determinado concepto. Estos elementos se representan como una colección de 6 símbolos, no más de uno de un mismo par. También se le informa que la posición de los símbolos no importa. Consultar la Figura 8.5 para ver un elemento de ejemplo.

Cuando el sujeto indica que ha terminado de leer las instrucciones, se lo envía a una página de pantalla completa con tres preguntas de opción múltiple cuyo propósito es verificar que el participante ha entendido las instrucciones; si se equivoca en alguna respuesta, vuelve a la página anterior y el ciclo se repite hasta que lo consiguen.

Si el participante responde correctamente, está listo para comenzar, y se ingresan a las fases §8.2.3.2, §8.2.3.3, y §8.2.3.4 secuencialmente para cada uno de los 6 ensayos.

### 8.2.3.2. La fase de aprendizaje

En esta fase de una Prueba  $i$ , al participante se le muestra un conjunto  $S^i \subsetneq U^i$ , un subconjunto adecuado de elementos del universo actual. Cada universo corresponde sintácticamente a todas las combinaciones de valores de verdad para 6 variables proposicionales tomadas del conjunto  $\{p_1, p_2, p_3, p_4, p_5, p_6, p_7, p_8\}$ , por lo tanto generando un conjunto  $U^i$  de 64 elementos. Del lado semántico, llamamos ‘características’ a las representaciones visuales de las variables proposicionales, y estas representaciones permanecen fijas durante el experimento (recordar la Figura 8.4).

Los elementos de  $S^i$  se muestran como cajas, algunas de las cuales tienen borde verde (que denota un ejemplo positivo, es decir que el elemento pertenece al concepto), mientras que el resto tiene bordes rojos (que denota un ejemplo negativo, es decir que no lo hacen). Las cajas de borde verde se muestran primero, y las de borde rojo aparecen después de la última caja con borde verde. Consultar la Figura 8.6 para ver un ejemplo de conjunto de aprendizaje.

Si las representaciones gráficas se abstraen de la estructura básica subyacente, hay dos reglas proposicionales  $\varphi_1^i$  y  $\varphi_2^i$  (de longitud mínima en su clase de reglas lógicamente equivalentes, consultar la Tabla 8.1) cuya semántica clasifica correctamente los ejemplos positivos y negativos mostrados. Si llamamos  $C_1^i, C_2^i$  a los conjuntos de valuaciones que satisfacen  $\varphi_1^i, \varphi_2^i$ , respectivamente, tenemos que  $S^i = (C_1^i \cap C_2^i) \cup \overline{(C_1^i \cup C_2^i)}$ . Las reglas  $\varphi_1^i, \varphi_2^i$  usan a lo sumo<sup>4</sup> 3 de las 6 variables proposicionales disponibles en  $U^i$ , y las dos

---

<sup>4</sup>Las reglas que son realmente ‘aprendibles’ usan exactamente 2 variables proposicionales.

reglas no tienen variables proposicionales en común.

Cuando el participante cree que ha aprendido qué elementos pertenecen al concepto, puede hacer clic en un botón para pasar a la siguiente etapa.

#### **8.2.3.3. La fase de entrenamiento–feedback**

En esta fase, al participante se le muestra un reordenamiento aleatorio de  $S^i$ , con todos los elementos ahora rodeados por un cuadrado con borde rojo. El sujeto debe hacer clic exactamente en esos elementos (si los hay) que cree que pertenecen al concepto —cambiándolos a un borde verde punteado (ver Figura 8.7)— y luego debe hacer clic en un botón para enviar su elección.

Si su selección es incorrecta, se le muestra al participante qué elementos clasificaron erróneamente (ya sea haciendo clic en ellos incorrectamente o no haciendo clic en ellos, consulte la Figura 8.8). Cuando hacen clic en un botón para continuar, reinician esta etapa (con una nueva mezcla aleatoria en la posición de las cajas y los símbolos dentro de ellas).

Cuando el participante finalmente hace la selección correcta, pasa a la siguiente fase.

#### **8.2.3.4. La fase de generalización**

En esta fase, se muestra al participante un subconjunto de  $U^i \setminus S^i$  (o sea,  $(C_1^i \cup C_2^i) \setminus (C_1^i \cap C_2^i)$ ), es decir, una selección de elementos que *no* estaban presentes en la fase de aprendizaje (por tanto, tampoco en la de aprendizaje). El participante debe clasificar cuáles de estos elementos cree que pertenecen al concepto. El participante no recibe comentarios sobre las elecciones que hace aquí. Excepto por la sexta prueba, parte de estos elementos satisfacen la regla  $\varphi_1^i \wedge \neg\varphi_2^i$ , mientras que el resto satisface  $\varphi_2^i \wedge \neg\varphi_1^i$ . Por lo tanto, —asumiendo

que el participante aprendió el concepto a través de un proceso similar a la representación de una de las dos reglas— esta fase sirve de manera crucial para distinguir qué regla ha aprendido, si es que ha aprendido alguna.

Después de esta selección, se solicita al participante que presente una explicación por escrito de lo que cree que define al concepto. Esta explicación escrita sirve como una validación adicional de si están pensando de una manera descriptible por lógica proposicional según nuestros supuestos, o si más bien están usando otros métodos (memorización, lápiz y papel, capturas de pantalla, otras lógicas o formalismos, etc.).

#### **8.2.4. Notas sobre el diseño del experimento**

Los elementos, universos y reglas que constituyen nuestro experimento están diseñados en términos de lógica proposicional. Sin embargo, es importante ser cuidadosos con la semántica, es decir, la forma en que los elementos se muestran realmente a los participantes. Tenemos que evitar dar más prominencia a la semántica de una variable proposicional sobre las demás, y es imperativo seleccionar la semántica de las variables de tal manera que no compartan características que puedan escapar a nuestra gramática proposicional: por ejemplo, si las variables proposicionales se representaron como círculos que pueden tener distintos colores o no, sería bastante natural suponer que contar círculos coloreados o no coloreados podría proporcionar información, pero esta opción no se considera en un diseño teórico que asume solo operadores proposicionales para describir reglas. Una consideración relacionada es que también debemos evitar introducir otras regularidades ajena a la formulación proposicional: si las imágenes correspondientes a todas las variables proposicionales se muestran siempre en línea recta en el mismo orden, los efectos de

prominencia pueden aparecer *incluso si* evitamos semánticas que se vuelven más expresivas gracias a la naturaleza ordenada de las variables representadas (como con descripciones de la forma *el primer y último elemento son del mismo tamaño*).

Santi: aca podes referenciar a los semáforos de PRE y decir que este diseño lo supera

**Construyendo representaciones semánticas adecuadas para nuestra lógica.** Teniendo en cuenta estas precauciones, optamos por hacer coincidir cada variable proposicional con una imagen o figura en particular, cuya posición en un cuadrado sería aleatoria (pero evitando superposiciones). Es difícil decidir exactamente cuál sería la mejor coincidencia de variable a imagen, pero nuestra decisión final consiste en hacer coincidir cada variable proposicional con un conjunto de dos caracteres Unicode relacionados (como un triángulo cuando la variable es 0 y un círculo en caso contrario). Ver la Figura 8.4 para las representaciones exactas. Nos encargamos de elegir diferentes tipos de caracteres para diferentes variables: tener  $A, B$  para  $p_1$  y  $Y, Z$  para  $p_5$  es una posibilidad, ya que naturalmente introduce el conteo del tipo ‘no hay más de 1 letra’ y similares. Por supuesto, este proceso no es completamente seguro, ya que existen innumerables asociaciones semánticas posibles que podrían introducir gramáticas extra-proposicionales en el experimento. No obstante, tratamos de minimizar la posibilidad de que esto suceda fácil o naturalmente, y usamos la etapa de explicación escrita como una forma de detectar estas excepciones si ocurriesen<sup>5</sup>.

Finalmente, para minimizar los posibles efectos de prominencia de mostrar símbolos que podrían tener (a pesar de nuestras intenciones en la dirección contraria) diferentes niveles de notoriedad, aleatorizamos por participante la asignación entre pares de símbolos y variables proposicionales (pero no aleatorizamos la asignación al valor positivo o negativo de una variable; los mismos caracteres Unicode son siempre positivos en todas las aleatorizaciones,

<sup>5</sup>Al final, no ocurrieron. Consultar §A.1.

o siempre negativos).

**Orden de ejemplos positivos y negativos.** Como se mencionó anteriormente, en la etapa de aprendizaje cambiamos el orden en el que se muestran los ejemplos positivos y negativos, pero siempre presentando todos los ejemplos positivos primero. Además, el número de ejemplos positivos es menor o igual al número de ejemplos negativos para todos los conceptos (ver Tabla 8.1).

El propósito de colocar los ejemplos positivos primero y tener menos ejemplos positivos que negativos es sesgar al participante para que piense en el concepto por su formulación positiva, en lugar de pensar posiblemente en una regla que describa los ejemplos negativos, y luego negar esa regla para obtener el positivo. Esto se vuelve importante cuando queremos razonar sobre la facilidad de aprendizaje de diferentes operadores: la suposición predeterminada es que los participantes que seleccionan correctamente ejemplos positivos del concepto piensan en la regla positiva, que difiere en su operador de la regla negativa (por las leyes de De Morgan).

## 8.3. Resultados

### 8.3.1. Hipótesis I

Nos preguntamos si el sesgo de conjunción-disyunción (que se sabe que afecta los tiempos de aprendizaje en el caso de una explicación única [Bourne, 1970]) también determina qué características se usan para describir un concepto cuando dos explicaciones alternativas son consistentes con el universo observado. En la primera prueba, los ejemplos

observados fueron consistentes con  $p_1 \vee p_2$  y con  $p_3 \wedge p_4$ . Como se explica en §8.1.2, en la etapa de generalización podemos determinar si los participantes explicaron el concepto usando  $\{p_1, p_2\}$  o  $\{p_3, p_4\}$ . Encontramos que 77 de los 100 participantes prestaron atención a  $\{p_3, p_4\}$ , que corresponde a una explicación que usa una conjunción. 11 participantes se enfocaron a  $\{p_1, p_2\}$  (correspondiente al uso de una disyunción para la explicación), y 12 participantes seleccionaron ejemplos en la etapa de generalización inconsistentes con  $p_3 \wedge p_4$  y  $p_1 \vee p_2$ . Para probar la importancia de este resultado, realizamos una prueba de permutación. Bajo la hipótesis nula de que los participantes eligen aleatoriamente entre explicar el concepto usando las características  $\{p_1, p_2\}$  y explicarlo usando  $\{p_3, p_4\}$ , la probabilidad de que 77 de los 100 participantes asistan a  $\{p_3, p_4\}$  es  $P < 10^{-12}$ . Por tanto, concluimos que la diferencia observada es significativa.

Hay que tener en cuenta que, en principio, es posible que el participante haya aprendido el concepto con un enfoque en ejemplos negativos (Bs en la Figura ??) en lugar de en ejemplos positivos ( sfAs en la Figura ??) (es decir, encontrar una explicación correcta para los ejemplos negativos y luego negar esa regla para obtener una explicación para los ejemplos positivos).

Como mencionamos en §8.2.4, indujimos un sesgo para comprender el concepto de la manera adecuada presentando primero los ejemplos positivos en la fase de aprendizaje y pidiéndoles que hicieran clic en los positivos en la fase de entrenamiento. Sin embargo, observamos que nueve participantes dieron explicaciones verbales coherentes con el enfoque en los ejemplos negativos. En esta prueba en particular, una interpretación inversa es problemática ya que la negación de una conjunción corresponde a una disyunción, y la negación de la disyunción a una conjunción (es decir,  $p \wedge q$  es lógicamente equivalente a  $\neg(\neg p \vee \neg q)$ ). Por lo tanto, un análisis más completo debe tener en cuenta las explicaciones

verbales de los participantes en esta prueba. Sin embargo, incluso considerando el peor escenario en el que estos 9 participantes fueran considerados originalmente como parte del grupo de ‘conjunción’ y ahora se consideren parte del grupo de ‘disyunción’, el sesgo de conjunción-disyunción sigue siendo significativo ( $P < 10^{-7}$ ). Por lo tanto, concluimos que, en este marco donde son posibles múltiples explicaciones dependiendo de las características enfocadas, existe un sesgo que favorece las explicaciones conjuntivas sobre las explicaciones disyuntivas.

### 8.3.2. Hipótesis II

La mayoría de los participantes entendieron el concepto en la Prueba 6 usando las mismas características  $\{p_7, p_8\}$  que se usaron para describir el concepto en la Prueba 5, incluso cuando la estructura lógica de la regla era exactamente la misma independientemente de prestar atención a  $\{p_7, p_8\}$  o  $\{p_3, p_4\}$ <sup>6</sup>. Para mostrar esto, estudiamos las elecciones de los participantes en la etapa de generalización de la Prueba 6 (consultar la Figura 8.9).

Supongamos que un participante está pensando en la regla  $\neg p_7 \wedge \neg p_8$ , por lo que solo está dirigiendo su atención a las características  $\{p_7, p_8\}$  mientras ignora las características  $\{p_3, p_4\}$ . Dado que se ignoran  $\{p_3, p_4\}$ , el participante debe marcar aquellos elementos en los que  $\{p_7, p_8\}$  está de acuerdo con la regla  $\neg p_7 \wedge \neg p_8$ , independientemente de los valores de  $\{p_3, p_4\}$ . Es decir, el participante debe marcar los elementos con  $\{p_3, p_4, p_7, p_8\}$  igual a  $(0, 0, \mathbf{0}, \mathbf{0})$ ,  $(1, 0, \mathbf{0}, \mathbf{0})$ ,  $(0, 1, \mathbf{0}, \mathbf{0})$  y  $(1, 1, \mathbf{0}, \mathbf{0})$ . Estos elementos tienen  $\{p_7, p_8\}$  igual a  $(0, 0)$  y ‘cualquier valor’ por  $\{p_3, p_4\}$ . Por otro lado, si el participante está pensando en la

---

<sup>6</sup>Como se esperaba en el diseño de nuestro experimento, 94 de los 100 participantes entendieron el concepto en la Prueba 5 usando las características  $\{p_7, p_8\}$  (6 características seleccionadas sin una justificación clara). Usar las características  $\{p_7, p_8\}$  es de hecho la única forma plausible de aprender el concepto, dada la alta complejidad de la fórmula alternativa MDL15.

regla  $p_3 \wedge \neg p_7 \wedge \neg p_8$ , entonces está atendiendo a  $\{p_3, p_7, p_8\}$ , y debe marcar  $(1, 0, \mathbf{0}, \mathbf{0})$  y  $(\mathbf{1}, 1, \mathbf{0}, \mathbf{0})$ .

En general, al estudiar cuál de los 7 ejemplos que se muestran en la Figura 8.9 (izquierda) selecciona el participante en la fase de generalización, podemos deducir qué características estaban atendiendo (Figura ??, derecha). Por ejemplo, todos los participantes deben marcar el ejemplo con  $\{p_3, p_4, p_7, p_8\}$  igual a  $(1, 1, 0, 0)$ , ya que es coherente con todas las reglas lógicas independientemente de las características son usadas.

En efecto, como se muestra en la Figura 8.9 (izquierda), todos los participantes seleccionaron este ejemplo. Aunque en la práctica el participante puede seleccionar cualquiera de los 7 ejemplos en la etapa de generalización, encontramos que todos menos cinco participantes respetaron las reglas de coherencia ilustradas en el párrafo anterior. Estos 5 participantes estaban ‘a un ejemplo de distancia’ de respetar la regla, sin embargo, los dejamos fuera del análisis de adherencia de características, pero haberlos incluido no habría cambiado nuestras conclusiones. También excluimos a 6 participantes que seleccionaron elementos sin una justificación clara en la prueba anterior, ya que es posible que no hayan utilizado las características  $\{p_7, p_8\}$ . Sin embargo, la inclusión de estos participantes (y asumiendo que usaron  $\{p_7, p_8\}$  en la prueba anterior) no cambia significativamente los resultados. En total, estas dos exclusiones dejan 89 participantes para este análisis. Las líneas grises en la Figura 8.9 (izquierda) muestran simulaciones de agentes que seleccionan aleatoriamente uno de los siete posibles subconjuntos de características, y luego proceden a seleccionar los ejemplos consistentes con la regla lógica usando esas características. Las respuestas de los participantes (línea negra) estaban sesgadas hacia las explicaciones usando  $\{p_7, p_8\}$ , como predijo el sesgo de adherencia de características. Esto también se puede ver en la Figura 8.9 (derecha), después de inferir qué características usaron los participantes para construir

la regla para el concepto. Además de estar sesgados hacia  $\{p_7, p_8\}$ , varios participantes explicaron el concepto utilizando todas las características disponibles  $\{p_3, p_4, p_7, p_8\}$ . Esto muestra que, además del sesgo de adherencia de características, cuando el número de características es relativamente pequeño, los participantes también están predispuestos a describir el concepto utilizando todas las características disponibles.

Para cuantificar el sesgo de adherencia de características, asignamos una puntuación a cada participante de acuerdo con las características atendidas en la Prueba 6 (deducida de los ejemplos marcados). Las puntuaciones de los subconjuntos  $\{p_7, p_8\}$ ,  $\{p_3, p_7, p_8\}$ ,  $\{p_4, p_7, p_8\}$ ,  $\{p_3, p_4, p_7, p_8\}$ ,  $\{p_3, p_4, p_7\}$ ,  $\{p_3, p_4, p_8\}$  y  $\{p_3, p_4\}$  son 1,  $2/3$ ,  $2/3$ ,  $1/2$ ,  $1/3$ ,  $1/3$  y 0 respectivamente<sup>7</sup>. El puntaje promedio para los 89 participantes fue  $0.68$  ( $P < 10^{-6}$  en una prueba de permutación con la hipótesis nula de atender al azar a uno de los siete subconjuntos de características, que corresponden a las líneas grises en la Figura 8.9), lo que indica un efecto significativo del sesgo de adherencia de la característica. Aunque el sesgo de adherencia de características fue significativo para ambos grupos de forma independiente (Grupo X: puntuación media  $0.62$ ,  $P < 10^{-5}$ ; Grupo Y: puntuación media  $0.74$ ,  $P < 10^{-6}$ ), encontraron que la adherencia de las características fue mayor en el Grupo Y (el t-test de dos muestras que compara las puntuaciones de los dos grupos muestra  $t = 2,35$ ,  $P < 0,05$ ). La única diferencia entre los grupos es que el Grupo Y ya había experimentado (artificialmente) la adherencia de las características entre las Pruebas 3 y 4 anteriores, por lo que ya lo identificaron como un sesgo útil para la tarea. Esto sugiere que toda la secuencia de aprendizaje de conceptos puede ser importante cuando se estudian los sesgos de aprendizaje.

---

<sup>7</sup>La parte (d) de la Plan de Análisis en nuestro pre-registro tenía un error en el uso de los nombres de las funciones: el concepto de aprendizaje correspondiente a la quinta prueba usa  $p_7$  y  $p_8$ , no  $p_3$  y  $p_4$  como está escrito erróneamente en esa parte; comparar con la sección sobre diseño del estudio, que coincide con la Tabla 8.1.

### 8.3.3. Hipótesis III

Esta hipótesis consideró la ventaja conductual del efecto de adherencia de características, que probamos comparando el tiempo de aprendizaje en la Prueba 4 para los participantes de los Grupos X versus Y (ver Figura 8.10). Si el sesgo de adherencia de la característica representa una ventaja de comportamiento, el Grupo Y debería aprender el concepto  $C_1^4$  más rápido que el Grupo X. Para evitar confusiones debido a diferencias inter-individuales en el tiempo absoluto de aprendizaje, para este análisis normalizamos el tiempo de aprendizaje individual con el tiempo invertido en la Prueba 5, que utiliza características diferentes a los conceptos anteriores y no debería verse afectado por ninguna relación obvia entre pruebas con conceptos anteriores<sup>8</sup>. Por lo tanto, comparamos entre los dos grupos (X e Y) el tiempo empleado en la Prueba 4 dividido el tiempo empleado en la Prueba 5. Esto da un número para cada participante, y comparamos las listas de números de los dos grupos usando un t-test de dos muestras. Las diferencias en los tiempos de aprendizaje entre los grupos no son significativas si analizamos los datos de todos los participantes, como se muestra en la Figura 8.10 (el t-test de dos muestras da  $t_{98} = 1,26$ ,  $P = 0,2$ ;  $d$  de Cohen = 0,25), pero sí son significativos si descartamos de este análisis 5 valores atípicos que gastaron más de 5 veces en el concepto 4 que en el 5, o en el concepto 5 que en el 4 ( $t_{98} = 2,18$ ,  $P < 0,05$ ,  $d$  de Cohen = 0,42)<sup>9</sup>.

---

<sup>8</sup>De hecho, la Prueba 5 fue pre-registrada como una prueba ‘normalizadora’.

<sup>9</sup>El ANOVA propuesto en el pre-registro tampoco reveló diferencias significativas en los tiempos de aprendizaje. Para simplificar el análisis de los valores atípicos, reemplazamos aquí el ANOVA por un t-test simple entre los tiempos de aprendizaje normalizados de los dos grupos.

### 8.3.4. Hipótesis IV

La idea de esta hipótesis es probar si, de una prueba a la siguiente, los participantes prefieren ceñirse a los operadores o ceñirse a las características. En este trabajo no encontramos evidencia concluyente sobre esta hipótesis. Sospechamos que la causa fue una configuración experimental que subestimó la fuerza del sesgo que favorecía al operador  $\wedge$  sobre el operador  $\vee$ . Encontramos que 77 de los 100 participantes explicaron la Prueba 1 usando  $\wedge$ , 11 lo explicaron usando  $\vee$  y 12 de ellos seleccionaron elementos en la fase de generalización sin una justificación clara. De los 77 que usaron  $\wedge$ , 64 también usaron  $\wedge$  en la Prueba 2, cambiando así las características pero manteniendo el operador; y 7 de ellos usaron  $\vee$ , cambiando de operador pero manteniendo las características (los otros 6 participantes seleccionaron elementos sin una justificación clara). De los 11 que usaron  $\vee$ , 10 usaron  $\wedge$  en la Prueba 2, cambiando de operador pero manteniendo las características; y 1 de ellos usó  $\vee$  en la segunda prueba. Sin embargo, nos damos cuenta de que un cambio de usar  $\vee$  en el primer concepto a  $\wedge$  en el segundo podría deberse no solo al efecto de la adherencia de las características, sino también simplemente a la preferencia más fuerte por  $\wedge$ . Por lo tanto, sin un conocimiento cuantitativo preciso de la preferencia previa de  $\wedge$  sobre  $\vee$ , no podemos concluir nada sobre el efecto de la adherencia del operador frente a la adherencia de la característica. Un experimento futuro podría probar la existencia de adherencia de operador al tener períodos consecutivos más largos donde la reutilización de características no es un sesgo útil y donde solo un operador lógico sigue siendo útil para explicar un concepto, antes de presentar finalmente un concepto que se puede explicar a través de dos reglas diferentes, cada uno usando diferentes operadores. De este modo, dejamos para el trabajo futuro la tarea de estudiar la interacción entre el sesgo de adherencia de características y la estructura precisa de las reglas lógicas que se están aprendiendo.

Santi: aca hay algo que podes mandar a una sección final en la tesis sobre trabajo futuro

### 8.3.5. El sesgo de MDL

La hipótesis del sesgo de MDL postula que la dificultad de aprendizaje de conceptos aumenta con su MDL [Feldman, 2000]. Además de sus otros roles, las Pruebas 3 (grupo X e Y), 4 y 5 sirvieron para probar esta hipótesis en el nuevo marco de múltiples explicaciones consistentes. En estas pruebas, hubo dos posibles explicaciones que eran consistentes con los datos mostrados, una de MDL mucho más alta que la otra (15 vs. 3). Por ejemplo, en el Grupo X de la Prueba 3, la explicación corta fue  $p_1 \wedge p_2$ , mientras que la más larga fue  $((p_3 \vee (p_4 \vee p_5)) \wedge (\neg p_3 \vee ((p_4 \vee \neg p_5) \wedge (p_5 \vee \neg p_4))))$ ; la regla más larga en otras pruebas fue siempre una sustitución de características aplicadas a este (para mantener las características disjuntas entre las dos explicaciones). Para estas 3 pruebas, las respuestas de los 100 participantes suman un total de 300 respuestas. De este total, las respuestas de 18 en la fase de generalización no eligieron objetos consistentes con ninguna de las dos explicaciones; 2 respuestas fueron consistentes con la regla de MDL 15; y 280 respuestas fueron consistentes con la regla de MDL 3. Si bien esto era lo esperable por el diseño experimental (dado que incluimos una regla de MDL 15 en aquellas pruebas en las que queríamos sesgar a los participantes para que encontraran la otra regla), concluimos que la hipótesis del sesgo de MDL se mantiene en este marco de múltiples explicaciones consistentes. Un trabajo futuro podría explorar con mayor detalle la dificultad relativa de las reglas con MDL ligeramente diferente en este marco.

Santi: idem

## 8.4. Discusión

En este trabajo, diseñamos un marco experimental en el que los participantes observan un conjunto incompleto de ejemplos, que son consistentes con dos descripciones mínimas

alternativas según las características que se observen. Ilustramos varias ventajas de nuestro método en comparación con la presentación por separado de conjuntos de ejemplos consistentes con solo una descripción mínima a la vez. Primero, mostramos que cuando un conjunto de ejemplos es consistente con una disyunción *y también* con una conjunción, es más probable que los participantes encuentren la conjunción, de acuerdo con resultados previos bien conocidos que muestran que la conjunción se aprende más rápido. que la disyunción cuando se presentan por separado [Bourne, 1970]. Luego, mostramos que cuando las reglas con MDL significativamente diferentes son consistentes con las observaciones, casi todos los participantes descubren las reglas más simples, consistentes con el resultado anterior que muestra que, cuando las reglas con MDL diferentes se testean por separado, los tiempos de aprendizaje son proporcionales a las MDLs [Feldman, 2000]. Finalmente, mostramos que cuando la estructura lógica de las reglas mínimas es independiente de las características seleccionadas, es más probable que los participantes reutilicen las mismas características usadas para describir conceptos anteriores, y los resultados preliminares sugieren que la reutilización de características les permite aprender conceptos más rápido que un grupo de control que no está reutilizando características. Hasta donde sabemos, este efecto no se ha caracterizado previamente en la literatura sobre el aprendizaje de conceptos, lo que se suma a la biblioteca de efectos que ilustran cómo la atención humana está sesgada hacia características que son útiles para describir los conceptos (ver [Blair et al., 2009, Kruschke and Blair, 2000, Kruschke et al., 2005, Hoffman and Rehder, 2010], entre otros).

Los estudios de seguimiento ocular (*eye tracking*) en las tareas de categorización han revelado que la atención a las características cambia rápidamente entre pruebas dependiendo de qué características son relevantes para la clasificación en cada ensayo [Blair et al., 2009],

así como según el conocimiento previo sobre la relevancia de las características [Kim and Rehder, 2011]. En [Kruschke et al., 2005] se encuentra que los movimientos oculares confirmaron que la atención se aprendió en el paradigma básico de inhibición aprendida, y en [Hoffman and Rehder, 2010] también se encontró que los movimientos oculares revelaron cómo un perfil de atención aprendido durante una primera fase de aprendizaje afectó una segunda fase. Nuestra configuración experimental nos permite probar una hipótesis complementaria posiblemente más simple: si todo lo demás permanece igual, los participantes están predispuestos a usar las mismas características que se usaron en el pasado. Es importante destacar que solo pudimos probar esta hipótesis gracias a nuestro marco, que nos permite presentar un conjunto de ejemplos consistentes con dos reglas de exactamente la misma estructura lógica, pero usando diferentes conjuntos de características. Luego, sin usar el seguimiento ocular, podemos recuperar qué regla aprendieron los participantes y, por lo tanto, a qué conjunto de características prestaron atención. Dado que los dos conjuntos de características explican los ejemplos usando exactamente la misma estructura lógica, explicar preferentemente el concepto usando un conjunto de características sobre el otro solo puede deberse a una preferencia sobre las características en sí mismas, y no una preferencia sobre estructuras lógicas alternativas.

Aunque algunas de las hipótesis que probamos están alineadas con el conocido efecto Einstellung, que establece que las soluciones adoptadas pueden obstaculizar las más simples al tratar de abordar problemas nuevos, nuestro entorno experimental es diferente a la prueba clásica de la jarra de agua (el ejemplo más comúnmente citado de un efecto Einstellung, donde los participantes necesitan descubrir cómo medir una cierta cantidad de agua usando tres jarras con capacidad diferente y fija) [Luchins, 1942] en dos direcciones. Primero, no condujimos el experimento para controlar y supervisar los aspectos a los que los

participantes deben prestar atención. Por el contrario, nuestro enfoque está en la *elección* de las características que demuestran ser útiles para aprender un concepto con más de una explicación racional. En segundo lugar, nuestro marco experimental es coherente con la hipótesis del lenguaje del pensamiento (LoT) [Fodor, 1975], que establece que la capacidad humana para describir conceptos —y, más generalmente, de todos los elementos del pensamiento— se basa en el uso de un lenguaje mental simbólico y combinatorio, y está específicamente concebido para manejar expresiones en lógica proposicional (pero expansible a otros lenguajes formales), que es el terreno donde se pueden formalizar las explicaciones racionales. Este enfoque nos permite tratar la noción de *característica* de una manera muy precisa.

Observamos que se pueden utilizar otros marcos además de LoT para nuestro experimento. Por ejemplo, consideremos las reglas de clasificación basadas en similitudes [?, ?], donde cada característica se multiplica por un peso y la regla de clasificación es una función de la suma de las características ponderadas, generalmente una función lineal con un límite de decisión suave [?]. En este marco, la fase de generalización determinaría cuál de los dos posibles límites de decisión fue utilizado por los participantes (ambos consistentes con los elementos observados en la fase de aprendizaje); y el efecto de adherencia de características se explicaría por la inercia de los valores de los pesos de un concepto al siguiente. Sin embargo, dos obstáculos en este marco nos hacen preferir el marco de LoT para las tareas de aprendizaje de conceptos booleanos. Primero, aunque una regla de clasificación lineal puede aprender fácilmente las conjunciones y disyunciones en nuestro experimento, las reglas de clasificación más complejas requerirían funciones no lineales de las características (por ejemplo, el o-exclusivo (XOR)). Para los límites no lineales, los valores de las ponderaciones que acompañan a las características pueden ser difíciles de interpretar,

Santi: esta parte de LoT seguramente se vaya porque vas a haber hablado mucho ya sobre esto en la intro.

ya que puede que ya no sea cierto que una ponderación más alta signifique una mayor importancia de las características. En contraste, en el marco de trabajo de LoT, las reglas de clasificación complejas se construyen de manera compositiva para acomodar conceptos de cualquier complejidad, y la importancia de las características siempre se puede modelar como la probabilidad de incluir una característica en una fórmula, independientemente de su complejidad. En segundo lugar, a diferencia de las reglas basadas en similitudes, el marco de LoT explica naturalmente cómo los humanos pueden construir explicaciones verbales para los conceptos aprendidos. De hecho, casi todos los participantes dieron explicaciones informales de conjunciones y disyunciones en la lógica proposicional después de aprender cada concepto (consultar los datos compartidos en línea para ver la lista de explicaciones verbales).

Otro fenómeno bien estudiado relacionado con nuestro trabajo es el *blocking* de Kamin, donde el aprendizaje de un estímulo B dado está *bloqueado* por el mero hecho de que fue precedido por un conjunto de estímulos A que ya se empareja con el resultado. Esto muestra que el sujeto aprendió que el estímulo B no era útil y, por lo tanto, ignora su atención en los eventos siguientes [Wagner, 1970, Mackintosh, 1975, Rescorla and Wagner, 1972]. Estudiado en humanos en [Chapman and Robbins, 1990, Arcediano et al., 1997, Kruschke and Blair, 2000] entre otros, nuestro trabajo se diferencia de estos enfoques en que nunca introducimos una etapa donde una característica A se expone intencionalmente en ausencia de B, con el fin de orientar la atención del participante.

Conjeturamos que la mayoría de los determinantes de primer orden de la dificultad del concepto subjetivo también se mantendrán de manera relativa en nuestra configuración de concepto dual, como el sesgo de MDL (para casos menos extremos que los evaluados en este trabajo)[Feldman, 2003] y el sesgo de la estructura jerárquica del aprendizaje por trans-

ferencia [Tano et al., 2020]. Es importante destacar que nuestra configuración experimental también permite probar directamente los efectos de dificultad subjetiva de segundo orden (por ejemplo, el concepto A se aprende más rápido si se presenta junto con el concepto B que con el concepto C), así como los efectos de aprendizaje de transferencia de segundo orden (por ejemplo, los participantes aprenden más rápidamente el concepto C si primero han observado el concepto A junto con B<sub>1</sub>, en comparación con A junto con B<sub>2</sub>). Creemos que un estudio sistemático de la dificultad de aprendizaje de conceptos con dos (o más) conceptos presentados al mismo tiempo en cada prueba puede abrir una nueva ventana a la dinámica de los mecanismos humanos de aprendizaje de conceptos. Por ejemplo, consideremos el estudio en [Piantadosi et al., 2016], donde los participantes aprenden gradualmente un concepto mientras simultáneamente seleccionan elementos que actualmente se creen que pertenecen a ese concepto. Aquí, los autores ajustan un modelo bayesiano de lenguaje a las elecciones de los participantes para ilustrar cómo la probabilidad posterior de las diferentes reglas en la gramática varió a lo largo del tiempo, para aproximar el orden en el que se aprenden las diferentes reglas. Por el contrario, utilizando nuestro entorno experimental podemos estimar directamente, sin modelos, la probabilidad de que cada regla se aprenda más rápido que otra. Uno simplemente necesita presentar conjuntamente (de una manera incompleta y mutuamente compatible) un conjunto de ejemplos consistentes con esas dos reglas mínimas, y luego medir la fracción de participantes que descubre cada regla.

Por lo general, los sesgos de aprendizaje de conceptos se han estudiado de manera aislada: el participante observa ejemplos indicados como dentro o fuera de un concepto *único*, y el experimentador evalúa su dificultad subjetiva para el participante. Aunque se han utilizado diferentes métodos para presentar el concepto al participante (por ejemplo, todos los elementos al mismo tiempo [Tano et al., 2020, Kemp, 2012] o pequeños conjuntos

de elementos presentados en serie [Piantadosi et al., 2016]), por lo que sabemos todos los estudios previos de aprendizaje de categorías han intentado evaluar un solo concepto a la vez. Aquí, presentamos un escenario lógico controlado para evaluar la dificultad relativa de dos conceptos presentados al mismo tiempo y bajo las mismas condiciones experimentales, y, de forma directa, nuestro marco podría generalizarse a más.

**Declaración de prácticas abiertas.** La metodología de este estudio, los procedimientos de recopilación de datos, el tamaño de la muestra, los criterios de exclusión y las hipótesis se registraron previamente en el Open Science Framework (OSF) antes de la recopilación y el análisis de datos, con el fin de garantizar la transparencia, la reproducibilidad y el rigor. El pre-registro de este estudio se puede encontrar en <https://osf.io/mgex3>. El experimento real presentado a los participantes, junto con todos los datos experimentales analizados, está disponible en línea en <https://osf.io/gtuwp/>.

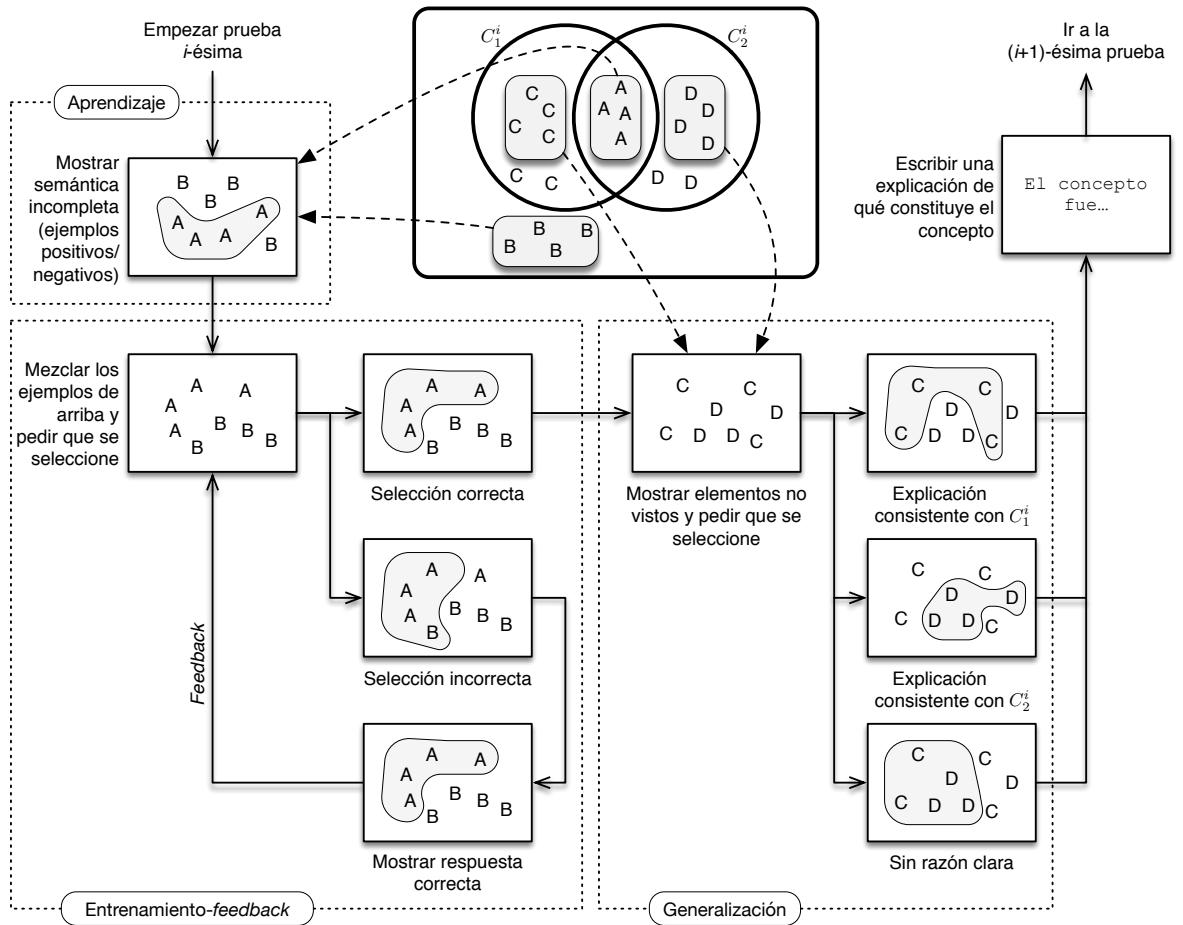


Figura 8.3: El esquema de nuestro marco experimental para estudiar el aprendizaje de conceptos en presencia de múltiples explicaciones. Ilustramos las tres fases que constituyen cada ensayo: fase de aprendizaje, fase de formación-feedback y fase de generalización. Los elementos se representan con las letras A, B, C y D (por ejemplo, las cuatro letras A en la intersección representan cuatro elementos diferentes en la intersección). El número representado de tales letras A, B, C o D es irrelevante (por ejemplo, habría 12 As y 4 Ds para los conceptos de la Figura 8.2).

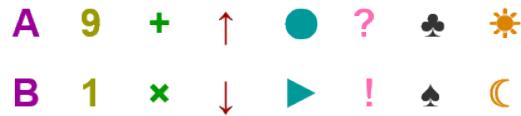


Figura 8.4: En la imagen de arriba se muestran las características, la representación visual de los valores positivos y negativos de las variables proposicionales. La fila superior representa valores positivos de las variables proposicionales, mientras que la fila inferior representa su negación.

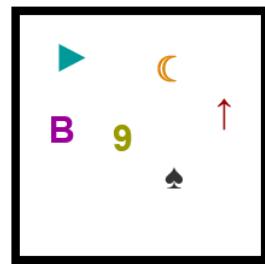


Figura 8.5: Un elemento. Esta caja que contiene características es la representación visual de una valuación sobre seis variables proposicionales. Aquí la caja aparece con un borde neutro, pero las cajas del experimento siempre aparecen con un borde que denota si son ejemplos positivos o negativos. La posición de los símbolos es irrelevante para los conceptos y se asigna al azar.

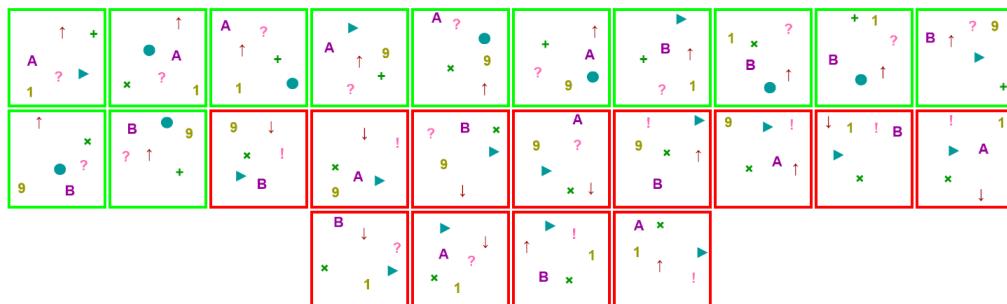


Figura 8.6: Una secuencia de ejemplos positivos y negativos en una etapa de aprendizaje, correspondiente a la Prueba 1. Un borde verde informa al participante que el elemento pertenece al concepto, mientras que un borde rojo informa que no pertenece al concepto. En este caso, los ejemplos podrían explicarse como ‘cajas que contienen una flecha que apunta hacia arriba y un signo de interrogación’ o como ‘cajas que contienen un círculo o un signo más’, pero hay que tener en cuenta que estas dos reglas determinan conceptos diferentes sobre el conjunto completo de posibles elementos.

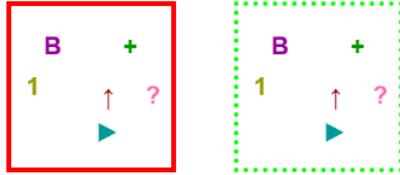


Figura 8.7: Un elemento no seleccionado, a la izquierda, está representado por bordes rojos sólidos. El mismo elemento en un estado seleccionado, a la derecha, se indica con bordes verdes punteados.

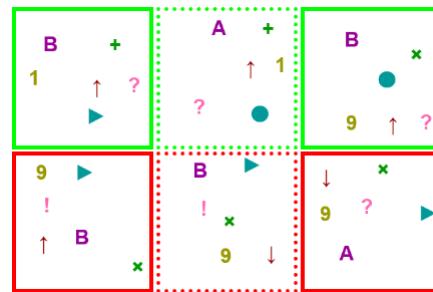


Figura 8.8: Una sección parcial del *feedback* resultante de una selección incorrecta. Un borde verde sólido significa que la casilla se seleccionó correctamente como perteneciente al concepto. Un borde rojo sólido significa que se dejó sin seleccionar correctamente, lo que significa que no pertenecía al concepto. Un borde verde punteado significa que la caja pertenecía al concepto pero no fue seleccionado, y un borde rojo punteado significa que la caja no pertenecía al concepto pero fue seleccionado.

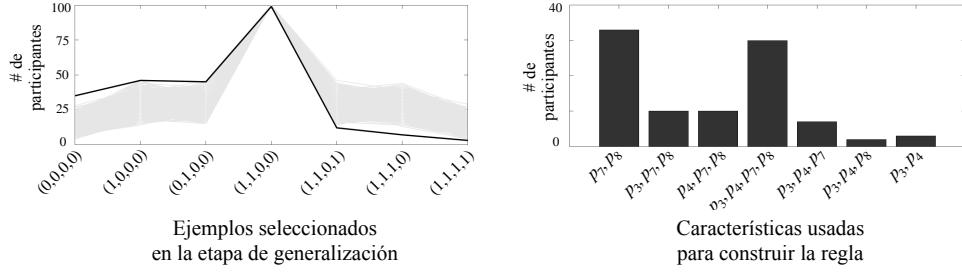


Figura 8.9: **(Izquierda)** Número de participantes (100 participantes en total) que, en la etapa de generalización de la Prueba 6, seleccionaron un elemento (posiblemente entre otros; los números suman más de 100) con los elementos escritos en el eje x, indicando los valores de las características  $\{p_3, p_4, p_7, p_8\}$  respectivamente. Como eran posibles múltiples opciones, la suma de todas las opciones suma un valor mayor que 100. En gris mostramos 100.000 simulaciones en las que 100 agentes atienden aleatoriamente a uno de los siete subconjuntos de características (ver texto). **(Derecha)** De los objetos seleccionados en la fase de generalización podemos inferir qué características usaron los participantes para construir la regla para el concepto (89 participantes válidos, ver texto principal).

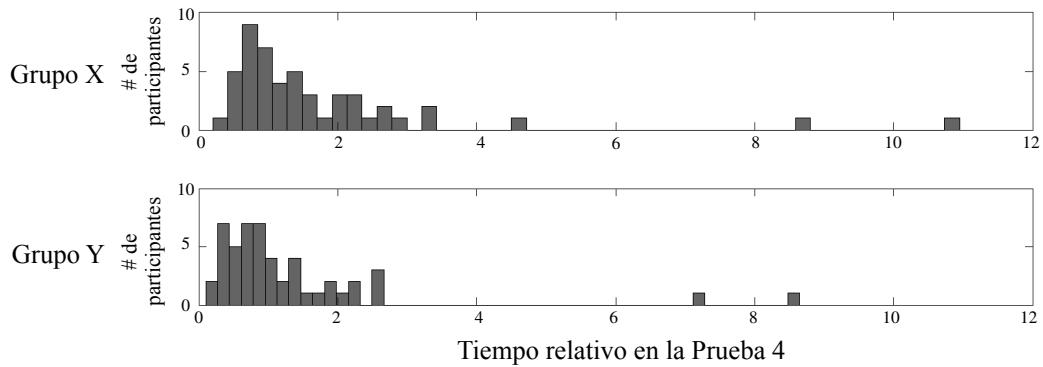


Figura 8.10: Tiempo relativo empleado en la Prueba 4 por los participantes de los dos grupos, normalizado por el tiempo empleado en la Prueba 5.

# **Capítulo 9**

**BORRAR: A theory of memory for  
binary sequences: Evidence for a mental  
compression algorithm in humans**

# **A theory of memory for binary sequences: Evidence for a mental compression algorithm in humans**

Samuel Planton<sup>1</sup>, Timo van Kerkoerle<sup>1</sup>, Leïla Abbih<sup>1</sup>, Maxime Maheu<sup>1,2</sup>, Florent Meyniel<sup>1</sup>, Mariano Sigman<sup>3,4,5</sup>, Liping Wang<sup>6</sup>, Santiago Figueira<sup>4,7</sup>, Sergio Romano<sup>4,7</sup>, Stanislas Dehaene<sup>1,8</sup>

<sup>1</sup> Cognitive Neuroimaging Unit, CEA, INSERM, Université Paris-Sud, Université Paris-Saclay, NeuroSpin center, 91191 Gif/Yvette, France

<sup>2</sup> Université de Paris, 75006 Paris, France

<sup>3</sup> Laboratorio de Neurociencia, Universidad Torcuato Di Tella, Buenos Aires, Argentina

<sup>4</sup> CONICET (Consejo Nacional de Investigaciones Científicas y Técnicas), Argentina

<sup>5</sup> Facultad de Lenguas y Educación, Universidad Nebrija, Madrid, Spain

<sup>6</sup> Institute of Neuroscience, Key Laboratory of Primate Neurobiology, CAS Center for Excellence in Brain Science and Intelligence Technology, Chinese Academy of Sciences, Shanghai, 200031, China

<sup>7</sup> Universidad de Buenos Aires. Facultad de Ciencias Exactas y Naturales. Departamento de Computación, Buenos Aires, Argentina

<sup>8</sup> Collège de France, 11 Place Marcelin Berthelot, 75005 Paris, France

Correspondence concerning this article should be addressed to Samuel Planton, Cognitive Neuroimaging Unit, CEA, INSERM, Université Paris-Sud, Université Paris-Saclay, NeuroSpin center, 91191 Gif/Yvette, France

Contact: [samuel.planton@cea.fr](mailto:samuel.planton@cea.fr)

## Abstract

The capacity to store information in working memory strongly depends upon the ability to recode the information in condensed form. Here, we tested the theory that human adults encode binary sequences of stimuli in memory using a recursive compression algorithm. The theory predicts that the psychological complexity of a given sequence should be proportional to the length of its shortest description in the proposed language, which can capture any nested pattern of repetitions and alternations. Five experiments examine the capacity of the theory to predict human adults' memory for a great variety of auditory and visual sequences. We used a sequence violation paradigm in which participants detected occasional violations in an otherwise fixed sequence. Both subjective complexity ratings and objective violation detection rates were well predicted by our theoretical measure of complexity. While a simpler transition-probability model accounted for significant variance in the data, the language model dominated over the transition probability model for long sequences whose number of elements far exceeded the limits of working memory. Model comparison also showed that shortest description length in a recursive language provides a better fit than a variety of previous encoding models for sequences. The data support the hypothesis that, beyond the extraction of statistical knowledge, human sequence coding relies on an internal compression using language-like nested structures.

## Keywords

Sequence processing; language of thought; complexity; novelty detection; statistical learning

Sequence processing, the ability to encode and represent in memory a temporally ordered series of discrete elements, plays a central role in numerous human activities, including language. In the 1950's, Karl Lashley (1951) and Noam Chomsky (Chomsky, 1957) famously argued that the sequential structures that humans can produce and remember cannot be viewed as mere associative links between consecutive item, but must be mentally represented as nested structures – the syntax of language, for instance, involves potentially unlimited embeddings of phrases within phrases. The goal of the present paper is to introduce a precise theory of sequence representation for the much simpler case of binary sequences, i.e. sequences informed by two elements A and B (e.g. high and low pitch, or red and green dots). We present experimental evidence that, even in this case, a similar postulation of nested structures is required in order to account for human memory performance.

Understanding how humans and other animals encode and represent temporal sequences has recently emerged as a crucial issue in the study of comparative cognition, as it allows a direct comparison between species (Dehaene et al., 2015; Wilson et al., 2017). Recursive phrase structures have been proposed to lie at the core of the human language faculty (Hauser et al., 2002), and a competence for nested trees has been postulated to underlie several other human cognitive abilities such as mathematics or music (Conway & Christiansen, 2001; Dehaene et al., 2015; Fitch, 2014; Hauser & Watumull, 2017). According to a recent review (Dehaene et al., 2015), non-human animals may encode sequences using a variety of encoding schemes, including transition probabilities, ordinal regularities (what comes first, second, etc.), recurring chunks, and algebraic patterns (Fujii, 2003; Jiang et al., 2018; Marcus et al., 1999; Wang et al., 2015; Wilson et al., 2013). However, several authors hypothesize that only humans have access to a language-like representation

of nested trees (Dehaene et al., 2015; Fitch, 2014), also being described as a “universal generative faculty” (Hauser & Watumull, 2017) or “language of thought” (Amalric et al., 2017; Fodor, 1975) capable of encoding arbitrarily nested rules.

Here we propose a precise language capable of encoding any arbitrary nesting of repetition and alternation structures, and we test the hypothesis that humans spontaneously encode sequences using the nested tree structures of this language. We do so using the simplest form of temporal sequences, namely binary sequences. Indeed, as opposed to more complex sequences, such as the ones of the natural language, which involve numerous factors that are difficult to properly control (prior knowledge, semantic content, word frequency, etc.), binary sequences allow to easily control the information content of the input. Furthermore, they are potentially accessible to a wide variety of populations beyond human adults, including infants and non-human primates. Finally, binary sequences are also widely used to study the cognitive processes and brain mechanisms involved in the perception of randomness and in statistical learning (Falk & Konold, 1997; Griffiths & Tenenbaum, 2003; Huettel et al., 2002; Maheu et al., 2019; Meyniel et al., 2016; Oskarsson et al., 2009). While minimal, they nevertheless preserve the possibility of forming structures at different hierarchical levels, from simple chunking to language-like rules, and thus of arbitrating between different models of sequence encoding.

# A short review of theories and experiments on sequence complexity

The concept of compression in working memory has a long history. Much research shows that human memory is not simply determined by the number of words, digits or locations that must be remembered, but also by their capacity to be “compressed” into a smaller number of known phrases, groups, or chunks (Brady et al., 2009; Chase & Ericsson, 1982; Cowan, 2001; Ericsson et al., 1980; Feldman, 2000; Gilchrist et al., 2008; Miller, 1956).

The apparent discrepancies between the different limits of working memory capacity proposed in the past, e.g.  $7 \pm 2$  items (Miller, 1956) versus 4 items (Baddeley & Hitch, 1974; Cowan, 2001) can indeed be reconciled if one takes into account the possibility of constituting chunks rather than encoding a complete series of individual items (Mathy & Feldman, 2012). The formation of chunks can be seen as a data compression process, and it was proposed that the complexity of a sequence can be defined as the size of its most compressed representation (Chater & Vitányi, 2003; E. L. Leeuwenberg, 1969; Mathy & Feldman, 2012; Simon, 1972).

Experimentally, half a century of behavioral studies have shown that accuracy in sequence encoding and production tasks varies according to the complexity or compressibility of the sequence. Glanzer and Clark (1963) already proposed to use the length of the most compact internal description of a sequence as a measure of its complexity. They found that the number of words that participants used to describe an array of eight symbols, each colored either in black or in white, was correlated with the accuracy in reproducing it. Such *mean verbalization length* (MVL) predicted behavior better than a simple count of the number of runs in the sequence (e.g. “AAABBBAA” has three runs), particularly

for the “ABABABAB” , which could be simply described as “alternating” .

Generalizing upon this early work, one may propose that the complexity of a sequence relates to the length of its compressed form when it is recoded using an internal language. Consistent with such idea, Restle and Brown (1970) showed that participants learned a series of 10 button presses, not as an associative chain of elements, but by encoding it as an abstract pattern, defined as the set of rules that were needed to generate it. The profile of errors suggested that participants represented the sequences as hierarchical trees of embedded rules (i.e., repetition, transposition, mirroring), equivalent to the tree structures found in language (Restle, 1970). The psychological reality of this proposal was strengthened by showing that performance decreased precisely at the boundaries of higher hierarchical level groups of elements (Restle, 1970, 1973; Restle & Brown, 1970). However, this approach was not developed into a full-blown universal language explaining how any sequence or pattern would be encoded.

A more formal approach for estimating the complexity of patterns, usually referred to as algorithmic complexity, program size complexity or *Kolmogorov complexity* (KC), was proposed by Kolmogorov (1965), Chaitin (1969) and Solomonoff (1964), within the framework of Algorithmic Information Theory. These mathematicians defined the complexity of a sequence as the length of the shortest computer program capable of producing it. Strictly speaking, the algorithmic complexity is defined relative to a specific descriptive language (or programming language). When this language is Turing complete –which means one can simulate any other Turing machine on it - we talk about the universal or plain KC. Unfortunately, since it is impossible to determine whether any Universal Turing machine will halt or not, KC is not computable. However, when the encoding language has reduced expressive power, the algorithmic complexity can be calculated and used as

a subjective measure of complexity even if it no longer implies a universal measure of complexity for any two sequences (Romano et al., 2013). Recently, the group of Gauvrit, Delahaye, Zenil and Soler-Toscano proposed an approximation to KC using the *coding theorem*, which relates the algorithmic complexity of a sequence to the probability that a universal machine outputs that sequence (Delahaye & Zenil, 2012; Gauvrit et al., 2014, 2016; Soler-Toscano et al., 2014). They provided algorithmic complexity measures for a large set of short sequences. This proposal was presented as the best approximation of “an ultimate measure of randomness” and appeared to predict the biases observed when individuals are asked to either judge the randomness of patterns or to produce random patterns (Gauvrit et al., 2014, 2016).

As an alternative to algorithmic complexity, Aksentijevic and Gibson (2012) proposed another measure of sequence complexity, based on the notion of “change” (the inverse of invariance), which they called *change complexity*. They argued that humans attend to the structural information conveyed by the transition from one element to the next, rather than the symbols themselves. Change complexity is thus computed by quantifying the average amount of change across all sub-sequences contained in a sequence. Aksentijevic and Gibson (2012) further show that their measure has interesting properties such as a sensitivity to periodicity and symmetries, and that it performs better than previously proposed measures in predicting objective behavioral performance and subjective complexity of sequences.

As stated above, a proposal tightly related to KC is that human subjects compress sequences internally, not necessarily using a set of instructions of a Turing-complete language, but using a variety of computer-like primitives such as for-loops, while-loops, and other routines forming a specific internal “language of thought” (Fodor, 1975), strong

enough to describe any sequence, but weak enough as to permit an explicit computation of KC. Such a language would allow the combination of simple primitives into complex embedded patterns or recursive rules. Language of thought (LoT) models have been proposed very early on (see Simon, 1972). Simon & Kotovsky (1963) used concepts such as “same”, “next” (on the alphabet), and the ability to cycle through a series, to build a formal representation of the human memory for sequences of letters (e.g. “cadaeafa...”). Similarly, Restle (1970) used the operations “repeat”, “transposition” and “mirror image”. Similar languages, based on repetitions with variations, were also used to encode linear geometric figures and more elaborated 2D and 3D shapes (Leeuwenberg, 1969; Leeuwenberg, 1971). More recently, similar proposals have been used with success to study different aspects of human learning, particularly concept learning (Feldman, 2000; Goodman et al., 2008, 2011; Piantadosi et al., 2012; Piantadosi & Jacobs, 2016; Siskind, 1996). Boolean complexity, i.e. the length of the shortest logical expression that captures the concept (a notion closely related to KC) was shown to closely capture human behavior (Feldman, 2000, 2003). Going beyond the pre-specification of a specific language, the LoT approach has also be used to specify which grammar and which set of primitive operations best captures the behavior of human subjects (e.g. Piantadosi et al., 2016; Romano et al., 2018).

## The proposed language for binary sequence

The development of a LoT model for sequence representation involves the selection of a set of rules or operations whose combination allows the (lossless) recoding of any given sequence. We introduce here a formal language for sequence processing as a variant of the

*language of geometry* previously introduced by our team to model human performance in the domain of spatial working memory (Amalric et al., 2017). In this previous study, human participants were presented with a sequence of eight locations on a regular octagon. Using both behavioral and brain-imaging data, we showed the necessity and adequacy of a computer-like language consisting of geometrical primitives of rotation and symmetry plus the ability to repeat them with various variations in starting point or symmetries (Al Roumi et al., 2020; Amalric et al., 2017; Romano et al., 2018; Wang et al., 2019). This language was shown to predict which sequences appear as regular, and how educated adults, uneducated Amazon Indians and young children performed in an explicit sequence completion task (Amalric et al., 2017) or in an implicit eye-tracking task (Wang et al., 2019). Sequence complexity, defined as minimal description length, also predicted human brain activation in a large cortical circuit including dorsolateral prefrontal cortex (Wang et al., 2019).

This language of geometry enables the generation of programs that can encode any sequence of spatial locations on an octagon. It uses primitive instructions or rules regarding the size and the direction of the next step (e.g.  $+1$  = next element clockwise;  $+2$  = second element clockwise), as well as the reflection over some axes (e.g. H = horizontal symmetry, picking the symmetrical location along a horizontal axis). Furthermore, these elements can be repeated, for instance  $+1^8$  describes a full clockwise turn around the octagon. Finally, those repetitions can be arbitrarily embedded. For instance, the expression  $\text{[[}+2\text{]}^4]^2<+1>$  first draws a square, as determined by the subexpression  $[+2]^4$ , then a second one with an offset of  $+1$  in the starting point (see Amalric et al., 2017, for a full formal description).

In the present study, we test the highly constrained hypothesis that the same language,

when reduced to only two locations, suffices to account for the human encoding of a completely different type of sequence, namely non-spatial binary sequences composed of only two arbitrary states A, B instead of the eight locations of the octagon. For such sequences, the language can be stripped of most of its primitives. We kept only the operations of staying (“+0” ) versus moving to the other item (“b” , i.e., the alternation instruction – or any specific symmetry in the original language), and the operation of repetition, possibly with a variation in the starting point. The language is thus able to encode any repetition of instructions in a compressed manner. The sequence “AAAA” , for instance, would be denoted  $[+0]^4$  (i.e., same state four times), the sequence “ABAB” would be denoted  $[+0]^4< b >$  (i.e., alternations from the initial state four times). The language is recursive and can produce nested descriptions, for instance “AABAAB” can be described as “two repetitions of [two repetitions plus one change]” (see example Figure 1A). Because of recursion, even long sequences can be encoded compactly in an easy-to-remember form, for instance “ABABBBBBBBBABABABBBBBB” is “2 times [5 alternations and 5 repetitions]” . The code is available online at <https://github.com/sromano/language-of-geometry>.

Given this language of thought, for each sequence, one can find the simplest expression that describes it, and its associated complexity (analogous to KC). Complexity is calculated by adding a fixed cost for each primitive instruction +0 and b. As in our previous work (Amalric et al., 2017), the additional cost for repeating an instruction  $n$  times is assumed to correspond to  $\log_{10}(n)$  (rounded up), i.e. the number of digits needed to encode the number in decimal notation. The relative value of those two costs is such that even a single repetition compresses an expression:  $+0^2$  is assumed to be more compressed than the mere concatenation of  $+0 +0$  (see supporting information in Amalric et al., 2017,

for details). As a result, the language favors an abstract description of sequences based on the maximum amount of nested repetitions, thus sharply dissociating sequence length and complexity. Among the multiple expressions that can describe the same sequence, the expression with the lowest complexity is considered to correspond to the human mental representation of the sequence. In a nutshell, the assumption is that, in order to minimize memory load, participants mentally compress the sequence structure using the proposed formal language.

## Probing memory for sequences: The sequence violation paradigm

In preparation for future experiments involving infants or non-human animals, it is useful to probe sequence processing using a paradigm that does not require language skills, nor explicit production of responses. A classic approach consists in introducing rare violations in an otherwise regular sequential input. At the most elementary level, in the *oddball* paradigm, the simple repetition of an auditory or visual stimulus with a regular timing suffices for the brain to generate expectations, such that the unexpected violation of this regularity, by suddenly replacing the stimulus by a different one, gives rise to an automatic surprise or novelty response. Such a surprise effect can be detected behaviorally, e.g. using an explicit detection, a pupillary response, or electrophysiological signatures including the mismatch negativity (Garrido et al., 2009; Näätänen, 2003; Squires et al., 1975) and it has been successfully used in non-human primates (e.g. Gil-da-Costa et al., 2013; Uhrig et al., 2014; Wilson et al., 2017).

A more complex brain response to novelty arises in the local/global paradigm (Bekinschtein et al., 2009; Wacongne et al., 2011), which contrasts two levels of violation: a local one, when a B stimulus follows a series of As (as in “AAAAB” ); and a global one where, at a higher hierarchical level, the habitual sequence (e.g. “AAAAB” repeated multiple times) is replaced by a difference sequence (e.g. “AAAAA” ). The use of this paradigm with neuroimaging made it for instance possible to show that macaques tend to spontaneously encode simple sequential patterns, using a cerebral network similar to the one in humans (Chao et al., 2018; Uhrig et al., 2014; Wang et al., 2015), or that such ability is already present in human infants (Basirat et al., 2014). It was also successfully used to show, with asleep participants or unconscious patients, that the processing of auditory sequential inputs at the global level (i.e., the level of patterns) is mainly restricted to conscious processing (Bekinschtein et al., 2009; Faugeras et al., 2011; Strauss et al., 2015). Behavioral and hemodynamic novelty responses to violations were also used by Huettel et al. (2002) to show that human adults spontaneously encoded simple repeating and alternating patterns, and that their response times and fMRI frontal activity patterns varied when such a local pattern was violated. Interestingly, the strength of the novelty response observed when the pattern was broken, was proportional to the length of the preceding pattern, suggesting that the novelty response may perhaps track sequence complexity.

Here, we test the hypothesis that the violation detection task can be used to probe the encoding of sequences of higher level of complexity, thus revealing their degree of psychological regularity and give an insight into the internal language of thought used to encode them. While we focus on explicit behavioral responses in a violation detection task, we do this with the aim of paving the way to future studies using non-verbal subjects or using

brain measures of implicit violation detection.

## Statistical learning in sequence processing

A language of thought is by no means the only way to encode binary sequences. At a lower level of abstraction, the detection of sequential structures in the environment may involve the identification of statistical regularities in the frequencies of events or the transitions between them (Dehaene et al., 2015; Maheu et al., 2019). Even in the language domain, transition probabilities are known to play an important role. Eight-month-old infants have for instance been shown to rely on transition probabilities between syllables in order to segment a continuous stream of syllables into distinct words (Romberg & Saffran, 2010; Saffran et al., 1996). Transition probability learning, revealed by the observation of a novelty response to an improbable event, was also reported in the visual modality (Abla & Okanoya, 2009; Kirkham et al., 2002), as well as in non-human primates (Hauser et al., 2001; Meyer & Olson, 2011). This process appears to be automatic and continues to operate under non-conscious conditions (Bekinschtein et al., 2009; Faugeras et al., 2011; Strauss et al., 2015). When using the novelty effect as an indicator of sequence complexity, it is therefore essential to separate the respective contributions of statistical learning and of a putative language of thought.

Computational models relying on probabilistic inference have been proposed for statistical learning. Mars et al., (2008) for instance showed that the trial-by-trial modulation of the amplitude of the P300 (an event-related potential response associated with unexpected events) could be explained by a model tracking the frequency of occurrence of items (among 4) in a temporal sequence. Similarly, our team proposed a Bayesian model for

the acquisition of transition probabilities (not simply item frequency), and showed that it could explain a great variety of different behavioral and brain observations in binary sequence processing experiments (Maheu et al., 2019; Meyniel et al., 2016). The degree of confidence in a prediction can furthermore be predicted using such computational approach (Meyniel & Dehaene, 2017). In these models, Shannon surprise, a mathematical measure of the improbability of an event considering past events (the negative log probability of events) (Friston, 2010; Shannon, 1948; Strange et al., 2005), is considered a good predictor of behavioral and neural responses.

In summary, prior research indicates that, at a minimum, two distinct systems may underlie sequence learning in the human brain: statistical versus rule-based learning (Bekinschtein et al., 2009; Dehaene et al., 2015; Maheu et al., 2020). What is unknown is whether they operate independently and whether one is privileged at the expense of the other depending on the nature of the information to be encoded. We argue that any attempt to uncover the specific cognitive mechanisms behind rule learning in humans, especially in comparison with other species, must take into account the contribution of the less abstract yet powerful prediction system based on the statistical properties of events.

## The current study

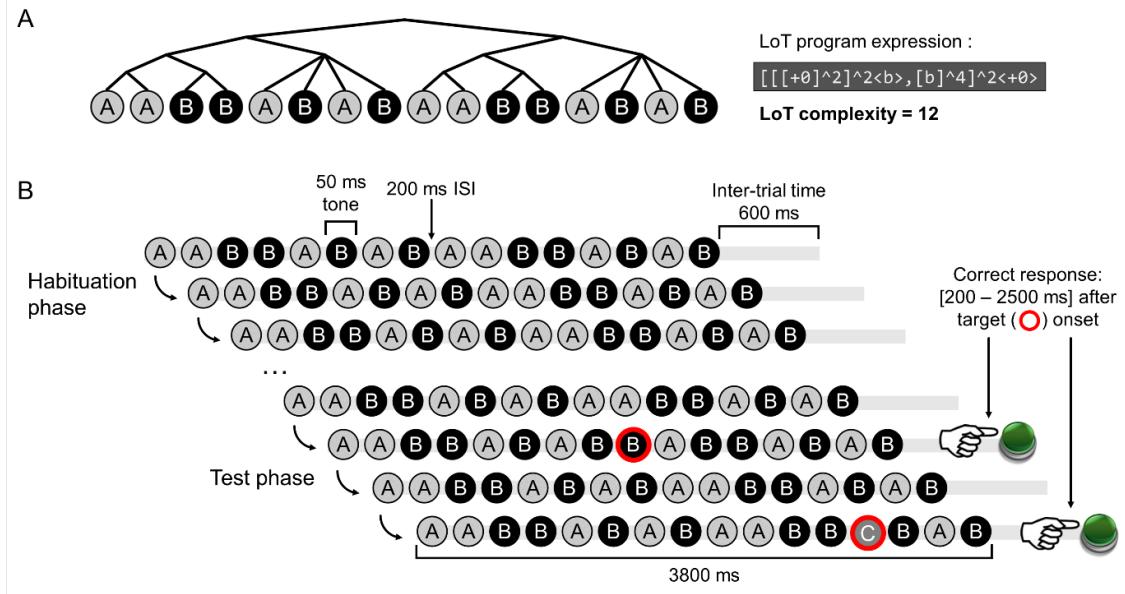
Our hypothesis is that, when confronted with a sequential input, individuals tend to spontaneously recode the sequence in an abstract form, using an internal “language of thought” composed of a limited set of simple rules that can be hierarchically embedded. To test this hypothesis, we conducted a series of behavioral experiments in which participants were asked to listen to short auditory binary sequences (alternations of a sound “A” and

a sound “B” ), whose statistical properties and predicted complexity varied. Learning was assessed by examining the capacity of participants to detect rare violations of the learned sequence (i.e. when one tone was replaced by the other). Our hypothesis was that, for equal sequence length, error rate and response time in violation detection would increase in parallel with sequence complexity. In some experiments, in addition to those objective indices of complexity, we also asked participants to report subjective rating of complexity. Finally, in one experiment, we also compared auditory and visual sequences to test whether our findings were dependent on the sensory modality.

For analysis, we examined if the results correlated with the shortest description length in the proposed language of thought (hereafter called LoT complexity to distinguish it from other complexity measures). To separate rule-based and statistical learning, we compared LoT complexity and surprise as predictors of performance. We also compare LoT complexity with other computational approaches to sequence complexity. We started with long sequences of 16 items (experiment 1), and then probed the adequacy of the proposed language to shorter sequences (experiments 2-5). A simple prediction is that shorter sequences are more likely to be stored in a verbatim representation in working memory, without any internal compression. Thus, we predicted that the effect of LoT complexity in the proposed language of thought would decrease as the sequence gets shorter. On the other hand, given the automaticity of statistical learning, we did not expect any difference in its contribution to long versus short sequences.

## Experiment 1: auditory sequences with 16 items

In experiment 1, we selected 10 auditory sequences of 16 items, a number that vastly exceeds working memory capacity, which is typically between 4 to 9 items (Cowan, 2001, 2010; Miller, 1956). All sequences had equal numbers of sounds A and B (to reduce confounds related to the relative probability of As and Bs), yet they varied widely in LoT complexity (see Figure 2). We obtained a subjective measure of complexity as well as objective measures of complexity based on the response to occasional violations. Two types of violations were introduced: sequence deviants in which an A was replaced by a B or vice-versa; and “super-deviants”, in which an A or B was replaced by a rare novel tone C (see Figure 1B). We predicted that the detection of sequence deviants would be affected by sequence complexity, since responding to them required the detection of a discrepancy between the observed and the predicted stimuli, and such a prediction would be more difficult for more complex sequences. Super-deviants were not expected to yield a complexity effect, however, since they deviated from other stimuli at the most basic stimulus-frequency level. Super-deviants stimuli were introduced in an effort to ensure an invariant task which would equalize level of attention in all blocks, regardless of sequence complexity.



**Figure 1:** (A) Example of a 16-items long sequential pattern, with its shortest representation in the language of thought (i.e. LoT program expression) and the tree-structure derived from this expression (illustrating the hierarchical representation). The LoT complexity of this sequence is also indicated. (B) Experimental design of the violation detection task: a session with the sequence “AABBABABAABBABAB” is represented, with one example of a target sequence deviant item (“A” replaced by “B”, at position 9) and one example of a target super-deviant item (“C” at position 13) (deviants could occur at positions 9, 11, 13 or 15).

## Method

### Participants

Twenty-eight healthy volunteers ( $M_{age} = 24.3$ ,  $SD = 3.2$ , 16 women) participated in the current experiment. They all gave written consent to participate and were paid for their participation. All participants performed the subjective complexity rating task. Due to time constraints, 7 of them performed only 6 out of the 10 independent short sessions of deviance detection.

## Stimuli

Auditory binary sequences were composed of an alternation of two different tones; low pitch and high pitch. Each stimulus was a complex tone synthesized with the superimposition of four sine waves. Sound frequencies were chosen to correspond to musical notes: 494, 740, 988 and 1480Hz (i.e., B, F#, B, F#) for the lower pitch tone, and 622, 932, 1245 and 1865Hz (i.e., D#, Bb, D#, Bb) for the higher pitch tone. The two complex tones were randomly assigned to items A and B (i.e., the two elements composing the binary sequential patterns) for each experimental session. Thus, stimulus attribution changed from one sequence to the next and from one participant to the next but was kept constant for a given sequence in a given participant. In addition, one lower pitch tone (415, 622, 831 and 1245Hz) and one higher pitch tone (740, 1109, 1480 and 2217Hz) were synthesized, to be used as easy-to-detect super-deviant (or C) stimuli. All tones were 50 ms long, with 5 ms initial and final ramp. Inter-stimulus interval (ISI) was 200 ms. Total sequence duration was 3800 ms.

Ten sequences were chosen (see Figure 2), which were all composed of the same number of items (8 As, 8 Bs). The first four sequences, of lowest complexity, followed the simple algebraic pattern  $(A^nB^n)^x$ :  $(AB)^8$ ,  $(A^2B^2)^4$ ,  $(A^4B^4)^2$  and  $A^8B^8$ . The period of these sequences differed (2, 4, 8 and 16 tones), but the complexity was identical (LoT complexity = 6). The other 6 sequences had LoT complexity values ranging from 12 to 23. Half of them were periodic (period of 8).

LoT complexity
(A A A A A A A A A B B B B B B B B) 6
(A A A A B B B B A A A A B B B B) 6
(A A B B A A B B A A B B A A B B) 6
(A B A B A B A B A B A B A B A B) 6
(A A B B A B A B A A B B A B A B) 12
(A B A A B B A B A B A A B B A B A B) 13
(A A A A B B B B A A A B B A B A B) 14
(A A A B B A B B A A A A B B A B A B) 15
(A A A A B B A B A B A B A A B B B B) 17
(A B A A A B B B A B B A B B A A A B) 23

**Figure 2:** Ten 16-items long sequential patterns used in Experiment 1, with their corresponding LoT complexity value.

## Procedure

Participants were seated in front of a computer in a quiet room and were wearing headphones. Stimuli were delivered using the Psychophysics Toolbox 3 (Brainard & Vision, 1997; Kleiner et al., 2007) running on Matlab R2016a (Mathworks Inc., Natick, MA, USA). Before starting the experiment, participants listened to a sample of the stimuli (different sequences from the ones used in the main experiment) and the sound volume was adjusted if necessary.

In the first part of the experiment, participants performed the complexity rating task. They were asked to judge each sequence on a scale going from “1: very simple” to “9: very complex”, by pressing the corresponding key on the keyboard just after sequence presentation. A response was requested at each trial. Each of the ten sequences was presented three times, in a pseudo-random order (30 trials). The low-pitch and high-pitch tone were randomly assigned to either A and B or to B and A at each presentation.

In the second part, the violation detection task, each of the ten sequences was tested

in a different short session of approximately 4 min (Figure 1B). Order of sessions was randomized for each participant. Each session comprised three blocks separated by pauses and in which the sequence (3800 ms long) was repeatedly presented with a 600 ms inter-trial duration. In the first block, the habituation block, the unaltered sequence was presented eight times. Participants were asked to listen to the stimuli and try to remember the sequence. In the two following blocks, the testing blocks, participants were asked to respond whenever they detected that the sequence had been altered (one deviant tone), by pressing the space key of the keyboard as quickly as possible (without necessarily waiting until the end of sequence presentation). Each of the two test blocks comprised 18 sequences, 9 of them containing one deviant tone (among the sixteen tones composing the sequence). Two-thirds of the deviant sequences were produced by replacing a tone A by a tone B, or conversely (“sequence deviant” tones, 12 trials per session). The remaining third were obtained by replacing one tone by a low or high-pitch C sound (“super-deviant” tone, 6 trials per session). Deviant tones could occur at only four, equally probable, positions within the second half of the sequence (positions 9, 11, 13 or 15).

## Data analysis

The responses collected in the complexity rating task, ranging from 1 to 9, were normalized for each participant using a *z*-score transformation of the raw ratings within each participant. An average complexity rating was computed for each sequence and subject and entered into a mixed effect model with participant as random factor and LoT complexity value as a fixed effect predictor. Here and in following mixed effect analyses, similar results were obtained using classical repeated-measures ANOVAs with participants as the random factor.

For the violation detection task, a button press occurring between 200 and 2500 ms after deviant stimulus onset was considered a hit (i.e. correct response). An absence of response during this interval was counted as a miss. False alarms were collected and analyzed separately (using a simple linear regression analysis with the LoT complexity predictor). Note that participants were not aware of the number or frequency of targets, and could respond at any time. Thus, only the number of false alarms, rather than a ratio depending on the number of trials, was relevant. The Linear Integrated Speed-Accuracy Score (LISAS) (Vandierendonck, 2017, 2018), an integrated measure of response times and error rates, was used as the main indicator of performance (results with response times and miss rates were quite convergent and are provided in supplementary materials). This score was computed for each sequence, each deviant type in each subject, according to the following formula:  $= RT_c + MR \times \frac{S_{RT}}{S_{MR}}$ , where  $RT_c$  refers to the average response time (of correct responses),  $MR$  to the miss rate,  $S_{RT}$  to participant's overall  $RT$  standard deviation and  $S_{MR}$  to the participant's overall  $MR$  standard deviation. These scores were computed after removing extreme response times (2.5 standard deviations ( $SD$ ) above or below the median in each condition and subject, 2.0% of data). Participants with excessive average miss rate over the entire session (i.e. 2.5  $SD$  above group median), average response time and/or average number of false alarms were excluded (three participants). All data analyzes were performed in R 3.6.0 (R Core Team, 2017).

We performed statistical analyses using a mixed model in which the dependent variable was the LISAS within each participant and each cell of the design, participants were the random factor, and LoT complexity and deviant type (sequence deviants vs. super-deviant) were fixed factors. To clarify the interactions, we also computed the same mixed effect model after restricting the data to each deviant type. All computations were per-

formed using the lme4 (Bates et al., 2015) and lmerTest (Kuznetsova et al., 2017) packages. P-values for each factor were obtained using Kenward-Roger approximation for degrees of freedom (Kenward & Roger, 1997).

Since statistical trends were also expected to play a role in how participants react to deviant stimuli, another predictor, distinct from LoT complexity, was constructed. We used Shannon surprise, defined as the negative log-probability of the likelihood of an observation (Friston, 2010; Meyniel et al., 2016; Meyniel & Dehaene, 2017; Shannon, 1948; Strange et al., 2005), to characterize how unexpected a deviant stimulus would be for an observer that tracks transition probabilities of the original sequence; for binary sequences:  $p(A| A) = 1 - p(B| A)$  and  $p(A| B) = 1 - p(B| B)$ . Since the sequence was considered to be learnt after the habituation phase, fixed probabilities were used (rather than evolving on a trial-by-trial basis based on a recent time window, as used for instance by Maheu et al., 2019, 2020; Meyniel et al., 2016). For instance, in the  $A^8B^8$  sequence,  $p(A| A)$  has a probability of 0.875 in the original sequence. Thus, the corresponding surprise of getting an A instead of a B at the 9<sup>th</sup> position is low ( $-\log_2(0.875) \approx 0.18\text{bit}$ ). In the same sequence,  $p(A| B) = 0$  (since B is always followed by another B), and therefore the surprise of getting an A instead of a B at, say, the 11<sup>th</sup> position, is maximal. To avoid an infinite when computing surprise, probabilities of 0 were replaced by a small but non-zero probability of  $p = 0.01$ , capping the maximum surprise value at around 6.64 bits. To test whether this would affect our conclusions, complementary analyses were also conducted while excluding deviants with such zero probability. Note that, contrary to the LoT complexity, which is identical whatever the position of the deviant, surprise varies with deviant location in the sequence (up to four different values in one given block). Analyses comparing the surprise and LoT complexity predictors were performed using the

same mixed model as above, including participants as random effects. To compare pair of models, we used likelihood ratio combined with chi-square statistical tests. When more than 2 models were involved, we computed the Akaike information criterion for each model (Akaike, 1998). Note that both methods penalize for model complexity (i.e. the number of predictors included in the regression), which varies depending on whether, or not, LoT complexity was included in addition to Shannon surprise (see above). Super-deviant trials were not included in these analyses.

In addition to those mixed effect statistics, we also report the results of simple regression analyses, which provide a summary view of the Pearson correlation coefficient  $r$  between LoT complexity and either subjective complexity ratings or the LISAS for each sequence, after averaging across participants (this is the  $r$  value reported in the figures). Supplementary figures provide this statistic for RTs and miss rates.

## Results and discussion

### Complexity rating task

We observed a strong positive linear relationship between the average subjective complexity ratings and the LoT complexity ( $t(278) = 24.6$ ,  $p < .0001$ ; Pearson correlation coefficient on the average ratings for each sequence,  $r = .94$ ) (see Figure 3A). These results indicate that participants were readily able to judge whether a pattern is “more complex” than another, and that the formal language we used to compute sequence complexity is close to how individuals form such complexity judgements.

## Deviant type and complexity effects in the violation detection task

We observed a linear relationship of LoT complexity and performance in the violation detection task (using LISAS). We observed main effects of LoT complexity ( $t(415.0) = 18.1$ ,  $p < .0001$ ), deviant type (994 ms for sequence deviants vs. 570 ms for super-deviants;  $t(414.4) = 18.9$ ,  $p < .0001$ ) and their interaction ( $t(414.5) = 11.7$ ,  $p < .0001$ ). Indeed, the slope of the complexity effect was significantly stronger, by an order of magnitude, for sequence deviants as opposed to super-deviants (respectively +51 ms vs. +5 ms in simple regression,  $t(16) = 11.7$ ,  $p < .0001$ ; see Figure 3B, and Figure S1 for the corresponding results using response times or miss rate instead of LISAS). Nevertheless, separate analyses revealed that LoT complexity was a strong predictor of performance for sequence deviants ( $t(193.0) = 15.5$ ,  $p < .0001$ ;  $r = .98$ ) and also, surprisingly, for super-deviants ( $t(198.5) = 4.08$ ,  $p < .0001$ ;  $r = .72$ ) (Figure 3B). The latter effect on LISAS was however mainly driven by response times, since the average hit-rate for super-deviants was high (96%) and weakly modulated by LoT complexity ( $t(200.7) = 2.32$ ,  $p < .03$ ).

The number of false alarms per sequence (which was 1.99 on average) also increased with sequence LoT complexity ( $t(214.4) = 4.20$ ,  $p < .0001$ ;  $r = .74$ ), suggesting here again that the LoT complexity was a good predictor of the quality of sequence encoding.

The results of this first experiment with long binary auditory sequences (16 items) thus indicate that the formal language used to describe sequences in a compressed form, based on simple (possibly embedded) rules, is highly relevant to predict (1) how “complex” an auditory sequence is judged by adult participants after having listened to it once and (2) how difficult it was to learn these sequences in order to detect alterations.

Sequence complexity was expected to have little or no impact on the detection of super-

deviants, i.e. high-pitch or low-pitch tones different from the two tones composing the binary auditory sequence. Our rationale was that such “C” tones were detectable even without any prior knowledge of sequence structure. While performance in detecting super-deviants was much better than for sequence deviants, even for the simplest sequences, a clear relationship between LoT complexity and performance continued to be observed. We see at least two interpretations of this finding. First, there could be an increased attentional cost of having to detect violations in more complex sequences, thus placing subjects in a dual-task setting of having to simultaneously maintain a complex representation in memory and to respond to deviants. Alternatively, the effect could reflect the influence of a top-down prediction system which would use sequence structure to generate predictions of the incoming stimuli. Complex sequences would be less well predicted, and this would in turn affect the speed with which any deviant is detected. We return to this question in the *General Discussion*.

## Surprise effects

Many prior experiments, using either or both behavior and brain-imaging measures, have shown that individuals constantly entertain predictions about future observations using probabilistic knowledge based on past observations (e.g. Maheu et al., 2019; Meyniel et al., 2016). In order to test whether task performance could be explained by transition probabilities (surprise) or also implied an encoding of sequence structure, a mixed model (with participants as a random effect) including fixed effects of both LoT complexity and surprise (averaged across the 4 possible positions of deviants in a given sequence) was compared to a null model including only the latter. The effect of surprise in the null model with surprise alone was significant ( $t(193.0) = 5.31$ ,  $p < .0001$ ). However, a likelihood

ratio test showed that adding LoT complexity significantly improved the goodness of fit:  $\chi^2(1) = 130.9$ ,  $p < .0001$ . Adding a “period” factor (i.e., period values were 2, 4, 8 or 16) did not improve the model fit ( $\chi^2(1) = 1.23$ ,  $p = .27$ ), confirming the prediction that the four included  $A^nB^n$  patterns have the same psychological complexity, and suggesting that this information is already captured by LoT complexity. Adding the interaction between surprise and LoT complexity did not improve goodness of fit either ( $\chi^2(1) = 2.50$ ,  $p = .11$ ). As reported in Table 1, the LoT complexity fixed effect was significant in the final full model ( $t(192.4) = 13.6$ ,  $p < .0001$ ), but not the surprise fixed effect ( $t(191.8) = 0.60$ ,  $p = .55$ ). The absence of a significant effect of surprise once sequence complexity is taken into account reflects the existence of a small correlation between the two measures ( $r = -.54$ ), biased transition probabilities in less complex sequences tending to make deviants more easily surprising. It also shows that when these two slightly colinear factors are included, LoT is more effective than surprise describing the variance of the data.

As our choice of attributing an arbitrary padding value (0.01) to deviant transitions events with zero probability when computing surprise may have biased the results, we recomputed the LISAS and average surprise while excluding all such trials (i.e. all deviant positions in the  $(AB)^8$  pattern, 3 out of 4 deviant positions in the  $A^8B^8$  pattern). Here again, a likelihood ratio test showed that the goodness of fit increased significantly when adding LoT complexity to a null model containing only surprise ( $\chi^2(1) = 116.3$ ,  $p < .0001$ ). However, both complexity ( $t(165.5) = 12.9$ ,  $p < .0001$ ) and surprise ( $t(165.8) = 3.82$ ,  $p < .0001$ ) were significant with this subset of the data.

In conclusion, the strong complexity effects observed here indicated that participants used some form of compression of information to encode the sequence and perform the task over and above statistical information. Although no instruction was given in that sense,

this strategy may be needed in order to deal with a difficult, memory-demanding task. Indeed, at the maximum level of complexity used, performance in violation detection was very low (the violation detection rate dropped to 41% for sequence deviants). In the subsequent experiments, we asked whether similar complexity effects emerged using the same paradigm with shorter sequences; when the sequence can be more easily encoded and stored “as a whole”, without necessarily requiring a re-encoding in a more abstract, compressed form. In these less demanding conditions, it can be expected that the spontaneous encoding of transitions probabilities between items will play a more important role in the detection of violations.

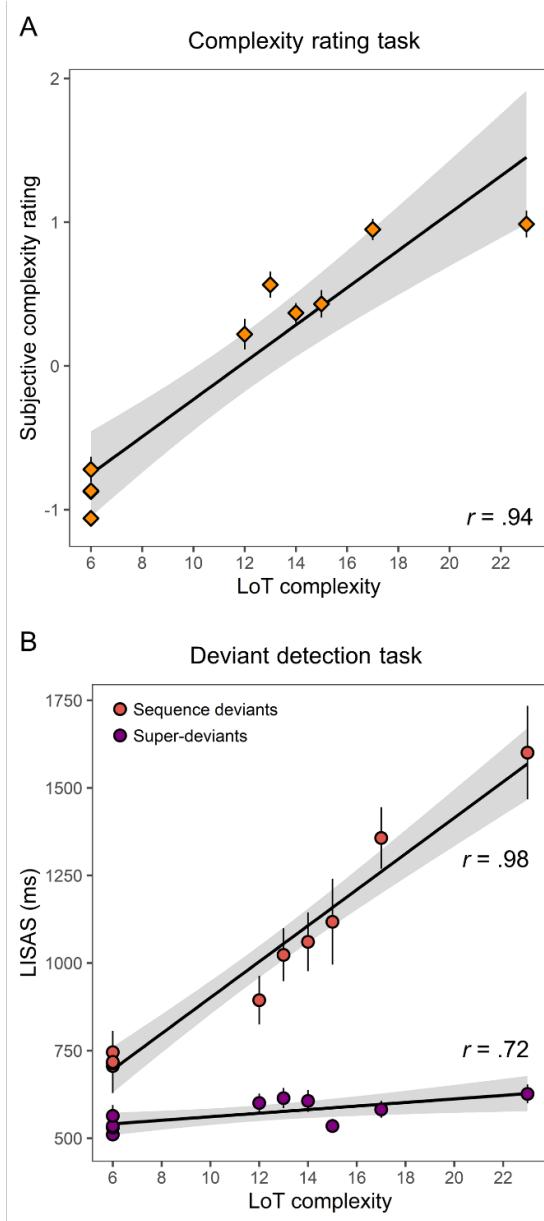


Figure 1: : Linear relationship between LoT complexity and subjective and objective measures obtained in experiment 1 with ten 16-items long auditory sequences (with 95% confidence intervals bands in gray). The Pearson correlation ( $r$ ) coefficient is indicated. Each marker represents the group-average for a given sequence. Error bars represent SEM across participants. (A) LoT complexity vs. subjective complexity ratings. (B) LoT complexity vs. performance in the violation detection task (Linear Integrated Speed-Accuracy Score), for sequence deviants and super-deviants.

**Experiment 1** (16-items sequences, excluding super-deviants)

*continued on next page*

*continued from previous page*

<i>Predictors</i>	<i>Estimates</i>	<i>Std. Error</i>	<i>T- value</i>	<i>95% CI</i>	<i>p</i>
(Intercept)	356.90	80.51	4.43	199.5 – 514.3	< .0001
Complexity	52.15	3.84	13.60	44.6 – 59.7	< .0001
Surprise	6.77	11.31	0.60	-15.4 – 28.9	.55

**Experiment 2** (12-items sequences, excluding super-deviants)

<i>Predictors</i>	<i>Estimates</i>	<i>Std. Error</i>	<i>T- value</i>	<i>95% CI</i>	<i>p</i>
(Intercept)	852.38	124.91	6.82	608.5 – 1096.2	< .0001
Complexity	24.21	6.29	3.85	11.9 – 36.5	< .0002
Surprise	-43.13	21.06	-2.05	-84.4 – -1.9	< .05

**Experiment 3** (8-items sequences)

<i>Predictors</i>	<i>Estimates</i>	<i>Std. Error</i>	<i>T- value</i>	<i>95% CI</i>	<i>p</i>
(Intercept)	852.40	73.39	11.62	707.8 – 997	< .0001
Complexity	10.75	3.49	3.08	3.9 – 17.6	< .003
Surprise	-32.37	5.60	-5.78	-43.3 – -21.4	< .0001

**Experiment 4** (6-items sequences, sequence 'AAAAAA' excluded)

<i>Predictors</i>	<i>Estimates</i>	<i>Std. Error</i>	<i>T- value</i>	<i>95% CI</i>	<i>p</i>
(Intercept)	751.6	47.5	15.8	658.8 – 844.5	< .0001
Complexity	1.4	4.4	0.3	-7.2 – 9.9	.75

*continued on next page*

*continued from previous page*

Surprise	-15.3	3.8	-4.1	-22.7 – -7.9	< <b>.0001</b>
----------	-------	-----	------	--------------	-------------------

#### **Experiment 5** (8-items sequences, auditory and visual)

Predictors	Estimates	Std. Error	T- value	95% CI	p
(Intercept)	645.1	92.2	7.0	464.4 – 825.9	< <b>.0001</b>
Complexity	25.2	25.2	4.4	14 – 36.4	< <b>.0001</b>
Surprise	-36.7	8.1	-4.5	-52.5 – -20.8	< <b>.0001</b>
Modality (Visual)	337.0	337.0	14.2	290.7 – 383.3	< <b>.0001</b>

## Experiment 2: auditory sequences with 12 items

### Methods

#### Participants

Twenty healthy volunteers ( $M_{\text{age}} = 26.5$ ,  $SD = 9.5$ , 15 women) participated in experiment

2. They all gave written consent to participate and were paid for their participation.

#### Stimuli

Auditory binary sequences of twelve sounds were used for this experiment. They were composed of an alternation of the same two complex tones as in the previous experiment, with the same duration and SOA. Total sequence duration was 2800 ms. Twelve different

sequential patterns, each composed of 6 As and 6 Bs were presented to each participant (Figure 4).

## **Procedure**

The same procedure and material as in the previous experiment was used. The complexity rating task was performed first (each of the twelve sequences was presented three times, in a pseudo-random order) followed by the violation detection task. In the latter, each sequence was tested in a different short session of approximately 3 min (habituation block of 8 trials, two test blocks of 18 trials each), followed by a pause. Each sequence lasted 2800 ms and was followed by a 1000 ms intertrial blank. Order of blocks was randomized for each participant. Half of the trials in tests block contained one deviant tone (at positions 7, 8, 9, 10, 11 or 12): 2/3 of “sequence deviants”, 1/3 of “super-deviants”. Participants were asked to press the button, as quickly as possible, as soon as they detected that the sequence has been altered.

## **Data analysis**

The same analysis as in the previous experiment were conducted. Extreme response times were removed (using the same procedure as in experiment 1), and represented 1.2% of all RTs. One participant was excluded (average number of false alarms per sequence more than 2.5 *SD* above the group median).

LoT complexity
(A A A A A A B B B B B B 6
(A A A B B B A A A B B B 6
(A B B A A B A B B A A B 8
(A A B B A A B B A B A B 9
(A A B B A A B A B A B B 11
(A A B B A B A A A B B A B 12
(A B B A B B A A A A B B 13
(A A A B B B A A A B B A B 14
(A A A B B A B B A A A B B 14
(A A B B A B B A A A A B B 16
(A B A A A A B B A B B B B 18
(A B B B B A A B A A A A B 19

**Figure 4:** Twelve 12-item sequences used in experiment 2, with their corresponding LoT complexity value (in bits).

## Results and discussion

### Complexity rating task

A positive linear relationship was found between subjective complexity ratings and LoT complexity ( $t(238) = 6.81$   $p < .0001$ ,  $r = .61$ ). The correlation of the average score per sequence with LoT complexity was however less strong than what was observed in the previous experiment with 16-items long sequences ( $r = .61$ , see Figure 5A). Subjective complexity was clearly underestimated for one specific sequence (“ABBAABABBAAB”, predicted complexity of 8), which is confirmed by an inspection of the residuals of the regression (residual 1.99  $SD$  above average for this sequence).

## Deviant type and complexity effects in the violation detection task

Regarding the violation detection task, main effects of LoT complexity ( $t(431.1) = 6.43$ ,  $p < .0001$ ) and deviant type (1078 ms for sequence deviants vs. 545 ms for super-deviants;  $t(431.0) = 19.3$ ,  $p < .0001$ ) were observed, as well as their interaction ( $t(431.1) = 3.48$ ,  $p < .0006$ ). The slope of the complexity effect appeared indeed stronger for sequence deviants as opposed to super-deviants (respectively +30 ms, vs. +7 ms; see Figure 5B). Separated analyses revealed that it was significant in analyses including either sequence deviants only ( $t(205.1) = 5.78$ ,  $p < .0001$ ;  $r = .63$ ), or super-deviants only ( $t(208.0) = 2.88$ ,  $p < .005$ ;  $r = .59$ ). The number of false alarms per sequence (3.88 on average) was also predicted by the LoT complexity of the sequence ( $t(208.0) = 3.50$ ,  $p < .0006$ ;  $r = .56$ ).

As in the complexity rating task, although the overall correlation was high, a noticeable deviation between predicted complexity and observed performance was present for some of the sequences. In fact, the correlation profiles observed in the Figure 5A and 5B suggest that the psychological complexity of the pattern, as indexed by subjective rating or violation detection task performance, might have been, for some sequences, consistently overestimated or underestimated by the LoT across both tasks (the largest residual in the regression with the sequence deviants, 1.50  $SD$  above average, corresponded to the same sequence identified by complexity ratings : “ABBAABABBAAB”). To further test this idea, we computed the correlation between the residuals of both linear regressions. The correlation was significant ( $t(10) = 4.02$ ;  $p < .003$ ), indicating that even after regressing out the effect of LoT complexity, the data from both experiments remained correlated with each other, and thus that, although the proposed LoT is a good predictor, it does not fully account for all details of the psychological complexity of patterns. One attempt

to address such potential limitations of the language is reported in the *Further analysis* section.

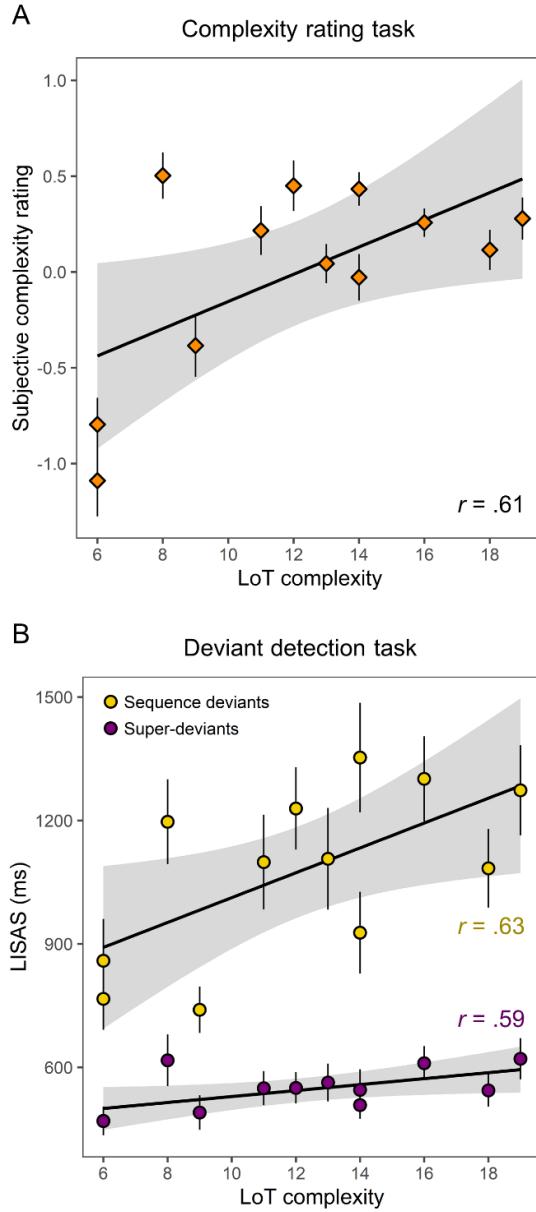


Figure 2: : Linear relationship between LoT complexity and scores obtained in the two tasks of experiment 2 with 12-item auditory sequences (with 95% confidence intervals bands in gray). Same format as Figure 3.

## **Surprise effects**

A comparison of mixed models (with participants as a random effect) showed that, compared to a null model only including the predicting power of surprise (null model; in which the main predictor was significant:  $t(205.0) = 4.67$ ,  $p < .0001$ ), a model also including LoT complexity (full model) fitted the data better (likelihood ratio test :  $\chi^2(1) = 14.4$ ,  $p < .0002$ ). Both fixed effects were significant in the full model: LoT complexity ( $t(204.1) = 3.85$ ,  $p < .0001$ ), as well as surprise ( $t(204.0) = 2.05$ ,  $p < .05$ ) (see Table 1). Although we can conclude that the effect of statistical learning (indexed by the level of surprise of deviant items) is here stronger than in the previous experiment (in which it was not clearly significant), note that the effect of surprise remained low.

## **Experiment 3 and 4: auditory sequences with 6 or 8 items**

The main objective of experiments 3 (with 8-items long sequences) and 4 (with 6-items long sequences) was to test whether the effect of complexity observed in the first two experiments could be generalized to larger sets of shorter sequences, where we could examine more gradual variations in complexity. The same violation detection paradigm was used. No subjective complexity ratings were collected (given the increased number of included sequences compared to the previous experiments).

## Methods

### Participants

Thirty-two healthy volunteers ( $M_{\text{age}} = 27.4$ ,  $SD = 5.3$ , 21 women) participated in experiment 3 and twenty-three in experiment 4 ( $M_{\text{age}} = 23.4$ ,  $SD = 4.5$ , 18 women). They all gave written consent to participate and were paid for their participation.

### Stimuli

In experiment 3, auditory binary sequences of eight sounds were used. They were composed of an alternation of the same two complex tones as in the previous experiment, with the same duration and SOA. Total sequence duration was 1800 ms. Thirty-five different sequential patterns were presented to each participant, i.e. all possible 8-element-long binary combinations that contained the same number of As and Bs (as in experiment 1 and 2).

In experiment 4, auditory binary sequences of six sounds were used (1300 ms). Thirty-two different sequential patterns were presented to each participant, representing all  $2^5$  types of 6-element sequences (given that the labelling of As and Bs is arbitrary, sequences such ABABAB and BABABA were considered identical). Note that, in this case, the proportion of As vs. Bs varied across sequences.

### Procedure

The same procedure and material as in previous experiments were used. Each sequence was however here tested in a single block of 35 trials (auditory sequence of 1800 or 1300

ms and inter-trial duration of 1000 ms). Alterations of the sequence occur on 1/3 of the trials, starting from the 9<sup>th</sup> trial (i.e. the habituation phase comprised 8 repetitions). Deviant tones (sounds A replaced by B or conversely — there were no super-deviants in these experiments) were positioned in the second half of the sequence (four or three equiprobable positions). As before, participants were asked to press the button, as quickly as possible, as soon as they detected that the sequence has been altered.

### Data analysis

The same analyzes as in the previous experiments were conducted. Extreme response times that were removed represented 1.6% of RTs in experiment 3 and 1.6% in experiment 4. One participant was excluded in experiment 3 (average number of false alarms per sequence more than 2.5 *SD* above the group median), and one in experiment 4 (average miss rate more than 2.5 *SD* above the group median).

### Results and discussion

Here again, we tested (using mixed models) whether surprise suffices to explain the variance in performance or if a significant proportion remained yet to be explained by sequence complexity (all models included participants as a random effect). In experiment 3 (8-items sequences, N = 35), goodness of fit improved when LoT complexity was included in the model ( $\chi^2(1) = 9.47$ ,  $p < .003$ ). Both fixed effects were significant in the full model: LoT complexity ( $t(1042.0) = 3.08$ ,  $p < .003$ ; see Figure 6A), as well as surprise ( $t(1042.0) = 5.78$ ,  $p < .0001$ ) (see Table 1). Note that the surprise fixed effect was already highly significant in the null model ( $t(1043.0) = 8.72$ ,  $p < .0001$ ).

Similarly, in experiment 4 (6-items sequences,  $N = 32$ ), goodness of fit improved when LoT complexity was included to the surprise-only null model ( $\chi^2(1) = 6.20$ ,  $p < .02$ ) with both fixed effects significant in the full model (LoT complexity:  $t(649.00) = 2.49$ ,  $p < .02$ ; see Figure 6B), and surprise ( $t(649.0) = 5.48$ ,  $p < .0001$ ). The surprise fixed effect was here again already highly significant in the null model ( $t(650.0) = 6.78$ ,  $p < .0001$ ). However, one sequence appeared as an outlier in this experiment, with an average LISAS 3.9 SD below the average of all sequences (i.e. indicating a much better performance): the “AAAAAA” sequence. In this case, performing the task requires no sequence learning, but merely remembering the identity of the A sound, and violation detection is therefore similar to a classic oddball paradigm. When this sequence was removed from the dataset (it was also excluded from further analyses), the inclusion of the complexity fixed factor did no longer improve model goodness of fit ( $\chi^2(1) = 0.10$ ,  $p = .75$ ). Indeed, the LoT complexity fixed effect was not significant in the full model ( $t(628.0) = 0.32$ ,  $p = .75$ ), as opposed to the surprise fixed effect ( $t(628.0) = 4.07$ ,  $p < .0001$ ) (see Table 1). No improvement in model fit was found when including the interaction between complexity and surprise ( $\chi^2(1) = 0.08$  in experiment 3,  $\chi^2(1) = 0.34$  in experiment 4).

Beside the effect of complexity, the strong effect of surprise in both experiments indicates that participants were quicker and more likely to detect a deviant when it violated statistical regularities characterizing the auditory sequence being repeatedly played. This is consistent with the idea that humans spontaneously encode the probabilities associated with events and react to surprising events depending on their level of predictability (Huettel et al., 2002; Meyniel et al., 2016).

The number of false alarms was low in the present experiments (0.91 per sequence on average in experiment 3, 0.60 in experiment 4). It was slightly related to sequence com-

plexity in experiment 3  $t(1048) = 2.19$ ,  $p < .03$ ) but not in experiment 4  $t(650.0) = 0.29$ ,  $p = .77$ .

Compared to the previous experiment with lengths 12 and 16, it was expected here, with sequences of 8 or 6 items, that the effect of LoT complexity would be mitigated, since those auditory sequences may become short enough to be stored in working memory as a simple chain (note that the range of LoT complexity values was also smaller). The correlation of performance with LoT complexity was in fact still present with 8-items sequences (at a similar level as in experiment 2) but disappeared with 6-items sequences. This is in line with the assumption that complexity is tightly linked with the idea of compressibility in memory, and suggests that such a compression strategy, whether it is simple chunking or involves a hierarchical representation, is more likely to be involved when the number of items to store in working memory exceeds the typical working memory span (MacGregor, 1987; Mathy & Feldman, 2012). However, rather than a clear threshold above which complexity would become predictive of performance, the estimates of the LoT complexity effect across the four experiments (in the mixed models taking into account surprise) reveal a gradient: with stronger effects of complexity for longer sequences (respectively +1.4 ms, +10.8 ms, +24.2 ms, and +52.2 ms, for the experiments with length 6, 8, 12 and 16 respectively; see Table 1). The effect of surprise seemed to follow an inverse trend, with insignificant or marginal effects in long sequences (experiments 1 and 2) and highly significant effects in short sequences (experiments 3 and 4). To test this idea, the data from experiments 1-4 (excluding super-deviants) were combined in a single mixed model including the three fixed factors of LoT complexity, surprise and length (as a continuous predictor), as well as the three two-way interactions (with participants as the random factor). An ANOVA on the mixed model revealed main effects of LoT complexity ( $F(1$ ,

$F(1, 2336.4) = 48.0$ ,  $p < .0001$ ) and surprise ( $F(1, 2334.1) = 4.91$ ,  $p < .03$ ). The main effect of sequence length was marginally significant ( $F(1, 96.6) = 3.08$ ,  $p = .082$ ). As expected, a strong interaction between LoT complexity and length was present ( $F(1, 2347.5) = 63.3$ ,  $p < .0001$ ), indicating a stronger effect of complexity when sequence length increased. The estimated slopes for the LoT complexity effect indeed increased with each sequence length (+15.5 ms, +46.0 ms, +107.1 ms, and +168.1 ms, for length 6, 8, 12 and 16, respectively). The interaction between length and surprise was not significant ( $F(1, 2330.0) = 1.19$ ,  $p = .28$ ). However, the estimated slopes for the surprise effect followed our initial observation: they decreased with each sequence length (-15.6 ms, -12.0 ms, -4.9 ms, and +2.2 ms).

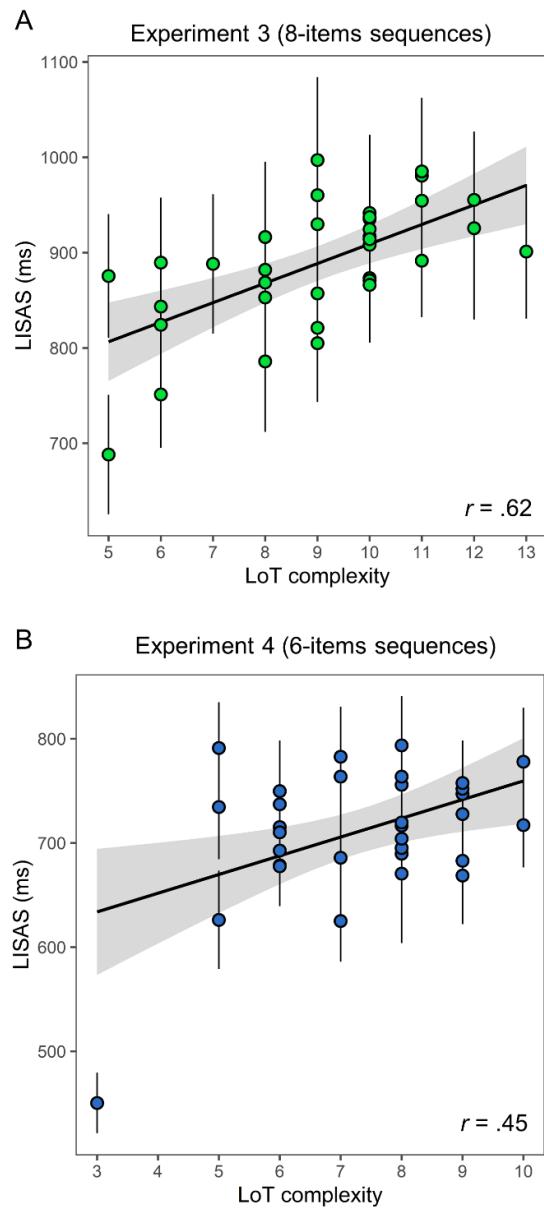


Figure 3: : Linear relationship between LoT complexity and violation detection task performance (LISAS) in: (A) experiment 3 (8-items sequences) and (B) experiment 4 (6-items sequences).

## Experiment 5: auditory and visual sequences

The observation of a LoT complexity effect on sequences of length 8 and higher is consistent with our initial claim that individuals spontaneously apply simple rules (mainly based on nested repetitions) in order to recode auditory sequences in a compressed abstract form in memory. It may be argued, however, that rather than being abstract and universal, some of these effects may reflect the great ability of our auditory system to manipulate and find regularities in acoustic stimuli; whether it is in spoken language or in music listening. In experiment 5, we wished to replicate the findings of previous experiment and extend them to the visual modality. Sequences of 8 items (allowing to use a sufficient number of trials while still expecting clear complexity effects) were presented to a group of participants in both a visual and in an auditory form (in different experimental blocks), using the same violation detection paradigm. Due to constraints in the perception of repeated visual stimuli, stimulus onset asynchrony was lengthened to 400 ms in both auditory and visual sessions, resulting in a sequence duration of 3000 ms (compared to 1800 ms in experiment 2).

## Methods

### Participants

Participants were eighteen healthy volunteers ( $M_{\text{age}} = 25.5$ ,  $SD = 5.7$ , 15 women). They all gave written consent to participate and were paid for their participation.

### Stimuli

Fifteen binary sequential patterns of eight items were used for this experiment (all were composed of 4 items A and 4 items B). All were previously used in experiment 2. They

were selected based on their LoT complexity, in order to preserve a large and homogenous distribution of complexity values. The same sequences were presented to participants in auditory and visual forms (in different blocks). Auditory sequences were composed of the same two complex tones as in the previous experiments. Visual sequences were composed of two colored Gabor patches presented in the center of the screen (a red Gabor patch with 45° orientation, and a green patch with 135° orientation). Stimulus duration was 200 ms with 200 ms inter-stimulus interval in both modalities. Total sequence duration was 3000 ms.

### **Procedure**

The same procedure and material as in previous experiments were used in the auditory blocks. Participants were instructed to fixate the center of the screen in the visual blocks. Each sequence was tested in a short block of approximately 2.5 min., followed by a pause. Since each sequence was presented twice (i.e. in the visual and in the auditory form), the experiment was divided in two sessions of fourteen blocks, separated by a longer pause. Each pattern appeared once in a given session, which comprised equal numbers of auditory and visual blocks. Order of blocks within each session was randomized for each participant. Each block comprised 35 trials (sequence of 3000 ms and inter-trial duration of 1000 ms). The habituation phase contained at least eight trials, alterations of the sequence occur on 1/3 of the remaining trials (i.e., 9 deviant trials). As before, deviant items only appeared within the second half of the sequence (positions 5, 6, 7 or 8). Participants were asked to press the button, as quickly as possible, as soon as they detected a change in the sequence.

## Data analysis

LISAS were computed for each sequence per modality per subject using correct response times and miss rate (after removing 2.4% extreme response times). One participant was excluded (miss rate and number of false alarms more than  $2.5SD$  above group median). The same analysis procedure described before was adopted with the sole exception that some analyses included modality as a categorical two-levels (auditory vs. visual) predictor.

## Results and discussion

### Complexity and modality effects

To assess the impact of LoT complexity and modality on performance, we first computed a mixed model including complexity and modality as fixed factors and participants as a random factor. Effects of LoT complexity ( $t(486.0) = 3.08$ ,  $p < .003$ ), modality (average LISAS of 1110 ms in visual blocks vs. 780 ms in auditory blocks;  $t(486.0) = 14.1$ ,  $p < .0001$ ) and their interaction ( $t(486.0) = 3.19$ ,  $p < .002$ ) were significant. The slope of the complexity effect was steeper in the visual than in the auditory modality (+54 ms vs. +22 ms,  $t(486) = 3.19$ ; see Figure 7). Separate analyses indicated that LoT complexity was a strong predictor of performance for visual sequences ( $t(233.0) = 6.82$ ,  $p < .0001$ ;  $r = .76$ ), and also for auditory sequences ( $t(237.0) = 3.76$ ,  $p < .0003$ ;  $r = .63$ ).

Note that, although the effects appeared stronger for the visual modality, the average performance in the visual and the auditory modality were highly correlated ( $r = .85$ ,  $p < .0001$ ). This suggests a common, cross-modal mechanism behind the observed differences in performance between sequences. It can however be acknowledged, here again, that this is not fully explained by complexity. Indeed, the residuals of linear regressions with LoT complexity in the visual and in the auditory modality (using average LISAS per sequence)

were still correlated ( $r = .73$ ,  $t(13) = 3.92$ ;  $p < .002$ ).

The number of false alarms per sequence was related to the task modality (mean number of FA: 0.58 in auditory blocks; 1.16 in visual blocks; difference between modalities:  $t(487.0) = 5.73$ ,  $p < .0001$ ) but not to sequence LoT complexity ( $t(487.0) = 0.08$ ,  $p = .94$ ).

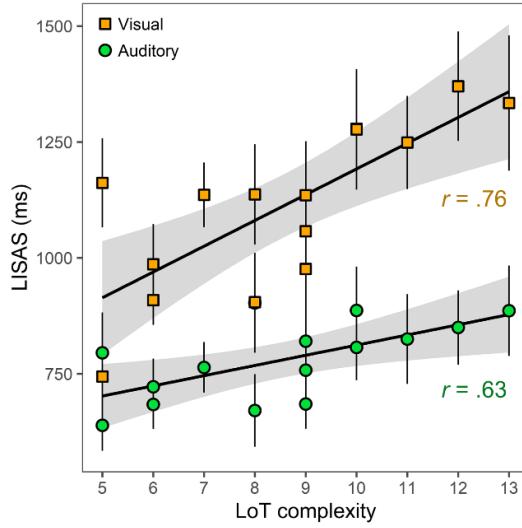


Figure 4: : Linear relationship between LoT complexity and violation detection task performance (LISAS) for each modality in experiment 5 (8-items auditory and visual sequences).

### Surprise effects

As in previous experiments, a surprise effect was also observed, in both modalities, when considered independently; deviants inducing rare transitions were more easily and quickly detected than frequent ones (effect of surprise in a mixed model with auditory trials only:  $t(237.0) = 3.87$ ,  $p < .0002$ ;  $r = -.65$ ; with visual trials only:  $t(233.0) = 6.79$ ,  $p < .0001$ ;  $r = -.78$ ). This effect suggests that a common, or at least a similar, mechanism is at play in the encoding of statistical regularities characterizing the sequences in both the visual and the auditory modality.

In order to test whether evidence for sequence compression could still be observed once the surprise effect was taken into account, we performed a comparison of mixed effects models. The null model included the surprise predictor, the modality as a categorical predictor and the subject random factor. It was compared against a full model including the same predictors, with the addition of the LoT complexity. This comparison was highly significant ( $\chi^2(1) = 19.0$ ,  $p < .0001$ ), indicating that goodness of fit improved when LoT complexity was added to the model. All three fixed effects were significant in the full model (LoT complexity:  $t(486.0) = 4.39$ ,  $p < .0001$ ; surprise:  $t(486.0) = 4.54$ ,  $p < .0001$ ; modality:  $t(486.0) = 14.2$ ,  $p < .0001$ , see Table 1).

Overall, the results obtained in the visual modality are very similar to those obtained in the auditory modality in the same and in previous experiments. We however observed here stronger effects of both LoT complexity and surprise. It should be noted that the overall difficulty of the task increased in the visual modality (as indicated by higher average miss rates per sequence; 22% vs. 11%,  $t(14) = 7.49$ ,  $p < .0001$ ; and longer average response times per sequence; 831 ms vs. 645 ms,  $t(14) = 10.5$ ,  $p < .0001$ ). 8-items visual sequences may have been more difficult to encode than 8-items auditory sequences, due to the known superiority of the auditory processing system in the processing of temporal sequences and rhythms (Freides, 1974; Patel et al., 2005). This increased encoding difficulty in the visual domain may have in turn lead to an increased need for the “mental sequence compression” mechanism that our language of thought aims to describe.

The present experiment also extends the results of experiment 3 by using a slower presentation rate. Indeed, although the participants in experiment 5 appeared to respond faster (in the auditory blocks) than those from experiment 3, the same relationship with

complexity was found (correlation of performance with LoT complexity of .62 and .63 respectively). It suggests that the effect of complexity is robust across sequence durations (as expected given than LoT complexity is based on abstract sequence patterns). More importantly, the fact that a similar complexity effect was observed irrespective of the modality is consistent with the idea of “language of thought” used to compress sequential information at an abstract, symbolic level. Such an assumption has already been supported by results from Yildirim and Jacobs (2015), who showed cross-modal transfer of sequence knowledge: learning to categorize visual sequences facilitated the categorization of auditory sequences and vice versa. In fact, the language we used here was initially designed to represent visually presented, geometrical patterns (Amalric et al., 2017). The present results thus confirm that this language can account for sequence representations in various modalities and presentation contexts.

## **Further analysis: comparison with other measures of sequence complexity**

The complexity, or the “compressibility”, of a sequence can be assessed in several ways, and various measures have been previously proposed in the psychological literature (e.g. Aksentijevic & Gibson, 2012; Alexander & Carey, 1968; Gauvrit et al., 2014; Glanzer & Clark, 1963; Griffiths & Tenenbaum, 2003; Mathy & Feldman, 2012; Psotka, 1975; Vitz, 1968; Vitz & Todd, 1969). In this last section, we examined how our LoT complexity value compares to six other measures in predicting task performance over different sequence lengths. These measures were the following:

**Chunk complexity:** following the observation that the number of chunks (or runs) is correlated to performance in sequence encoding tasks (e.g. Glanzer and Clark, 1963), we here define chunk complexity using the formula proposed by Mathy & Feldman (2012), which they showed to correlate with performance in the encoding of series of digits:

$$Chunkcomplexity = \sum_{i=1}^K \log_2 (1 + L_i)$$

Where K is the number of chunks and  $L_i$  the length of the  $i$ -th run. Note that contrary to Mathy & Feldman, (2012), whose sequences were composed of digits and chunks defined based on constant (positive or negative) increments from one digit to the next (e.g. “1234”, “7531”), we here simply define chunks as consecutive repetitions of the same item, e.g. the sequence “AAABAA” has 3 chunks, and a chunk complexity of  $\log_2(4) + \log_2(2) + \log_2(3)$ .

**Entropy of apparent transition probabilities:** here we computed the Shannon entropy ( $H$ ), a measure of information that quantifies the uncertainty of a distribution, of the probability of pairs of items, (AA, AB, BA, BB), in order to capture the effect of order-1 transition probabilities (Maheu et al., 2020). Given that the probability of a given pair is defined as  $p(X, Y) = p(X) \cdot p(Y|X)$ ,  $H$  is computed as follow:

$$H = - [p(A) \cdot p(A|A) \cdot (\log_2 p(A) + \log_2 p(A|A)) + p(A) \cdot p(B|A) \cdot (\log_2 p(A) + \log_2 p(B|A)) + p(B) \cdot$$

We used the convention that  $0 * \log_2(0) = 0$  when null probabilities occurred.

**Lempel-Zif complexity** (Lempel & Ziv, 1976) is derived from the popular lossless data compression algorithm, the Lempel-Ziv (LZ) algorithm. Briefly, the LZ algorithm works by scanning the sequence from left to right and adding to a vocabulary each new substring it has never encountered before. LZ complexity is the number of substrings in this vocabulary once the scan is complete. Beyond the field of computer data compression, LZ complexity has been used in various domains, for instance, to measure the complexity of rhythmic patterns in music (Thul & Toussaint, 2008), or to assess the complexity of human (Peng et al., 2014) or non-human behaviors (Belkaid et al., 2020).

The number of **subsymmetries** is the number of symmetric sub-sequences of any length within a sequence. For instance, the sequence “AABBAB” has two symmetric subsequences of length 2 (“AA” and “BB”), one of length 3 (“BAB”), and one of length 4 (“ABBA”), for a total of four subsymmetries. This measure was proposed by Alexander and Carey (1968) and shown to be negatively correlated to performance in perception and production tasks with visual and auditory patterns (Alexander & Carey, 1968; Toussaint & Beltran, 2013).

**Change complexity** is an advanced measure proposed by Aksentijevic and Gibson (2012), based on the notion of “change” (the inverse of invariance), computed across all sub-sequences contained in a sequence, and showing interesting properties such as a sensibility to periodicity and symmetries.

**Algorithmic complexity** was introduced by Gauvrit et al., (2014, 2016) and Soler-Toscano et al., (2014). It is based on the mathematical definition of Kolmogorov-Chaitin complexity (Chaitin, 1969; Kolmogorov, 1968) and derived from the probability of obtaining a given pattern in the output of a randomly chosen Universal Turing Machine that halts.

**LoT chunk complexity.** Note that the alternative measures of complexity tested here, which provide a unique metric for each pattern, are quite conceptually different from the one we propose. LoT complexity is based on the proposal that humans possess a language of thought, composed of a small number of atomic rules which they use recursively to recode the abstract structure of the pattern in a compressed form. Such a recursive representation differs radically from, say, the mere counting of the number of chunks. However, it is possible to combine the two ideas. The formal language we proposed produces many legal expressions for each sequence (the number of possible expressions can reach several tens of thousands for a sequence of length 16), which correspond to distinct “parses” of the same sequence. We initially assumed that the shortest expression is always selected, and thus that LoT complexity is equal to the shortest possible description using this language. However, it is unclear whether humans could ever search such a vast space of possibilities. A more plausible hypothesis is that participants begin by chunking the sequence into groups of identical items, and only then compress it by detecting repetitions of those chunks (for a similar proposal, see E. Leeuwenberg, 1969; Leeuwenberg, 1971). According to this idea, the shortest sequence should only be accepted when its proposed parsing coincides with chunk boundaries. Consider the sequence “ABBAAB”, which consists of 4 chunks [A] [BB] [AA] [B]. According to our language, its optimal description is [AB] [BA] [AB] (i.e. 3 repetitions of the stay-change program; LoT complexity = 5), but that representation does not coincide with chunk boundaries. Interestingly, the data suggested that the shortest description may not be optimal in similar cases (see *Experiment 2, Results and discussion*). To test this idea, we recomputed LoT values restricted to chunk-preserving expressions (i.e., excluding expressions producing “A][A” or “B][B”). We called this new LoT complexity the **LoT chunk complexity**. Its

value was higher than the original one for 58% of sequences (and remained the same for the others). For instance, the sequence “ABBAAB” from the previous example, when described as four chunks [A] [BB] [AA] [B], has an LoT-chunk complexity = 9. We tested LoT chunk complexity as another potential predictor of behavioral performance.

## Model comparison

To conduct the analyses, data were pooled from all previous experiment with auditory sequences (using LISAS to index task performance), excluding super-deviants trials. Unfortunately, due to the nature of algorithmic complexity (derived from the output frequency for a pattern using small Turing machines, which decreases rapidly with sequence length), no values were available for the ten length-16 patterns that we used in experiment 1, as well as for one length-12 pattern used in experiment 2. Those sequences were therefore excluded from some analyses. The sequence “AAAAAA” from experiment 4 was also excluded. Consequently, a first pooled dataset, for which all 8 different predictors could be compared, included performance with 77 different auditory sequences (and 88 different participants), of length 6 ( $n = 31$  sequences), length 8 ( $n = 35$ ) and length 12 ( $n = 11$ ), while a second one, for which 7 different predictors were compared, also included sequences of length 16 ( $n = 88$  sequences, 113 participants).

To assess whether one measure was a better predictor of task performance, we first computed different mixed models, which all included the predictor of interest as the only fixed effect and participants as a random effect (note that this is a way to control for the fact that different participants coming from different experiments, with different sets of stimuli, were pooled together). We then report the Akaike information criterion (AIC)

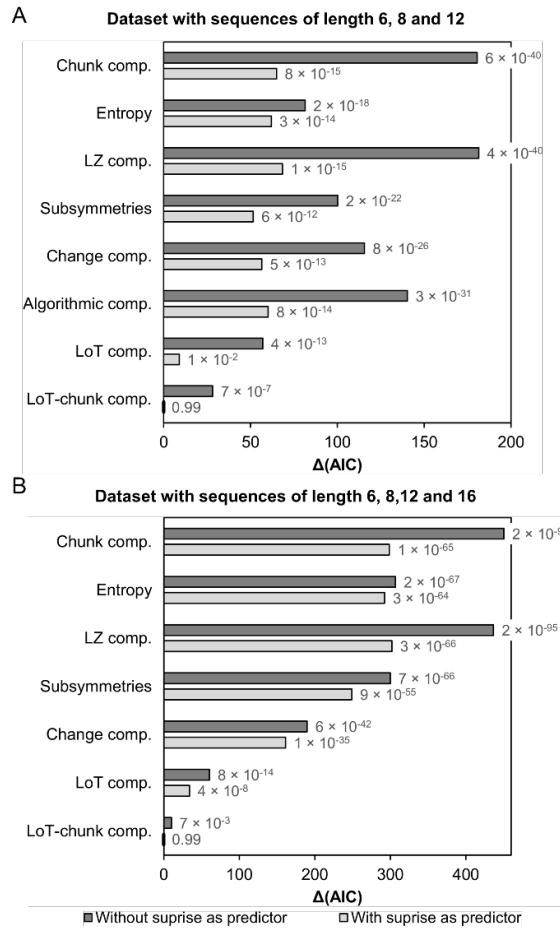
as an indicator of goodness of fit which penalizes for model complexity (i.e. the number of predictors); the model with the lowest AIC value being considered the best (or with lowest “ $\Delta$  (AIC)” value, i.e. the relative difference in AIC with the best model: for a model  $i$ ,  $\Delta$  (AIC) $_i$  = AIC $_i$  - AIC $_{\min}$ ). Note that we also report the Bayesian information criterion (BIC) which, in addition, scales the strength of penalization by the (log) number of data points. Second, since, as we reported earlier, surprise derived from the learning of transition probabilities may strongly affect the performance in such violation detection task, all these models were computed again, this time including surprise as a fixed effect covariate.

## **Dataset with sequences of length 6, 8 and 12.**

Sixteen different mixed models were fitted using datasets with sequences of length 6, 8 and 12. As illustrated in Figure 8A, model fit, as indexed by the  $\Delta$  (AIC) value, always improved when the surprise associated to the deviants was included in the model. This finding confirms that the effect due to transition probabilities needs to be taken into account when assessing responses to deviants in the violation detection paradigm. The improvement in model fit was smallest for the model with entropy. This effect was expected since entropy and surprise are two tightly related information measures (i.e. Shannon entropy is the average of Shannon surprise).

When considering either only single-predictor models (i.e. without the surprise covariate) or two-predictors models (i.e. with surprise), the two best models were the ones with our modified version of LoT complexity (i.e. LoT-chunk, with the “no-splitting” chunks constraint) followed by the one with original LoT complexity (see Table 2). In order to test

whether the differences in the raw AIC values were meaningful, we computed the Akaike weights for this set of 14 models. Akaike weights can be interpreted as the probability that a given model is the best model of the set (Wagenmakers & Farrell, 2004). Akaike weight was .99 for the LoT-chunk complexity (+ surprise) model, .01 for the LoT complexity (+ surprise) model, and below .01 for all other models (see Table 2 and Figure 8A).



**Figure 8:**  $\Delta$  (AIC) for the sixteen mixed models tested using the dataset including the task performance (LISAS) for sequences of length 6, 8 and 12 (A), and for the twelve different mixed models tested using the dataset with sequences of length 6, 8, 12 and 16 (B). The fixed effect of interest is indicated along the vertical axis (all models included participants as a random effect and could include surprise as a covariate — light gray bars). Akaike weight for each model is also reported. The model with lower AIC ( $\Delta$  (AIC) = 0) is indicated by short dark vertical line on the vertical axis.

Although the correlations of performance with LoT complexity in experiments 2, 3 and 4 (lengths 6, 8 and 12) were small in comparison with experiment 1 (length 16), LoT complexity again appears as the best predictor of performance in the violation detection task with sequences of length  $\leq 12$ . Notably, the constraint of excluding, for each pattern, the expressions that resulted in the splitting of a chunk (before the selection of shortest expression) improved the fit to the behavioral data. This observation suggests that participants did not always find the best way of coding some patterns (best in the sense of the language of thought considered here) because of a propensity to perform an initial chunking solely based on consecutive runs of identical items.

The next best model was the one with the “number of subsymmetries” predictor (and including the surprise covariate), suggesting that it also provides a good measure of the psychological complexity of patterns. However, while this appeared true here using statistical models partially controlling for sequence length (i.e. by including participant index as a random factor, since each participant performed the task with only one given sequence length), this measure appears inappropriate to predict complexity across different lengths. Indeed, when we computed the Pearson correlation of average LISAS per sequence for the pooled dataset (sequences of length 6, 8 and 12), we obtained a *positive* correlation value of .39. Such positive correlation is in conflict with the presupposition that patterns containing more symmetries should be simpler. It is due to the fact that the number of subsymmetries tends to increase with sequence length. These correlations were actually negative when each length was considered independently ( $r = -.44$  for length 6;  $r = -.54$  for length 8; and  $r = -.58$  for length 12). This is illustrated in Figure 9, where the average LISAS for each sequence is presented in relation to each complexity measure (see also Figure S6 and S7 for the equivalent with reaction times and miss rates). To summa-

rize, although this measure is quite good in predicting the complexity of sequences of a given length, it is not efficient in predicting the variations in complexity due to sequence length.

Another similar limitation applies to algorithmic complexity, where the correlation observed across lengths ( $r = .79$ ) is mostly because this value presents excessive discontinuities with length: algorithmic complexity ranges roughly between 14 and 16 for length 6; between 19 and 23 for length 8; and between 31 and 35 for length 12 (see Figure 9). Such large increases in complexity with length are not consistent with behavior. Again, LoT complexity provides a better correlation with the present behavioral data across a large range of sequence lengths, because it correctly predicts that, for instance, some 6-items long sequences can be more complex than some 12-items ones.

Model fixed effect(s)	Dataset with sequences of length 6, 8 and 12				Dataset with sequences of length 6, 8, 12 and 16			
	Log-lik.	$\Delta(AIC)$	$\Delta(BIC)$	w(AIC)	Log-lik.	$\Delta(AIC)$	$\Delta(BIC)$	w(AIC)
<i>LoT comp.</i>	-14886	57	51	$4.0 \times 10^{-13}$	-16653	60	55	$7.8 \times 10^{-14}$
<i>LoT comp. + Surp.</i>	-14861	9	9	$1.1 \times 10^{-2}$	-16639	34	34	$4.1 \times 10^{-8}$
<i>LoT-chunk comp.</i>	-14872	28	23	$7.4 \times 10^{-7}$	-16628	10	4	$6.8 \times 10^{-3}$
<i>LoT-chunk comp. + Surp.</i>	-14857	0	0	0.99	-16622	0	0	0.99
<i>Chunk comp.</i>	-14948	180	175	$6.4 \times 10^{-40}$	-16848	450	445	$1.6 \times 10^{-98}$
<i>Chunk comp. + Surp.</i>	-14889	65	65	$7.5 \times 10^{-15}$	-16771	299	299	$1.4 \times 10^{-65}$
<i>Entropy</i>	-14899	81	76	$2.0 \times 10^{-18}$	-16776	307	301	$2.3 \times 10^{-67}$
<i>Entropy + Surp.</i>	-14888	62	62	$3.4 \times 10^{-14}$	-16768	292	292	$3.3 \times 10^{-64}$
<i>LZ comp.</i>	-14948	181	176	$3.9 \times 10^{-40}$	-16841	436	431	$1.6 \times 10^{-95}$
<i>LZ comp. + Surp.</i>	-14891	68	68	$1.4 \times 10^{-15}$	-16773	302	302	$2.6 \times 10^{-66}$
<i>Subsymmetries</i>	-14908	100	94	$1.2 \times 10^{-22}$	-16773	300	294	$8.8 \times 10^{-55}$
<i>Subsymmetries + Surp.</i>	-14883	52	52	$6.2 \times 10^{-12}$	-16746	249	249	$1.3 \times 10^{-17}$
<i>Change comp.</i>	-14916	116	110	$7.6 \times 10^{-26}$	-16718	190	184	$6.2 \times 10^{-42}$
<i>Change comp. + Surp.</i>	-14885	57	57	$5.3 \times 10^{-13}$	-16703	161	161	$1.0 \times 10^{-35}$
<i>Algorithmic comp.</i>	-14928	140	135	$3.4 \times 10^{-31}$		N.A.		
<i>Algorithmic comp. + Surp.</i>	-14887	60	60	$8.4 \times 10^{-14}$		N.A.		

*Note.* All models included participants as a random effect, and either one or two fixed effect(s) (i.e. “+ Surp.” : with additional surprise fixed effect). Log-lik. = log of the maximum likelihood for the model.  $\Delta$  (AIC) = AIC difference with the model with the lowest AIC value (where AIC is the Akaike Information Criterion).  $\Delta$  (BIC) = BIC difference with the model with the lowest BIC value (where BIC is the Bayesian Information Criterion). w(AIC) = Akaike weight.

## Dataset with sequences of length 6, 8, 12 and 16.

Fourteen different mixed models (with participants as a random effect) were here fitted, using the same dataset as before to which was added data from 11 sequences for which algorithmic complexity value was not available (thus now with sequences of length 6, 8, 12 and 16). The same predictors as above were used, with the exception of algorithmic complexity. Here again, as illustrated in Figure 8B, goodness of fit systematically increased when surprise was included. LoT-chunk complexity and LoT complexity (with or without surprise as a covariate) were again the best predictors of performance (see Table 2). As opposed to the previous set of analyses in which the data from experiment 1 (length 16) was not included, the model with change complexity performed clearly better than the one with the number of subsymmetries. The long sequences used in experiment 1 indeed presented important differences in their number of subsymmetries (e.g. 56 for  $(AB)^8$  vs. 32 for  $(A^4B^4)^2$ ), which were clearly not predictive of performance. Consequently, and as stated earlier, the number of subsymmetries does not appear as a good predictor of task performance across different sequence lengths. Change complexity also appeared as a much better predictor when performing a simple linear regressions on average LISAS per sequence (see Figure 9), resulting in an  $r = .81$ , which is close to the one obtained with LoT complexity ( $r = .82$ ). It indicates that change complexity can also be a good measure of the psychological complexity of a sequence regardless of its length. It must however be noted that, contrary to the mixed models, these linear regressions using data averaged over participants did not control for the variance accounted for by surprise, or due to inter-subject variability. Important variations were indeed observed across participants regarding the correlation with complexity (especially for experiments with shorter sequences). When computed at the level of individual participants, the correlation

with LoT complexity appeared on average stronger (mean  $r = .31$ ,  $SD = .32$ ) than the one with change complexity (mean  $r = .23$ ,  $SD = .30$ ) ( $t(112) = 3.54$ ,  $p < .0006$ ).

With both datasets, two measures performed poorly, LZ complexity and chunk complexity. Contrary to our language, the LZ algorithm has the advantage to be able to quickly “parse” any sequence of any number of different characters, by building for each sequence its own vocabulary of substrings. Its adequacy to human behavior, however, appears limited since, when scanning the sequence from one item to the next, it does not necessarily take into consideration runs of repeated items (“AAA” can be described with two substrings, “A” and “AA” ) and fails to capture repeating patterns. This deficiency is especially striking for a low LoT complexity sequence such as  $(A^2B^2)^4$  (i.e., AABBAABB... ), where 8 substrings are present in the vocabulary at the end of scanning (the first four substrings encountered by the algorithm are “A” , “AB” , “B” , “AA” ). This gives this sequence the lower level of LZ compressibility among those tested, which is clearly not predictive of performance.

Similarly, “chunk complexity” , like other methods solely based on quantifying chunks (number of chunks, chunks length, or a combination of both), is strongly dependent on how chunks are defined. Here, since chunks are defined as runs of identical items, the complexity of sequences containing alternations tends to be overestimated (e.g. “ABABABAB” has 8 chunks). Assessing complexity based on chunks therefore requires first building a model that defines what chunks are for the sequence processing cognitive system, which is not trivial. Another limitation of this measure is an excessive sensitivity to sequence length. In the absence of any recursive compression, complexity increases linearly with the number of chunks. Allowing compression based on consecutive repetitions of chunks (chunks of chunks), as in the LoT model proposed here, appears to be a better strategy for

predicting the subjective complexity of sequences. Note that, notwithstanding the aforementioned concerns, change complexity captures relatively well the complexity variations due to both structure and length (Figure 9). This may be due to the fact that change complexity is computed within substrings of all possible lengths, which is another way to capture regularities at multiple hierarchical levels.

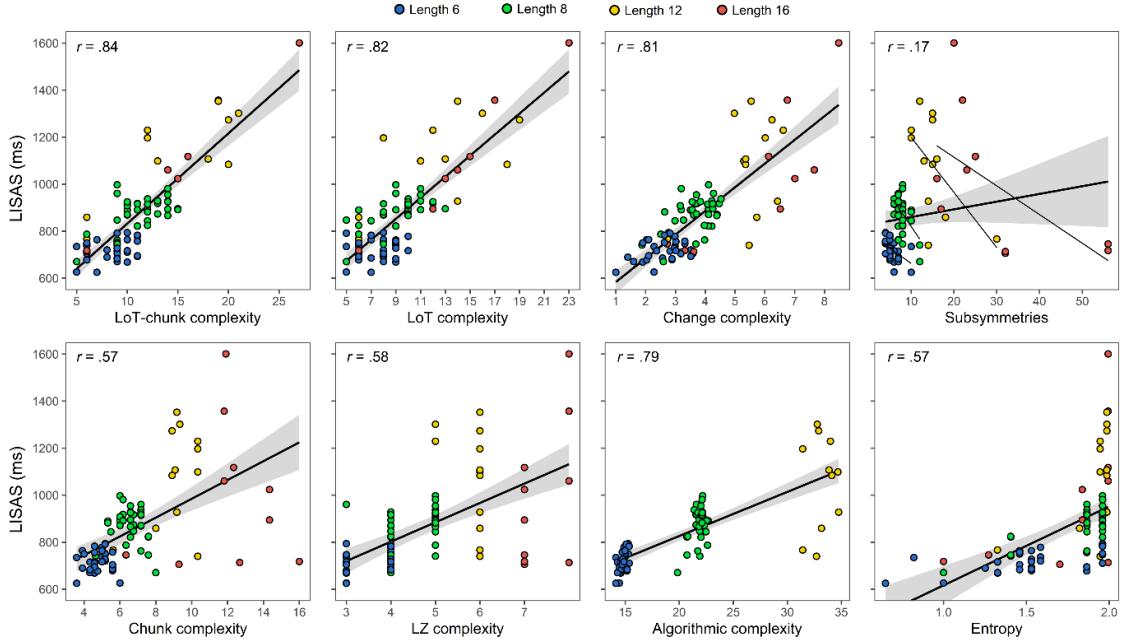


Figure 5: : Linear regressions of average performance per sequence (LISAS, in ms) with eight different predictors of interest when combining data from experiments with auditory sequences of 4 different lengths. Each marker corresponds to one sequence. Sequences of different lengths are indicated by different markers only for illustration purposes (the length factor was not taken into account when computing the correlation,  $r$ , coefficient). 16-items long sequences (as well as one 12-items sequence) could not be included in the regression with algorithmic complexity. Regressions lines for each sequence length were added in the subsymmetries plot, in order to illustrate the fact that negative correlations were observed when each length was considered separately. Note that the average performance data presented here does not take into account the effects of surprise, inter-subject, or inter-experiment variability.

## General discussion

The main goal of this series of experiments was to evaluate the mental representation of binary sequences and to test the adequacy of a formal language of thought previously proposed to account for geometrical sequences (Amalric et al., 2017). Similar models were proposed in the past (e.g. Leeuwenberg, 1969; Restle, 1970; Simon & Kotovsky, 1963), but they were not submitted to a full experimental validation, particularly in comparison to the most recent approaches to sequence complexity assessment. Moreover, we sought to distinguish the effects related to statistical transition-probability learning, which are unavoidable when dealing with temporal sequences of stimuli, from the putative influence of rule-based encoding. Across five different experiments with sequences of different lengths, in the auditory but also in the visual modality, we found consistent evidence that a significant part of the variations in sequence encoding performance (as indexed by the capacity to detect sequence violations) was explained by the length of the shortest possible description of the sequence in the proposed formal language (i.e. LoT complexity). These results are consistent with the idea that upon hearing or seeing a binary sequence, subjects form an internal representation corresponding to an abstract and compressed form of the sequence content. It is remarkable that a language merely composed of two simple instructions (“same” and “change”) and their recursive embeddings suffices to model the formation of such a representation. The complexity measure derived from this language was indeed better predictive of the degree of psychological complexity than other sophisticated approaches designed as alternatives to the non-computable Kolmogorov complexity (Aksentijevic & Gibson, 2012; Soler-Toscano et al., 2014).

The assumption that the length of the shortest description in the formal language corre-

sponds to perceived sequence complexity was further corroborated by subjective complexity rating (experiments 1 and 2). Moreover, we found that sequence structure was not the only information encoded by the participants, since the level of surprise derived from the statistical estimation of transition probabilities also consistently helped explaining the variance in violation detection performance. The effects of surprise and of complexity on responses to violations were found to vary differently depending on sequence length, thus providing new insights on how the human brain makes predictions in temporal sequences.

The predictive power of the LoT approach was most notable for the longest sequences tested, in particular for 16 items long sequences (experiment 1;  $r = 98$ ). Indeed, massive differences in miss rates were observed between the sequences predicted to be the least complex ( $A^nB^n$  patterns, with LoT complexity = 6) and those predicted to be the most complex (a set of 10 instructions, LoT complexity = 23), suggesting that subjects simply could not learn the latter efficiently, even after eight or more repetitions. An additional prediction of LoT was verified, namely the fact that the four sequences based on the  $A^nB^n$  pattern were associated with a similar performance level, regardless of  $n$  ( $= 1, 2, 4,$  or  $8$ ). In the language, this is because the complexity of a repetition is proportional to the logarithm of the number of repetitions, rounded up to the nearest integer. For a total number of 16 items, it therefore does not matter when the sequence is decomposed in 2 chunks of 8, 4 chunks of 4, 8 chunks of 2, or 16 chunks of 1: the sum of the weights remains unchanged, leading to a LoT complexity of 6 bits in all cases — and indeed, the observed performance remained stable across such a broad variation ranging from huge chunks to pure alternation (see Figure 3).

The correlation of performance with LoT complexity decreased in subsequent experiments using increasingly shorter sequences, until it became almost absent for sequences compris-

ing only six elements. Rather than an indication of an intrinsic limitation of the language for describing very short binary patterns, we believe that a significant part of this effect relates to differences in working memory demands. The number 6 indeed falls within the usual limits for the number of elements that can be stored in working memory, which is around  $7 \pm 2$  items when there is no compression (Mathy & Feldman, 2012; Miller, 1956). Thus, subjects could have solved the violation detection task without compression, purely by storing each 6-items sequence “as is” in working memory. Similarly, 8-items sequences could have been stored as a mere series of “chunks”, which are thought to be the units of encoding in working memory (Cowan, 2010; Cowan et al., 2004; Luck & Vogel, 1997; Mathy & Feldman, 2012), without any recursive embedding. All in all, an increasingly greater need to rely on compression would explain why the predictive power of LoT complexity increases with sequence length.

Although the definition of working memory chunks as “a collection of elements having strong associations with one another” (Cowan, 2001; Gobet et al., 2001) is too vague to be rigorously tested using the present data, it is easy to imagine that both conceptions can lead to similar predictions (sequences composed of a small number of small chunks also have a short description in our language). Note however that, when considering all tested sequences, LoT complexity outperformed the “chunk complexity” predictor, for which chunks are defined using consecutive repetitions of the same item. In fact, a crucial feature of our theory lies in going beyond a simple concatenation of chunks and forming recursively embedded or nested representations, that is the ability to represent “chunks of chunks” or “repetitions of repetitions”. Indeed, the construction of recursively nested structured has been proposed as a core human ability, which sets us apart from other primates (Conway & Christiansen, 2001; Dehaene et al., 2015; Fitch & Hauser, 2004;

Hauser et al., 2002). Our results support the idea that the inclusion of such feature is essential to explain human behavior when working memory capacity is exceeded and compression is most beneficial.

The fact that we reached such a conclusion using the simplest type of temporal sequences (binary sequences) and a simple deviant detection task (rather than the more demanding recall, completion or production tasks used in the previous literature) is consistent with Fitch’s “dendrophilia hypothesis” (Fitch, 2014) which states that “humans have a multi-domain capacity and proclivity to infer tree structures from strings” even in the simplest cases. The present work provides a foundation for future experiments in non-human primates, which would allow us to test the second aspect of this hypothesis, namely that this capacity for building recursive tree structures is only available to humans (Dehaene et al., 2015; Fitch, 2014; Hauser et al., 2002). In non-human primates, we postulate that a simpler language will suffice to account for sequence coding.

Numerous other frameworks for the estimation of pattern complexity have been proposed in the past, such as change complexity (Aksentijevic & Gibson, 2012), algorithmic complexity (Gauvrit et al., 2014, 2016; Soler-Toscano et al., 2014), subsymmetries (Alexander & Carey, 1968) or entropy (see also Glanzer & Clark, 1963; Psotka, 1975; Vitz, 1968, 2019; Vitz & Todd, 1969). These models are often based on quantitative aspects of information, such as the length, the number of transitions or runs, the probability of those transitions, the number of symmetries, or the number of changes. Although they all show some level of success in predicting behavior, they fail to capture recursive nesting, which as noted above seem to be an essential factor in human cognition (Dehaene et al., 2015; Hauser et al., 2002). The same limitation applies to the Lempel-Zif data compression algorithm, which compresses sequences by storing in memory a set of unique substrings that can

occur at different location in a sequence. Although it may seem psychologically relevant, this specific algorithm is unable to consider relationships between substrings mediated by an abstract, higher-level operation of repetition or change, as a LoT model does. In addition, this algorithm does not take advantage of contiguous repetitions. Conversely, the notion of repetition with variations is central to the success of our language. Others have also proposed that humans possess a “repetition detector”, as they are much better to learn repetition-based grammars than other forms of simple grammars (Endress et al., 2007). Repetition detection may already be present at birth, which suggests that it may be an innate neurocognitive function, perhaps essential for language acquisition (Gervain et al., 2008). It may therefore not be surprising that nested repetition with variation suffices to account for the human memory for sequences, and that models that do not incorporate it struggle to replicate human behavior.

Following others in the domain of concept learning (e.g. Piantadosi et al., 2012, 2016), the approach adopted here assumes that binary sequences are encoded using a specific cognitive system that manipulates abstract, symbolic representations — a language of thought with recursive calls to a limited number of primitive operations. Thus, the present proposal does not merely provide a numerical value for complexity, but also a parse tree and a precise internal format of representation, both of which could possibly be tested in future behavioral or brain-imaging experiments.

Although the current study is based on the use of a "fixed" language, with predetermined rules and associated weights, some evidence suggests that a better description of human behavior can be achieved by incorporating a probabilistic component to the modeling. This approach, advocated by Piantadosi & Jacobs (2016) under the term *probabilistic language of thought* (pLOT), consists in using Bayesian probabilistic inference to estimate

the likelihood of the existence of some set of rules (a proposed formal language), given the observed data. It has been shown to be especially efficient in modeling concept learning, for instance by replicating the patterns of errors throughout learning (Goodman et al., 2008; Piantadosi et al., 2012, 2016). This approach was also adopted to investigate how humans assess randomness in their environment. Human biases in subjective randomness judgments (e.g. Kahneman & Tversky, 1972; Lopes & Oden, 1987) could be explained by assuming that the representation of randomness results from a statistical inference about the processes that generated the sequence, i.e. an estimation of the probability that a given regular process produced it (Griffiths et al., 2018). A good fit to human behavior was obtained without using the full power of Turing machines, but only finite-state automata with a stack, which are able to recognize repetition, alternation or symmetry (Griffiths et al., 2018; Griffiths & Tenenbaum, 2003). Thus, despite fundamental differences (notably, deterministic versus probabilistic languages), the pLOT theory shares with our approach the need to consider similar types of primitive operations. Given the strong links between subjective randomness and complexity, we can reasonably expect that our formal language may also predict whether a pattern is perceived as random or not – this possibility remains to be tested in future work.

Beside the learning of conceptual knowledge and work on subjective randomness, a pLOT approach was also used to model the learning of spatial sequences: to study the cross-modal transfer of sequence knowledge (Yildirim & Jacobs, 2015), and to investigate the adequacy of the language of geometry (Romano et al., 2018). Indeed, by using the behavioral data from the octagon task of Amalric et al. (2017), Romano et al. (2018) showed that the primitives included in the language of geometry were all required in order to best account for human behavior. In spite of its successes, a number of questions and potential

limitations of the LoT approach remain. First, the construction of our formal language implied methodological choices that could be considered as arbitrary or at least requiring more experimental validation. The primitive instructions included in our formal language were chosen for their alleged simplicity and because they suffice to represent any binary sequence. Other primitives could be tested (e.g. counting and a system of arithmetic; or temporal inversion or “mirroring”, see Jiang et al., 2018). Furthermore, modifications of the weights associated with each instruction or their number of repetitions may lead to different estimates of complexity. Finding the correct language for a given population is crucial, especially in the context of the debate on the uniqueness of human sequence processing skills, and specific statistical methodologies need to be developed for this purpose. As mentioned earlier, the pLOT approach which, using Bayesian inference, allows to find the most likely concepts and rules from a grammatically structured hypothesis space containing several candidates, appears to be a very promising approach for that purpose (Goodman et al., 2008; Piantadosi & Jacobs, 2016; Romano et al., 2018). Nevertheless, we also found that some of the minimal expressions produced by this language did not fit well with the way participants represent some sequences. The addition of the constraint that the minimal parse tree should respect the chunks or runs of consecutive repetitions, and never split any such chunk, was found to lead to a noticeable improvement in model fit. We speculate that this finding reflects the way participants build their internal representation of sequences: since the space of possible programs is immense, they would restrict the search to only those programs that, at the lowest level, generate the observed consecutive runs in the sequence. The perceptual dominance of the runs could act as a bottleneck, an initial grouping that would then restrict the sequence parsing process (as is sometimes assumed in some complexity estimation models; see e.g. Vitz & Todd,

1969). A better characterization of this parsing process during sequence learning could help address the current limitations of our language.

Another limitation is that, although we argued that the capacity to represent sequences using hierarchically embedded or nested descriptions is an essential feature of human behavior (Dehaene et al., 2015), about half of the minimal expressions for the sequences that we used included only two hierarchical levels ( a single level of embedding) (the average hierarchical depth was 2.5). Only a few sequences such as AABBABABAABBABA explicitly required repetitions of repetitions of repetitions. Although our model correctly predicted their subjective and objective complexity (see Figure 3), and although embedding is an effective compression process, more research is needed to probe whether human participants always consider such deep levels of embedding as beneficial in the processing of short auditory sequences. Increasing the hierarchical depth may imply an additional processing cost, making it useful only in specific situations (e.g. for more demanding learning tasks or with long sequences).

Finally, our approach assumes that the mental compression of sequences does not necessarily occur at the level of the sensory events (i.e. grouping contiguous identical elements) but at the more abstract level of the relationships between events. Besides its success in predicting the psychological complexity of sequences of tones, one argument in favor of such an abstract symbolic representation is that it fitted equally well the complexity of visual binary sequences. However, it could be proposed that the mental encoding of temporal sequence does not involve a modal, domain-general processing mechanisms, but rather two similarly organized modality-specific systems, or even a single modality-specific cognitive system dedicated to auditory processing; visual sequences would then be converted into an auditory representation prior to compression. Indeed, we observed a lower performance

and slower responses in the visual compared to the auditory modality, a difference which has been postulated to reflect a dominance of the auditory system for the encoding of temporal information (Conway & Christiansen, 2005; Glenberg et al., 1989; Guttman et al., 2005). One potential strategy for performing the task of experiment 5 with visual stimuli could have been a subvocal naming of the items, and a maintenance in working memory using the phonological loop (Baddeley, 1992; Baddeley & Hitch, 1974). Further investigation is required to resolve these points, perhaps by relying on other sensory modalities, by testing transfer across modalities, or by using brain-imaging to determine the sensory versus higher-level nature of the brain mechanisms at play. We merely note here that activation of supra-modal prefrontal cortices has been reported during sequence processing (e.g. Huettel et al., 2002; Wang et al., 2019); that the existence of an automatic visual-to-auditory conversion in sequence processing has been challenged (McAuley & Henry, 2010); and that the existence of an abstract representation of sequences as proposed here, allowing a transfer of knowledge across modalities, is already supported by some behavioral data (see Yildirim & Jacobs, 2015).

The violation detection task used in the present study implied the learning of a specific and deterministic sequence in each block, which was repeated multiple times with predictable timings. Our results, however, indicate that the statistical properties of the original sequence were also computed in parallel to the compression process and used for prediction, since, for a given sequence, performance varied according to the level of surprise, i.e. the transition probability of the deviant sound in the context of the current sequence. For equal complexity, we observed a higher accuracy and faster response times for deviants that induced less frequent transitions. The observation that transition probability affects behavior even within a deterministic sequence (see also Maheu et al., 2020), as opposed

to the stochastic sequences that were used in previous studies of statistical learning (e.g. Huettel et al., 2002; Mars et al., 2008; Garrido et al., 2013; Meyniel et al., 2016; Meyniel and Dehaene, 2017; Maheu et al., 2019), suggests that the learning of transition probabilities between items may occur automatically and in parallel to compression in working memory. This is compatible with the large amount of evidence showing that the brain encodes statistical regularities in sensory inputs in an implicit and unconscious manner (Barascud et al., 2016; Bendixen et al., 2009; McDermott et al., 2013; Paavilainen, 2013; Saffran et al., 1996). Since the effect of surprise occurred over and above any effect of sequence complexity, it also suggests that this statistical learning system is distinct from the more strategic system based on the learning of the deterministic sequence structure. Again, this is compatible with prior brain imaging results on the local-global paradigm, which indicate that the mismatch negativity (MMN), sensitive to local transition probability, can be dissociated from the P3b response associated with the acquisition of the global sequence (Bekinschtein et al., 2009; Strauss et al., 2015; Wacongne et al., 2011).

When pooling datasets from experiments with different sequence lengths, the linear mixed models with surprise and complexity as predictors fitted the data better than models including one predictor alone, indicating that those two predictors captured distinct variance. However, one may note that the size of the surprise effect varied across experiments. Surprise and complexity showed opposite patterns, with a stronger effect of complexity for longer sequences than for short ones and conversely, a strong effect of surprise only with the shortest sequences. Given the evidence that we just cited, showing that transition probabilities are constantly being computed unconsciously, the most likely interpretation is probably that task difficulty increased with sequence length and resulted in longer response times, thus masking the contribution of statistical learning and rendering it more

difficult to detect. To evaluate this idea, future work should use event-related potentials such as the MMN, which may provide a more sensitive measure of transition-probability learning.-

Finally, we found a complexity effect even when subjects responded to “super-deviants” items, i.e. outlier sounds that could be detected without any knowledge of the sequence because their identity itself was novel. We suggest two putative interpretations of this unexpected effect. First, it could be due to the increased attentional load associated with more complex sequences. Essentially, participants would be placed in a dual-task situation of having to attend to two things at once: the complex sequence and the occasional deviants. In support of this idea, increased attentional load has indeed been found associated to sequence learning impairment in dual-task experiments (see Shanks et al., 2005).

A second interpretation, within the predictive coding framework, is that deviance detection, even for extremely salient deviants, is easier for predictable than for unpredictable stimuli. Indeed, Southwell and Chait (2018) found a larger brain response to deviant stimuli within a regular sequence than within a random sequence of tones. The authors propose that it could reflect a difference in the *precision* or predictability associated with the flow of sensory information. Indeed, in addition to the prediction regarding the content of incoming stimuli (manifested by prediction error signals), recent versions of predictive coding theories also formalize the concept of precision, which corresponds to the reliability of the prediction (Auksztulewicz et al., 2017; Feldman & Friston, 2010; Heilbron & Chait, 2018; Rao, 2005). Precision would manifest itself as a gain modulation of the relevant neural units (which is tightly related to attention), with increased precision leading to an increasing sensitivity to the predicted stimuli. This theory can explain the increased and sustained neuronal responses observed in a highly predictable context (Auksztulewicz et

al., 2017; Barascud et al., 2016; Southwell et al., 2017; Southwell & Chait, 2018). The present complexity effect observed for super-deviants may thus indicate that responses to completely unexpected events were modulated by the degree of predictability of the pattern, which itself depends upon the complexity of the pattern. A precision-weighting mechanism would thus explain why greater complexity leads to slower response times to any kind of violations in our violation detection task. Overall, the distinct contributions of surprise and complexity underline the joint contributions of statistical versus rule-based information in temporal sequence processing.

## Conclusion

Our study provides a first demonstration that, even after accounting for statistical transition-probability learning, responses to sequence violations can be used to uncover the properties of the abstract mental language used by individuals to encode sequential patterns. The present proposal, which takes the form of a psychologically plausible formal language composed of a restricted set of simple rules, proved to be more effective than alternative approaches in modeling the human memory for simple sequences. The observed relationship between sequence complexity and performance in the detection of violations is consistent with the idea that the brain acts as a compressor of incoming information that captures regularities and uses them to predict the remainder of the sequence. The present non-verbal passive paradigm paves the way to future neurophysiological recording studies that would probe the similarities and differences between humans and other species (Wang et al., 2015) or test the abilities of preverbal infants (Basirat et al., 2014). A fundamental question for future research is whether the same formal language can explain sequence processing in other primate species, or if such a language is unique to humans (Hauser et

al., 2002).

- Abla, D., & Okano, K. (2009). Visual statistical learning of shape sequences: An ERP study. *Neuroscience Research*, 64(2), 185–190. <https://doi.org/10.1016/j.neures.2009.02.013>
- Akaike, H. (1998). Information Theory and an Extension of the Maximum Likelihood Principle. In E. Parzen, K. Tanabe, & G. Kitagawa (Eds.), *Selected Papers of Hirotugu Akaike* (pp. 199–213). Springer. [https://doi.org/10.1007/978-1-4612-1694-0\\_15](https://doi.org/10.1007/978-1-4612-1694-0_15)
- Aksentijevic, A., & Gibson, K. (2012). Complexity equals change. *Cognitive Systems Research*, 15–16, 1–16. <https://doi.org/10.1016/j.cogsys.2011.01.002>
- Al Roumi, F., Marti, S., Wang, L., Amalric, M., & Dehaene, S. (2020). An abstract language of thought for spatial sequences in humans. *BioRxiv*, 2020.01.16.908665. <https://doi.org/10.1101/2020.01.16.908665>
- Alexander, C., & Carey, S. (1968). Subsymmetries. *Perception & Psychophysics*, 4(2), 73–77. <https://doi.org/10.3758/BF03193113>
- Amalric, M., Wang, L., Pica, P., Figueira, S., Sigman, M., & Dehaene, S. (2017). The language of geometry: Fast comprehension of geometrical primitives and rules in human adults and preschoolers. *PLOS Computational Biology*, 13(1), e1005273. <https://doi.org/10.1371/journal.pcbi.1005273>
- Auksztulewicz, R., Barascud, N., Cooray, G., Nobre, A. C., Chait, M., & Friston, K. (2017). The cumulative effects of predictability on synaptic gain in the auditory processing stream. *Journal of Neuroscience*, 37(28), 6751–6760.
- Baddeley, A. (1992). Working memory. *Science*, 255(5044), 556–559. <https://doi.org/10.1126/science.1736359>
- Baddeley, A. D., & Hitch, G. (1974). Working Memory. In G. H. Bower (Ed.), *Psychology of Learning and Motivation* (Vol. 8, pp. 47–89). Academic Press. [https://doi.org/10.1016/S0079-7421\(08\)60452-1](https://doi.org/10.1016/S0079-7421(08)60452-1)
- Barascud, N., Pearce, M. T., Griffiths, T. D., Friston, K. J., & Chait, M. (2016). Brain responses in humans reveal ideal observer-like sensitivity to complex acoustic patterns. *Proceedings of the National Academy of Sciences*, 113(5), E616–E625. <https://doi.org/10.1073/pnas.1508523113>
- Basirat, A., Dehaene, S., & Dehaene-Lambertz, G. (2014). A hierarchy of cortical responses to sequence violations in three-month-old infants. *Cognition*, 132(2), 137–150. <https://doi.org/10.1016/j.cognition.2014.03.013>
- Bates, D., Mächler, M., Bolker, B., & Walker, S. (2015). Fitting Linear Mixed-Effects Models Using lme4. *Journal of Statistical Software*, 67(1). <https://doi.org/10.18637/jss.v067.i01>
- Bekinschtein, T. A., Dehaene, S., Rohaut, B., Tadel, F., Cohen, L., & Naccache, L. (2009). Neural signature of the conscious processing of auditory regularities. *Proceedings of the National Academy of Sciences*, 106(5), 1672–1677. <https://doi.org/10.1073/pnas.0809667106>
- Belkaid, M., Bousseyrol, E., Cuttoli, R. D., Dongelmans, M., Duranté, E. K., Yahia, T. A., Didienné, S., Hanesse, B., Come, M., Mourot, A., Naudé, J., Sigaud, O., & Faure, P. (2020). Mice adaptively generate choice variability in a deterministic task. *Communications Biology*, 3(1), 1–9. <https://doi.org/10.1038/s42003-020-0759-x>
- Bendixen, A., Schröger, E., & Winkler, I. (2009). I heard that coming: Event-related potential evidence for stimulus-driven prediction in the auditory system. *The Journal of Neuroscience: The Official Journal of the Society for Neuroscience*, 29(26), 8447–8451. <https://doi.org/10.1523/JNEUROSCI.1493-09.2009>
- Brady, T. F., Konkle, T., & Alvarez, G. A. (2009). Compression in visual working memory: Using statistical regularities to form more efficient memory representations. *Journal of Experimental Psychology. General*, 138(4), 487–502. <https://doi.org/10.1037/a0016797>
- Brainard, D. H., & Vision, S. (1997). The psychophysics toolbox. *Spatial Vision*, 10, 433–436.
- Chaitin, G. J. (1969). On the length of programs for computing finite binary sequences: Statistical considerations. *Journal of the ACM (JACM)*, 16(1), 145–159.
- Chao, Z. C., Takaura, K., Wang, L., Fujii, N., & Dehaene, S. (2018). Large-Scale Cortical Networks for Hierarchical Prediction and Prediction Error in the Primate Brain. *Neuron*, 0(0). <https://doi.org/10.1016/j.neuron.2018.10.001>
- Chase, W. G., & Ericsson, K. A. (1982). Skill and Working Memory. In G. H. Bower (Ed.), *Psychology of Learning and Motivation* (Vol. 16, pp. 1–58). Academic Press. [https://doi.org/10.1016/S0079-7421\(08\)60546-0](https://doi.org/10.1016/S0079-7421(08)60546-0)
- Chater, N., & Vitányi, P. (2003). Simplicity: A unifying principle in cognitive science? *Trends in Cognitive Sciences*, 7(1), 39–43. <https://doi.org/10.1016/j.tics.2002.12.005>

- Cognitive Sciences*, 7(1), 19–22. [https://doi.org/10.1016/S1364-6613\(02\)00005-0](https://doi.org/10.1016/S1364-6613(02)00005-0)
- Chomsky, N. (1957). *Syntactic structures*. Mouton.
- Conway, C. M., & Christiansen, M. H. (2001). Sequential learning in non-human primates. *Trends in Cognitive Sciences*, 5(12), 539–546. [https://doi.org/10.1016/S1364-6613\(00\)01800-3](https://doi.org/10.1016/S1364-6613(00)01800-3)
- Conway, C. M., & Christiansen, M. H. (2005). Modality-constrained statistical learning of tactile, visual, and auditory sequences. *Journal of Experimental Psychology. Learning, Memory, and Cognition*, 31(1), 24–39. <https://doi.org/10.1037/0278-7393.31.1.24>
- Cowan, N. (2001). The magical number 4 in short-term memory: A reconsideration of mental storage capacity. *Behavioral and Brain Sciences*, 24(1), 87–114. <https://doi.org/10.1017/S0140525X01003922>
- Cowan, N. (2010). The Magical Mystery Four: How Is Working Memory Capacity Limited, and Why? *Current Directions in Psychological Science*, 19(1), 51–57. <https://doi.org/10.1177/0963721409359277>
- Cowan, N., Chen, Z., & Rouder, J. N. (2004). Constant capacity in an immediate serial-recall task: A logical sequel to Miller (1956). *Psychological Science*, 15(9), 634–640. <https://doi.org/10.1111/j.0956-7976.2004.00732.x>
- Dehaene, S., Meyniel, F., Wacongne, C., Wang, L., & Pallier, C. (2015). The Neural Representation of Sequences: From Transition Probabilities to Algebraic Patterns and Linguistic Trees. *Neuron*, 88(1), 2–19. <https://doi.org/10.1016/j.neuron.2015.09.019>
- Delahaye, J.-P., & Zenil, H. (2012). Numerical evaluation of algorithmic complexity for short strings: A glance into the innermost structure of randomness. *Applied Mathematics and Computation*, 219(1), 63–77. <https://doi.org/10.1016/j.amc.2011.10.006>
- Endress, A. D., Dehaene-Lambertz, G., & Mehler, J. (2007). Perceptual constraints and the learnability of simple grammars. *Cognition*, 105(3), 577–614. <https://doi.org/10.1016/j.cognition.2006.12.014>
- Ericsson, K. A., Chase, W. G., & Faloon, S. (1980). Acquisition of a memory skill. *Science (New York, N.Y.)*, 208(4448), 1181–1182. <https://doi.org/10.1126/science.7375930>
- Falk, R., & Konold, C. (1997). Making sense of randomness: Implicit encoding as a basis for judgment. *Psychological Review*, 104(2), 301–318. <https://doi.org/10.1037/0033-295X.104.2.301>
- Faugeras, F., Rohaut, B., Weiss, N., Bekinschtein, T. A., Galanaud, D., Puybasset, L., Bolgert, F., Sergent, C., Cohen, L., Dehaene, S., & Naccache, L. (2011). Probing consciousness with event-related potentials in the vegetative state. *Neurology*, 77(3), 264–268. <https://doi.org/10.1212/WNL.0b013e3182217ee8>
- Feldman, H., & Friston, K. (2010). Attention, Uncertainty, and Free-Energy. *Frontiers in Human Neuroscience*, 4. <https://doi.org/10.3389/fnhum.2010.00215>
- Feldman, J. (2000). Minimization of Boolean complexity in human concept learning. *Nature*, 407(6804), 630–633. <https://doi.org/10.1038/35036586>
- Feldman, J. (2003). The Simplicity Principle in Human Concept Learning. *Current Directions in Psychological Science*, 12(6), 227–232. <https://doi.org/10.1046/j.0963-7214.2003.01267.x>
- Fitch, W. T. (2014). Toward a computational framework for cognitive biology: Unifying approaches from cognitive neuroscience and comparative cognition. *Physics of Life Reviews*, 11(3), 329–364. <https://doi.org/10.1016/j.plrev>
- Fitch, W. T., & Hauser, M. D. (2004). Computational constraints on syntactic processing in a nonhuman primate. *Science (New York, N.Y.)*, 303(5656), 377–380. <https://doi.org/10.1126/science.1089401>
- Fodor, J. A. (1975). *The language of thought* (Vol. 5). Harvard university press.
- Freides, D. (1974). Human information processing and sensory modality: Cross-modal functions, information complexity, memory, and deficit. *Psychological Bulletin*, 81(5), 284.
- Friston, K. (2010). The free-energy principle: A unified brain theory? *Nature Reviews Neuroscience*, 11(2), 127–138. <https://doi.org/10.1038/nrn2787>
- Fujii, N. (2003). Representation of Action Sequence Boundaries by Macaque Prefrontal Cortical Neurons. *Science*, 301(5637), 1246–1249. <https://doi.org/10.1126/science.1086872>
- Garrido, M. I., Kilner, J. M., Stephan, K. E., & Friston, K. J. (2009). The mismatch negativity: A review

- of underlying mechanisms. *Clinical Neurophysiology*, *120*(3), 453–463. <https://doi.org/10.1016/j.clinph.2008.11.029>
- Garrido, M. I., Sahani, M., & Dolan, R. J. (2013). Outlier responses reflect sensitivity to statistical structure in the human brain. *PLoS Computational Biology*, *9*(3), e1002999. <https://doi.org/10.1371/journal.pcbi.1002999>
- Gauvrit, N., Singmann, H., Soler-Toscano, F., & Zenil, H. (2016). Algorithmic complexity for psychology: A user-friendly implementation of the coding theorem method. *Behavior Research Methods*, *48*(1), 314–329. <https://doi.org/10.3758/s13428-015-0574-3>
- Gauvrit, N., Zenil, H., Delahaye, J.-P., & Soler-Toscano, F. (2014). Algorithmic complexity for short binary strings applied to psychology: A primer. *Behavior Research Methods*, *46*(3), 732–744. <https://doi.org/10.3758/s13428-013-0416-0>
- Gervain, J., Macagno, F., Cogoi, S., Peña, M., & Mehler, J. (2008). The neonate brain detects speech structure. *Proceedings of the National Academy of Sciences*, *105*(37), 14222–14227. <https://doi.org/10.1073/pnas.0806530105>
- Gilchrist, A. L., Cowan, N., & Naveh-Benjamin, M. (2008). Working Memory Capacity for Spoken Sentences Decreases with Adult Aging: Recall of Fewer, but not Smaller Chunks in Older Adults. *Memory (Hove, England)*, *16*(7), 773–787. <https://doi.org/10.1080/09658210802261124>
- Gil-da-Costa, R., Stoner, G. R., Fung, R., & Albright, T. D. (2013). Nonhuman primate model of schizophrenia using a noninvasive EEG method. *Proceedings of the National Academy of Sciences*, *110*(38), 15425–15430. <https://doi.org/10.1073/pnas.1312264110>
- Glanzer, M., & Clark, W. H. (1963). Accuracy of perceptual recall: An analysis of organization. *Journal of Verbal Learning and Verbal Behavior*, *1*(4), 289–299. [https://doi.org/10.1016/S0022-5371\(63\)80008-0](https://doi.org/10.1016/S0022-5371(63)80008-0)
- Glenberg, A. M., Mann, S., Altman, L., Forman, T., & Procise, S. (1989). Modality effects in the coding reproduction of rhythms. *Memory & Cognition*, *17*(4), 373–383. <https://doi.org/10.3758/BF03202611>
- Gobet, F., Lane, P. C. R., Croker, S., Cheng, P. C.-H., Jones, G., Oliver, I., & Pine, J. M. (2001). Chunking mechanisms in human learning. *Trends in Cognitive Sciences*, *5*(6), 236–243. [https://doi.org/10.1016/S1364-6613\(00\)01662-4](https://doi.org/10.1016/S1364-6613(00)01662-4)
- Goodman, N. D., Tenenbaum, J. B., Feldman, J., & Griffiths, T. L. (2008). A Rational Analysis of Rule-Based Concept Learning. *Cognitive Science*, *32*(1), 108–154. <https://doi.org/10.1080/03640210701802071>
- Goodman, N. D., Ullman, T. D., & Tenenbaum, J. B. (2011). Learning a theory of causality. *Psychological Review*, *118*(1), 110–119. <https://doi.org/10.1037/a0021336>
- Griffiths, T. L., Daniels, D., Austerweil, J. L., & Tenenbaum, J. B. (2018). Subjective randomness as statistical inference. *Cognitive Psychology*, *103*, 85–109. <https://doi.org/10.1016/j.cogpsych.2018.02.003>
- Griffiths, T. L., & Tenenbaum, J. B. (2003). Probability, algorithmic complexity, and subjective randomness. *Proceedings of the Annual Meeting of the Cognitive Science Society*, *25*.
- Guttman, S. E., Gilroy, L. A., & Blake, R. (2005). Hearing what the eyes see: Auditory encoding of visual temporal sequences. *Psychological Science*, *16*(3), 228–235. <https://doi.org/10.1111/j.0956-7976.2005.00808.x>
- Hauser, M. D., Chomsky, N., & Fitch, W. T. (2002). The Faculty of Language: What Is It, Who Has It, and How Did It Evolve? *Science*, *298*(5598), 1569–1579. <https://doi.org/10.1126/science.298.5598.1569>
- Hauser, M. D., Newport, E. L., & Aslin, R. N. (2001). Segmentation of the speech stream in a non-human primate: Statistical learning in cotton-top tamarins. *Cognition*, *78*(3), B53–B64. [https://doi.org/10.1016/S0010-0277\(00\)00132-3](https://doi.org/10.1016/S0010-0277(00)00132-3)
- Hauser, M. D., & Watumull, J. (2017). The Universal Generative Faculty: The source of our expressive power in language, mathematics, morality, and music. *Journal of Neurolinguistics*. <https://doi.org/10.1016/j.jneuroling.2017.07.061>
- Heilbron, M., & Chait, M. (2018). Great Expectations: Is there Evidence for Predictive Coding in Auditory Cortex? *Neuroscience*, *389*, 54–73. <https://doi.org/10.1016/j.neuroscience.2017.07.061>
- Huettel, S. A., Mack, P. B., & McCarthy, G. (2002). Perceiving patterns in random series: Dynamic processing of sequence in prefrontal cortex. *Nature Neuroscience*, *5*(5), 485–490. <https://doi.org/10.1038/nn841>
- Jiang, X., Long, T., Cao, W., Li, J., Dehaene, S., & Wang, L. (2018). Production of Supra-regular Spatial Sequences by Macaque Monkeys. *Current Biology: CB*, *28*(12), 1851–1859.e4. <https://doi.org/10.1016/j.cub.2018.04.047>

- Kenward, M. G., & Roger, J. H. (1997). Small sample inference for fixed effects from restricted maximum likelihood. *Biometrics*, 53(3), 983–997.
- Kirkham, N. Z., Slemmer, J. A., & Johnson, S. P. (2002). Visual statistical learning in infancy: Evidence for a domain general learning mechanism. *Cognition*, 83(2), B35–B42. [https://doi.org/10.1016/S0010-0277\(02\)00004-5](https://doi.org/10.1016/S0010-0277(02)00004-5)
- Kleiner, M., Brainard, D., Pelli, D., Ingling, A., Murray, R., & Broussard, C. (2007). What's new in Psychtoolbox-3. *Perception*, 36(14), 1.
- Kolmogorov, A. N. (1968). Three approaches to the quantitative definition of information. *International Journal of Computer Mathematics*, 2(1–4), 157–168.
- Kuznetsova, A., Brockhoff, P. B., & Christensen, R. H. (2017). lmerTest package: Tests in linear mixed effects models. *Journal of Statistical Software*, 82(13), 1–26.
- Lashley, K. S. (1951). The problem of serial order in behavior. In L. A. Jeffress & L. A. (Ed) Jeffress (Eds.), *Cerebral mechanisms in behavior; the Hixon Symposium*. (1952-04498-003; pp. 112–146). Wiley.
- Leeuwenberg, E. L. (1969). Quantitative specification of information in sequential patterns. *Psychological Review*, 76(2), 216–220. <https://doi.org/10.1037/h0027285>
- Leeuwenberg, E. L. J. (1971). A Perceptual Coding Language for Visual and Auditory Patterns. *The American Journal of Psychology*, 84(3), 307–349. JSTOR. <https://doi.org/10.2307/1420464>
- Lempel, A., & Ziv, J. (1976). On the Complexity of Finite Sequences. *IEEE Transactions on Information Theory*, 22(1), 75–81. <https://doi.org/10.1109/TIT.1976.1055501>
- Luck, S. J., & Vogel, E. K. (1997). The capacity of visual working memory for features and conjunctions. *Nature*, 390(6657), 279–281. <https://doi.org/10.1038/36846>
- MacGregor, J. (1987). Short-Term Memory Capacity: Limitation or Optimization? *Psychological Review*, 94(1), 107–108.
- Maheu, M., Dehaene, S., & Meyniel, F. (2019). Brain signatures of a multiscale process of sequence learning in humans. *eLife*, 8. <https://doi.org/10.7554/eLife.41541>
- Maheu, M., Meyniel, F., & Dehaene, S. (2020). Rational arbitration between statistics and rules in human sequence learning. *BioRxiv*, 2020.02.06.937706. <https://doi.org/10.1101/2020.02.06.937706>
- Marcus, G. F., Vijayan, S., Bandi Rao, S., & Vishton, P. M. (1999). Rule learning by seven-month-old infants. *Science*, 283(5398), 77–80.
- Mars, R. B., Debener, S., Gladwin, T. E., Harrison, L. M., Haggard, P., Rothwell, J. C., & Bestmann, S. (2008). Trial-by-Trial Fluctuations in the Event-Related Electroencephalogram Reflect Dynamic Changes in the Degree of Surprise. *Journal of Neuroscience*, 28(47), 12539–12545. <https://doi.org/10.1523/JNEUROSCI.2925-08.2008>
- Mathy, F., & Feldman, J. (2012). What's magic about magic numbers? Chunking and data compression in short-term memory. *Cognition*, 122(3), 346–362. <https://doi.org/10.1016/j.cognition.2011.11.003>
- McAuley, J. D., & Henry, M. J. (2010). Modality effects in rhythm processing: Auditory encoding of visual rhythms is neither obligatory nor automatic. *Attention, Perception, & Psychophysics*, 72(5), 1377–1389. <https://doi.org/10.3758/APP.72.5.1377>
- McDermott, J. H., Schemitsch, M., & Simoncelli, E. P. (2013). Summary statistics in auditory perception. *Nature Neuroscience*, 16(4), 493–498. <https://doi.org/10.1038/nn.3347>
- Meyer, T., & Olson, C. R. (2011). Statistical learning of visual transitions in monkey inferotemporal cortex. *Proceedings of the National Academy of Sciences*, 108(48), 19401–19406. <https://doi.org/10.1073/pnas.1112895108>
- Meyniel, F., & Dehaene, S. (2017). Brain networks for confidence weighting and hierarchical inference during probabilistic learning. *Proceedings of the National Academy of Sciences*, 114(19), E3859–E3868. <https://doi.org/10.1073/pnas.1615773114>
- Meyniel, F., Maheu, M., & Dehaene, S. (2016). Human Inferences about Sequences: A Minimal Transition Probability Model. *PLOS Computational Biology*, 12(12), e1005260. <https://doi.org/10.1371/journal.pcbi.1005260>
- Miller, G. A. (1956). The magical number seven, plus or minus two: Some limits on our capacity for

- processing information. *Psychological Review*, 63(2), 81–97. <https://doi.org/10.1037/h0043158>
- Näätänen, R. (2003). Mismatch negativity: Clinical research and possible applications. *International Journal of Psychophysiology*, 48(2), 179–188. [https://doi.org/10.1016/S0167-8760\(03\)00053-9](https://doi.org/10.1016/S0167-8760(03)00053-9)
- Oskarsson, A. T., Van Boven, L., McClelland, G. H., & Hastie, R. (2009). What's next? Judging sequences of binary events. *Psychological Bulletin*, 135(2), 262–285. <https://doi.org/10.1037/a0014821>
- Paavilainen, P. (2013). The mismatch-negativity (MMN) component of the auditory event-related potential to violations of abstract regularities: A review. *International Journal of Psychophysiology: Official Journal of the International Organization of Psychophysiology*, 88(2), 109–123. <https://doi.org/10.1016/j.ijpsycho.2013.03>
- Patel, A. D., Iversen, J. R., Chen, Y., & Repp, B. H. (2005). The influence of metricality and modality on synchronization with a beat. *Experimental Brain Research*, 163(2), 226–238. <https://doi.org/10.1007/s00221-004-2159-8>
- Peng, Z., Genewein, T., & Braun, D. A. (2014). Assessing randomness and complexity in human motion trajectories through analysis of symbolic sequences. *Frontiers in Human Neuroscience*, 8. <https://doi.org/10.3389/fnhum.2014.00389>
- Piantadosi, S. T., & Jacobs, R. A. (2016). Four Problems Solved by the Probabilistic Language of Thought. *Current Directions in Psychological Science*, 25(1), 54–59. <https://doi.org/10.1177/0963721415609581>
- Piantadosi, S. T., Tenenbaum, J. B., & Goodman, N. D. (2012). Bootstrapping in a language of thought: A formal model of numerical concept learning. *Cognition*, 123(2), 199–217. <https://doi.org/10.1016/j.cognition.2011.11.00>
- Piantadosi, S. T., Tenenbaum, J. B., & Goodman, N. D. (2016). The logical primitives of thought: Empirical foundations for compositional cognitive models. *Psychological Review*, 123(4), 392–424. <https://doi.org/10.1037/a0039>
- Psotka, J. (1975). Simplicity, symmetry, and syntely: Stimulus measures of binary pattern structure. *Memory & Cognition*, 3(4), 434–444. <https://doi.org/10.3758/BF03212938>
- R Core Team. (2017). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria. <https://www.R-project.org/>
- Rao, R. P. N. (2005). Bayesian inference and attentional modulation in the visual cortex. *NeuroReport*, 16(16), 1843. <https://doi.org/10.1097/01.wnr.0000183900.92901.fc>
- Restle, F. (1970). Theory of serial pattern learning: Structural trees. *Psychological Review*, 77(6), 481–495. <https://doi.org/10.1037/h0029964>
- Restle, F. (1973). Serial pattern learning: Higher order transitions. *Journal of Experimental Psychology*, 99(1), 61–69. <https://doi.org/10.1037/h0034751>
- Restle, F., & Brown, E. R. (1970). Serial Pattern Learning. *Journal of Experimental Psychology*, 83(1, Pt.1), 120–125. <https://doi.org/10.1037/h0028530>
- Romano, S., Salles, A., Amalric, M., Dehaene, S., Sigman, M., & Figueira, S. (2018). Bayesian validation of grammar productions for the language of thought. *PloS One*, 13(7), e0200420. <https://doi.org/10.1371/journal.pone.0200420>
- Romano, S., Sigman, M., & Figueira, S. (2013).  $\$ LT^2C^2\$$ : A language of thought with Turing-computable Kolmogorov complexity. *Papers in Physics*, 5, 050001–050001. <https://doi.org/10.4279/pip.050001>
- Romberg, A. R., & Saffran, J. R. (2010). Statistical learning and language acquisition. *Wiley Interdisciplinary Reviews: Cognitive Science*, 1(6), 906–914. <https://doi.org/10.1002/wcs.78>
- Saffran, J. R., Aslin, R. N., & Newport, E. L. (1996). Statistical Learning by 8-Month-Old Infants. *Science*, 274(5294), 1926–1928. <https://doi.org/10.1126/science.274.5294.1926>
- Shanks, D. R., Rowland, L. A., & Ranger, M. S. (2005). Attentional load and implicit sequence learning. *Psychological Research*, 69(5), 369–382. <https://doi.org/10.1007/s00426-004-0211-8>
- Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3), 379–423.
- Simon, H. A. (1972). Complexity and the representation of patterned sequences of symbols. *Psychological Review*, 79(5), 369–382. <https://doi.org/10.1037/h0033118>
- Simon, H. A., & Kotovsky, K. (1963). Human acquisition of concepts for sequential patterns. *Psychological Review*, 70(6), 534–546. <https://doi.org/10.1037/h0043901>

- Siskind, J. M. (1996). A computational study of cross-situational techniques for learning word-to-meaning mappings. *Cognition*, 61(1), 39–91. [https://doi.org/10.1016/S0010-0277\(96\)00728-7](https://doi.org/10.1016/S0010-0277(96)00728-7)
- Soler-Toscano, F., Zenil, H., Delahaye, J.-P., & Gauvrit, N. (2014). Calculating Kolmogorov Complexity from the Output Frequency Distributions of Small Turing Machines. *PLoS ONE*, 9(5), e96223. <https://doi.org/10.1371/journal.pone.0096223>
- Solomonoff, R. J. (1964). A formal theory of inductive inference. Part I and Part II. *Information and Control*, 7(1), 1–22. [https://doi.org/10.1016/S0019-9958\(64\)90223-2](https://doi.org/10.1016/S0019-9958(64)90223-2)
- Southwell, R., Baumann, A., Gal, C., Barascud, N., Friston, K., & Chait, M. (2017). Is predictability salient? A study of attentional capture by auditory patterns. *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences*, 372(1714). <https://doi.org/10.1098/rstb.2016.0105>
- Southwell, Rosy, & Chait, M. (2018). Enhanced deviant responses in patterned relative to random sound sequences. *Cortex; a Journal Devoted to the Study of the Nervous System and Behavior*, 109, 92–103. <https://doi.org/10.1016/j.cortex.2018.08.032>
- Squires, N. K., Squires, K. C., & Hillyard, S. A. (1975). Two varieties of long-latency positive waves evoked by unpredictable auditory stimuli in man. *Electroencephalography and Clinical Neurophysiology*, 38(4), 387–401. [https://doi.org/10.1016/0013-4694\(75\)90263-1](https://doi.org/10.1016/0013-4694(75)90263-1)
- Strange, B. A., Duggins, A., Penny, W., Dolan, R. J., & Friston, K. J. (2005). Information theory, novelty and hippocampal responses: Unpredicted or unpredictable? *Neural Networks*, 18(3), 225–230. <https://doi.org/10.1016/j.neunet.2004.12.004>
- Strauss, M., Sitt, J. D., King, J.-R., Elbaz, M., Azizi, L., Buiatti, M., Naccache, L., van Wassenhove, V., & Dehaene, S. (2015). Disruption of hierarchical predictive coding during sleep. *Proceedings of the National Academy of Sciences*, 112(11), E1353–E1362. <https://doi.org/10.1073/pnas.1501026112>
- Thul, E., & Toussaint, G. T. (2008). Rhythm Complexity Measures: A Comparison of Mathematical Models of Human Perception and Performance. *Rhythm and Meter*, 6.
- Toussaint, G. T., & Beltran, J. F. (2013). Subsymmetries predict auditory and visual pattern complexity. *Perception*, 42(10), 1095–1100. <https://doi.org/10.1088/p7614>
- Uhrig, L., Dehaene, S., & Jarraya, B. (2014). A Hierarchy of Responses to Auditory Regularities in the Macaque Brain. *Journal of Neuroscience*, 34(4), 1127–1132. <https://doi.org/10.1523/JNEUROSCI.3165-13.2014>
- Vandierendonck, A. (2017). A comparison of methods to combine speed and accuracy measures of performance: A rejoinder on the binning procedure. *Behavior Research Methods*, 49(2), 653–673. <https://doi.org/10.3758/s13428-016-0721-5>
- Vandierendonck, A. (2018). Further Tests of the Utility of Integrated Speed-Accuracy Measures in Task Switching. *Journal of Cognition*, 1(1). <https://doi.org/10.5334/joc.6>
- Vitz, P. C. (1968). Information, run structure and binary pattern complexity. *Perception & Psychophysics*, 3(4), 275–280. <https://doi.org/10.3758/BF03212743>
- Vitz, P. C. (2019). A hierarchical model of binary pattern learning. *Learning and Motivation*, 65, 52–59. <https://doi.org/10.1016/j.lmot.2019.01.002>
- Vitz, P. C., & Todd, T. C. (1969). A coded element model of the perceptual processing of sequential stimuli. *Psychological Review*, 76(5), 433–449. <https://doi.org/10.1037/h0028113>
- Wacongne, C., Labyt, E., Wassenhove, V. van, Bekinschtein, T., Naccache, L., & Dehaene, S. (2011). Evidence for a hierarchy of predictions and prediction errors in human cortex. *Proceedings of the National Academy of Sciences*, 108(51), 20754–20759. <https://doi.org/10.1073/pnas.1117807108>
- Wagenmakers, E.-J., & Farrell, S. (2004). AIC model selection using Akaike weights. *Psychonomic Bulletin & Review*, 11(1), 192–196. <https://doi.org/10.3758/BF03206482>
- Wang, L., Amalric, M., Fang, W., Jiang, X., Pallier, C., Figueira, S., Sigman, M., & Dehaene, S. (2019). Representation of spatial sequences using nested rules in human prefrontal cortex. *NeuroImage*, 186, 245–255. <https://doi.org/10.1016/j.neuroimage.2018.10.061>
- Wang, L., Uhrig, L., Jarraya, B., & Dehaene, S. (2015). Representation of Numerical and Sequential Pat-

- terns in Macaque and Human Brains. *Current Biology*, 25(15), 1966–1974. <https://doi.org/10.1016/j.cub.2015.06.035>
- Wilson, B., Marslen-Wilson, W. D., & Petkov, C. I. (2017). Conserved Sequence Processing in Primate Frontal Cortex. *Trends in Neurosciences*, 40(2), 72–82. <https://doi.org/10.1016/j.tins.2016.11.004>
- Wilson, B., Slater, H., Kikuchi, Y., Milne, A. E., Marslen-Wilson, W. D., Smith, K., & Petkov, C. I. (2013). Auditory Artificial Grammar Learning in Macaque and Marmoset Monkeys. *Journal of Neuroscience*, 33(48), 18825–18835. <https://doi.org/10.1523/JNEUROSCI.2414-13.2013>
- Yildirim, I., & Jacobs, R. A. (2015). Learning multisensory representations for auditory-visual transfer of sequence category knowledge: A probabilistic language of thought approach. *Psychonomic Bulletin & Review*, 22(3), 673–686. <https://doi.org/10.3758/s13423-014-0734-y>

# **Apéndice A**

## **Apéndice del Capítulo 8**

### **A.1. Criterios de exclusión y tratamiento de datos**

Decidimos recopilar datos durante un máximo de 3 semanas o hasta llegar a un total de 100 participantes. A través de restricciones en la plataforma donde se realizó el experimento, los participantes que tardaron más de 4 horas o que no completaron todos las pruebas fueron automáticamente excluidos del análisis. Estábamos preparados para excluir posteriormente los resultados de aquellos participantes cuyas explicaciones verbales denotaban el uso de ayudas externas o métodos fuera del alcance del artículo, como la toma de capturas de pantalla del concepto. Sin embargo, no hubo casos claros de ese comportamiento ( $N = 0$ ).

Además, si bien nuestros criterios de exclusión prerre registrados no abarcaron los casos potenciales de explicaciones escritas que eran legítimas pero indicativas del uso de reglas ajena a la lógica proposicional o a nuestro marco semántico, al final no detectamos ninguno de estos casos. Este resultado alentador es débilmente indicativo de la utilidad de nuestras

cuidadosas consideraciones para construir representaciones semánticas adecuadas, como se menciona en la Sección 8.2.4. Para las explicaciones escritas completas de los participantes, remitimos al lector a los datos crudos cargados en <https://osf.io/gtuwp/>.

La división equilibrada en los dos grupos se manejó a través de la biblioteca psiTurk, que decide el grupo al que se asignará un nuevo trabajador, en función del número actual de experimentos completados en cada grupo.

Ignoramos los rastros individuales de los participantes que en la etapa de generalización eligieron una generalización inconsistente con cualquier explicación válida (pero esto no provocó la exclusión de otras pruebas independientes por parte del mismo participante). Consultar la Sección 8.3 para obtener más detalles.

## A.2. Prueba piloto

Este experimento fue encarado por un prueba piloto con 22 participantes, que ejecutamos con el fin de tener alguna validación de nuestros efectos esperados antes de realizar el pre-registro. Esta prueba piloto utilizó pares de conceptos más complejos, con una longitud mínima de descripción más larga para las dos reglas correspondientes, y donde a menudo era necesario usar tanto *AND* como *OR* en la misma regla. Originalmente, esperábamos una separación que surgiera naturalmente en diferentes grupos, dependiendo de las características de explicación encontradas para la primera prueba. Sin embargo, encontramos una preferencia muy fuerte por las explicaciones que usan únicamente  $\wedge$ , y esto provocó varios cambios en el diseño final del experimento que fue prer-registrado en la versión OSF.

Más precisamente, en nuestra primera prueba en ese piloto, el 81 % ( $N = 18$ ) de

los trabajadores explicó el concepto (incompleto) como una conjunción de tres variables, mientras que solo el 9 % ( $N = 2$ ) lo explicó como una disyunción de dos. Esto sucedió a pesar de que habíamos alargado la explicación de  $\wedge$  con la intención de compensar la relativa facilidad de  $\wedge$  con respecto a  $\vee$  (para evitar que un número estadísticamente inadecuado de participantes se autoseleccionados al caso  $\vee$ ). Este resultado concuerda con el trabajo conocido sobre la relativa dificultad de aprender conceptos con el operador  $\vee$  [Bourne, 1970]. En nuestro marco de más de una regla plausible, una posible explicación a esta disparidad poblacional podría ser que, al buscar características comunes, es natural buscar primero las características individuales que siempre aparecen. Otra explicación podría ser que, en un universo con un número reducido de características, la repetición de muchas de ellas se vuelve muy destacada y, por tanto, la relación entre dificultad y número de conjunciones no es necesariamente monótona. En cualquier caso, este resultado no formó parte del pre-registro, por lo que se presenta aquí solo como una indicación de un efecto interesante a estudiar.

### A.3. Resultados técnicos

Fijemos un conjunto no vacío de variables proposicionales PROP. Una valuación se define formalmente como una función  $v : \text{PROP} \rightarrow \{0, 1\}$  que determina el valor de verdad de las variables proposicionales. Una valuación puede extenderse de la forma estándar para preservar la semántica habitual de los operadores booleanos y así determinar el valor de verdad de las fórmulas proposicionales (que llamamos ‘reglas’ en el contexto de la descripción de conceptos). Decimos que una valuación  $v$  satisface una fórmula  $\varphi$  si  $v(\varphi) = 1$ . Decimos que una fórmula  $\varphi$  es una contingencia si existe una valuación  $v_t$  que

la satisface y una valuación  $v_f$  que no.

Dada una fórmula proposicional  $\varphi$ , definimos  $\text{VAR}(\varphi)$  como el conjunto de variables que aparecen en  $\varphi$ . Por ejemplo, si  $\varphi_e = p_1 \vee (p_2 \wedge \neg p_2)$ , entonces  $\text{VAR}(\varphi_e) = \{p_1, p_2\}$ .

Decimos que una fórmula  $\varphi$  es variable-minimal si no existe otra fórmula  $\psi$  tal que los valores de verdad de  $\varphi$  y  $\psi$  coincidan sobre todas las valuaciones y  $\text{VAR}(\psi) \subsetneq \text{VAR}(\varphi)$ . Por ejemplos, la  $\varphi_e$  previa no es variable-minimal, dado que es equivalente a  $\psi = p_1$ , que usa una variable proposicional menos.

Comenzamos probando un lema muy básico con fines ilustrativos.

**Lema 1.** *Sean  $\varphi_1$  y  $\varphi_2$  dos contingencias tales que  $\text{VAR}(\varphi_1) \cap \text{VAR}(\varphi_2) = \emptyset$ . Entonces existe una valuación  $v_{in}$  tl que  $v_{in}$  satisface  $\varphi_1$  and  $\varphi_2$ , y una valuación  $v_{out}$  no satisface  $\varphi_1$  ni  $\varphi_2$ .*

En otras palabras, el lema dice que cuando tenemos dos conceptos no triviales sobre conjuntos de características que no se superponen, entonces hay al menos un ejemplo (positivo) que satisface ambos conceptos simultáneamente y al menos un ejemplo (negativo) que no satisface ninguno de ellos.

*Demostración.* El hecho de que una valuación satisfaga o no una fórmula  $\varphi$  depende solo de cómo se evalúan las variables proposicionales en  $\text{VAR}(\varphi)$ . Como  $\text{VAR}(\varphi_1) \cap \text{VAR}(\varphi_2) = \emptyset$  y ambas fórmulas son satisfacibles vía algunas  $v_1$  y  $v_2$  respectivamente, podemos construir valuaciones  $v_{in}$  juntando los valores de  $v_1, v_2$  en los conjuntos (disjuntos) de variables de cada fórmula:  $v_{in}(p) = v_1(p)$  si  $p \in \text{VAR}(\varphi_1)$ ,  $v_{in}(p) = v_2(p)$  si  $p \in \text{VAR}(\varphi_2)$ , y  $v_{in}(p) = 0$  en caso contrario.

Análogamente, como  $\varphi_1, \varphi_2$  no son contingencias, existen valuaciones  $\bar{v}_1$  y  $\bar{v}_2$  que no

satisfacen  $\varphi_1$  ni  $\varphi_2$  respectivamente. Usamos estas valuaciones como antes para construir valuaciones  $v_{out}$  que no satisfacen  $\varphi_1$  ni  $\varphi_2$ , como queríamos.  $\square$

**Lemma 2.** *Si  $\varphi$  es una contingencia variable-minimal, y  $p \in \text{VAR}(\varphi)$ , entonces existe una valuación  $v$  tal que  $v$  satisface  $\varphi$  pero  $\tilde{v}$  no, donde  $\tilde{v}$  es la única valuación que coincide con  $v$  excepto en  $p$ .*

*Demostración.* Por el absurdo, supongamos que la conclusión no es válida: que para cualquier valuación, la verdad de  $\varphi$  es independiente de su valor en  $p$ . En este caso, necesariamente  $\{p\} \neq \text{VAR}(\varphi)$ , o de lo contrario  $\varphi$  no sería una contingencia (ya que siempre sería verdadera o siempre falsa).

Sea  $V_\varphi$  el conjunto (no vacío) de valuaciones que satisface  $\varphi$ , y sea  $V_\varphi^{-p}$  su restricción a  $\text{VAR}(\varphi) \setminus \{p\}$ . A partir de  $V_\varphi^{-p}$  podemos construir de forma estándar a través de tablas de verdad, una fórmula  $\tilde{\varphi}$  con  $\text{VAR}(\tilde{\varphi}) = \text{VAR}(\varphi) \setminus \{p\}$  tal que una valuación  $v$  satisface  $\tilde{\varphi}$  si y solo si  $v|_{\text{VAR}(\tilde{\varphi})} \in V_\varphi^{-p}$ . Como la suposición que el valor de  $p$  no importa para  $\varphi$ , tenemos por construcción que  $\varphi$  es equivalente a  $\tilde{\varphi}$ , pero  $\text{VAR}(\tilde{\varphi}) \subsetneq \text{VAR}(\varphi)$ , que contradice la variable-minimalidad de  $\varphi$ .  $\square$

El siguiente teorema muestra la corrección teórica general de nuestra configuración experimental. Dice que si mostramos como ejemplos positivos la intersección completa de dos conceptos no triviales cuyas descripciones mínimas no contienen características en común, y mostramos como ejemplos negativos el complemento de la unión de ambos conceptos, cualquier regla utilizada para explicar el concepto visto (incompleto) debe utilizar un superconjunto de las variables utilizadas para describir mínimamente uno de estos conceptos. De lo contrario, la regla elegida sería incompatible con los datos conocidos.

**Theorem 3.** Sean  $\varphi_1$  y  $\varphi_2$  dos contingencias variable-minimales tales que  $\text{VAR}(\varphi_1) \cap \text{VAR}(\varphi_2) = \emptyset$ . Sea  $\psi$  una fórmula tal que  $\text{VAR}(\psi) \cap \text{VAR}(\varphi_1) \neq \text{VAR}(\varphi_1)$  y tal que  $\text{VAR}(\psi) \cap \text{VAR}(\varphi_2) \neq \text{VAR}(\varphi_2)$ . Furthermore, assume that for all valuations  $v$  that satisfy  $\varphi_1 \wedge \varphi_2$ ,  $v$  also satisfies  $\psi$ . Then there exist two valuations  $v_{in}, v_{out}$  such that:

1.  $v_{in}$  satisface  $\varphi_1 \wedge \varphi_2$ ;
2.  $v_{out}$  no satisface  $\varphi_1 \vee \varphi_2$ ;
3.  $v_{in}$  y  $v_{out}$  satisfacen  $\psi$ .

*Demostración.* De las hipótesis sabemos que hay una variable  $p_1 \in \text{VAR}(\varphi_1) \setminus \text{VAR}(\psi)$  y una variable  $p_2 \in \text{VAR}(\varphi_2) \setminus \text{VAR}(\psi)$ . Como  $\varphi_1, \varphi_2$  hay contingencias variable-minimales, del Lema 2 tenemos que existen valuciones  $v_1$  y  $v_2$  tales que satisfacen  $\varphi_1$  y  $\varphi_2$  respectivamente, pero donde  $\tilde{v}_1$  y  $\tilde{v}_2$  no lo hacen, donde  $\tilde{v}_1$  y  $\tilde{v}_2$  son las valuciones que coinciden con  $v_1$  y  $v_2$  excepto en  $p_1$  y  $p_2$  respectivamente. Usando que  $\text{VAR}(\varphi_1) \cap \text{VAR}(\varphi_2) = \emptyset$ , podemos construir a partir de  $v_1$  y  $v_2$  (como lo hicimos en la prueba del Lema 1) una valución  $v_{in}$  tal que  $v_{in}$  satisface tanto  $\varphi_1$  como  $\varphi_2$ , y también tal que  $v_{out}$  no satisface ninguna de ellas, donde tomamos  $v_{out}$  coincidente con  $v_{in}$  salvo en  $p_1$  y en  $p_2$ . Por hipótesis, necesariamente  $v_{in}$  satisface  $\psi$ . Sin embargo, como  $\{p_1, p_2\} \cap \text{VAR}(\psi) = \emptyset$ , el valor sobre  $p_1$  o  $p_2$  es irrelevante para  $\psi$ , y por lo tanto  $v_{out}$  también satisface  $\psi$ , como queríamos probar.  $\square$

Notar que el enunciado del Teorema 3 se puede generalizar a cualquier número de reglas no triviales  $\varphi_1, \dots, \varphi_n$  tales que  $\text{VAR}(\varphi_i) \cap \text{VAR}(\varphi_j) = \emptyset$  para todo  $i \neq j$ , y donde  $\psi$  satisfaga  $\text{VAR}(\psi) \cap \text{VAR}(\varphi_i) \neq \text{VAR}(\varphi_i)$  para todo  $i$ . Esto significa que podemos testear el aprendizaje de conceptos bajo cualquier multiplicidad de explicaciones posibles, siempre

que el universo proposicional subyacente sea lo suficientemente grande y las reglas se elijan adecuadamente.

# Bibliografía

- [Abelson et al., 1974] Abelson, H., Goodman, N., and Rudolph, L. (1974). *Logo manual*. -.
- [Amalric et al., 2017a] Amalric, M., Wang, L., Pica, P., Figueira, S., Sigman, M., and Dehaene, S. (2017a). The language of geometry: Fast comprehension of geometrical primitives and rules in human adults and preschoolers. *PLOS Computational Biology*, 13(1):e1005273.
- [Amalric et al., 2017b] Amalric, M., Wang, L., Pica, P., Figueira, S., Sigman, M., and Dehaene, S. (2017b). The language of geometry: Fast comprehension of geometrical primitives and rules in human adults and preschoolers. *PLoS computational biology*, 13(1):e1005273.
- [Arcediano et al., 1997] Arcediano, F., Matute, H., and Miller, R. R. (1997). Blocking of pavlovian conditioning in humans. *Learning and Motivation*, 28(2):188–199.
- [Ashby and Maddox, 2005] Ashby, F. G. and Maddox, W. T. (2005). Human category learning. *Annu. Rev. Psychol.*, 56:149–178.

[Ashby and Maddox, 2011] Ashby, F. G. and Maddox, W. T. (2011). Human category learning 2.0. *Annals of the New York Academy of Sciences*, 1224:147.

[Aydede, 1997] Aydede, M. (1997). Language of thought: The connectionist contribution. *Minds and Machines*, 7(1):57–101.

[Bengio et al., 2013] Bengio, Y., Courville, A., and Vincent, P. (2013). Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence*, 35(8):1798–1828.

[Blackburn, 1984] Blackburn, S. (1984). Spreading the word: Grounding in the philosophy of language.

[Blair and Homa, 2003] Blair, M. and Homa, D. (2003). As easy to memorize as they are to classify: The 5–4 categories and the category advantage. *Memory & Cognition*, 31(8):1293–1301.

[Blair et al., 2009] Blair, M. R., Watson, M. R., Walshe, R. C., and Maj, F. (2009). Extremely selective attention: Eye-tracking studies of the dynamic allocation of attention to stimulus features in categorization. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, 35(5):1196.

[Boole, 1854] Boole, G. (1854). *An investigation of the laws of thought: on which are founded the mathematical theories of logic and probabilities*. Dover Publications.

[Borges, 1944] Borges, J. L. (1944). *Ficciones, 1935-1944*. Buenos Aires: Sur.

[Bourne, 1970] Bourne, L. E. (1970). Knowing and using concepts. *Psychological Review*, 77(6):546.

- [Buhrmester et al., 2011] Buhrmester, M., Kwang, T., and Gosling, S. D. (2011). Amazon's Mechanical Turk: A new source of inexpensive, yet high-quality, data? *Perspectives on psychological science*, 6(1):3–5.
- [Calude et al., 2002] Calude, C. S., Dinneen, M. J., Shu, C.-K., et al. (2002). Computing a glimpse of randomness. *Experimental Mathematics*, 11(3):361–370.
- [Carvalho and Goldstone, 2014] Carvalho, P. F. and Goldstone, R. L. (2014). Putting category learning in order: Category structure and temporal arrangement affect the benefit of interleaved over blocked study. *Memory & cognition*, 42(3):481–495.
- [Chapman and Robbins, 1990] Chapman, G. B. and Robbins, S. J. (1990). Cue interaction in human contingency judgment. *Memory & Cognition*, 18(5):537–545.
- [Chomsky, 1986] Chomsky, N. (1986). *Knowledge of language: Its nature, origin, and use*. Greenwood Publishing Group.
- [Chomsky et al., 2006] Chomsky, N. et al. (2006). On cognitive structures and their development: A reply to piaget. *Philosophy of mind: Classical problems/contemporary issues*, pages 751–755.
- [Cohen and Lefebvre, 2005] Cohen, H. and Lefebvre, C. (2005). *Handbook of categorization in cognitive science*. Elsevier.
- [Crump et al., 2013] Crump, M. J., McDonnell, J. V., and Gureckis, T. M. (2013). Evaluating Amazon's Mechanical Turk as a tool for experimental behavioral research. *PloS one*, 8(3):e57410.
- [Dehaene et al., 2006] Dehaene, S., Izard, V., Pica, P., and Spelke, E. (2006). Core knowledge of geometry in an amazonian indigene group. *Science*, 311(5759):381–384.

- [Denison et al., 2013] Denison, S., Bonawitz, E., Gopnik, A., and Griffiths, T. L. (2013). Rational variability in children’s causal inferences: The sampling hypothesis. *Cognition*, 126(2):285–300.
- [Dillon et al., 2013] Dillon, M. R., Huang, Y., and Spelke, E. S. (2013). Core foundations of abstract geometry. *Proceedings of the National Academy of Sciences*, 110(35):14191–14195.
- [Ellis et al., 2015] Ellis, K., Solar-Lezama, A., and Tenenbaum, J. (2015). Unsupervised learning by program synthesis. In *Advances in Neural Information Processing Systems*, pages 973–981.
- [Feldman, 2000] Feldman, J. (2000). Minimization of boolean complexity in human concept learning. *Nature*, 407(6804):630–633.
- [Feldman, 2003] Feldman, J. (2003). The simplicity principle in human concept learning. *Current Directions in Psychological Science*, 12(6):227–232.
- [Fodor, 1975] Fodor, J. (1975). *The Language of Thought*. Language and thought series. Harvard University Press.
- [Geman and Geman, 1984] Geman, S. and Geman, D. (1984). Stochastic relaxation, gibbs distributions, and the bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-6(6):721–741.
- [Gentner, 1983] Gentner, D. (1983). Structure-mapping: A theoretical framework for analogy. *Cognitive science*, 7(2):155–170.

- [Gershman et al., 2015] Gershman, S. J., Horvitz, E. J., and Tenenbaum, J. B. (2015). Computational rationality: A converging paradigm for intelligence in brains, minds, and machines. *Science*, 349(6245):273–278.
- [Ghahramani, 2015] Ghahramani, Z. (2015). Probabilistic machine learning and artificial intelligence. *Nature*, 521(7553):452.
- [Goldsmith, 2001] Goldsmith, J. (2001). Unsupervised learning of the morphology of a natural language. *Computational linguistics*, 27(2):153–198.
- [Goldsmith, 2002] Goldsmith, J. (2002). Probabilistic models of grammar: Phonology as information minimization. *Phonological Studies*, 5:21–46.
- [Goodman et al., 2008] Goodman, N. D., Tenenbaum, J. B., Feldman, J., and Griffiths, T. L. (2008). A rational analysis of rule-based concept learning. *Cognitive Science*, 32(1):108–154.
- [Grünwald and Grunwald, 2007] Grünwald, P. D. and Grunwald, A. (2007). *The minimum description length principle*. MIT press.
- [Hoffman and Rehder, 2010] Hoffman, A. B. and Rehder, B. (2010). The costs of supervised classification: The effect of learning task on conceptual flexibility. *Journal of Experimental Psychology: General*, 139(2):319.
- [Izard et al., 2011] Izard, V., Pica, P., Dehaene, S., Hinchey, D., and Spelke, E. (2011). Geometry as a universal mental construction. *Space, Time and Number in the Brain*, 19:319–332.
- [Johnson et al., 2007] Johnson, M., Griffiths, T. L., and Goldwater, S. (2007). Bayesian inference for pcfgs via markov chain monte carlo. In *HLT-NAACL*, pages 139–146.

- [Kemp, 2012] Kemp, C. (2012). Exploring the conceptual universe. *Psychological review*, 119(4):685.
- [Kim and Rehder, 2011] Kim, S. and Rehder, B. (2011). How prior knowledge affects selective attention during category learning: An eyetracking study. *Memory & cognition*, 39(4):649–665.
- [Knowles, 1998] Knowles, J. (1998). The language of thought and natural language understanding. *Analysis*, 58(4):264–272.
- [Kolmogorov, 1968] Kolmogorov, A. N. (1968). Three approaches to the quantitative definition of information\*. *International Journal of Computer Mathematics*, 2(1-4):157–168.
- [Kruschke, 1996] Kruschke, J. K. (1996). Dimensional relevance shifts in category learning. *Connection Science*, 8(2):225–248.
- [Kruschke and Blair, 2000] Kruschke, J. K. and Blair, N. J. (2000). Blocking and backward blocking involve learned inattention. *Psychonomic Bulletin & Review*, 7(4):636–645.
- [Kruschke et al., 2005] Kruschke, J. K., Kappenman, E. S., and Hetrick, W. P. (2005). Eye gaze and individual differences consistent with learned attention in associative blocking and highlighting. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, 31(5):830.
- [Lake et al., 2015] Lake, B. M., Salakhutdinov, R., and Tenenbaum, J. B. (2015). Human-level concept learning through probabilistic program induction. *Science*, 350(6266):1332–1338.

- [Lake et al., 2017] Lake, B. M., Ullman, T. D., Tenenbaum, J. B., and Gershman, S. J. (2017). Building machines that learn and think like people. *Behavioral and Brain Sciences*, 40.
- [Landau et al., 1981] Landau, B., Gleitman, H., and Spelke, E. (1981). Spatial knowledge and geometric representation in a child blind from birth. *Science*, 213(4513):1275–1278.
- [LeCun et al., 2015] LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *nature*, 521(7553):436.
- [Lee et al., 2012] Lee, S. A., Sovrano, V. A., and Spelke, E. S. (2012). Navigation as a source of geometric knowledge: Young children’s use of length, angle, distance, and direction in a reorientation task. *Cognition*, 123(1):144–161.
- [Leeuwenberg, 1971] Leeuwenberg, E. L. (1971). A perceptual coding language for visual and auditory patterns. *The American Journal of Psychology*, pages 307–349.
- [Levin, 1974] Levin, L. A. (1974). Laws of information conservation (nongrowth) and aspects of the foundation of probability theory. *Problemy Peredachi Informatsii*, 10(3):30–35.
- [Lewandowsky, 2011] Lewandowsky, S. (2011). Working memory capacity and categorization: individual differences and modeling. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, 37(3):720.
- [Li and Vitányi, 2013] Li, M. and Vitányi, P. (2013). *An introduction to Kolmogorov complexity and its applications*. Springer Science & Business Media.
- [Loewer and Rey, 1991] Loewer, B. and Rey, G. (1991). Meaning in mind. *Fodor and his Critics*.

- [Luchins, 1942] Luchins, A. S. (1942). Mechanization in problem solving: The effect of einstellung. *Psychological monographs*, 54(6):i.
- [Lupyan et al., 2007] Lupyan, G., Rakison, D. H., and McClelland, J. L. (2007). Language is not just for talking: Redundant labels facilitate learning of novel categories. *Psychological science*, 18(12):1077–1083.
- [Machilsen et al., 2009] Machilsen, B., Pauwels, M., and Wagemans, J. (2009). The role of vertical mirror symmetry in visual shape detection. *Journal of Vision*, 9(12):11–11.
- [MacKay, 2003] MacKay, D. J. (2003). *Information theory, inference and learning algorithms*. Cambridge university press.
- [Mackintosh, 1975] Mackintosh, N. J. (1975). A theory of attention: Variations in the associability of stimuli with reinforcement. *Psychological review*, 82(4):276.
- [Maddox and Ashby, 1993] Maddox, W. T. and Ashby, F. G. (1993). Comparing decision bound and exemplar models of categorization. *Perception & psychophysics*, 53(1):49–70.
- [Manning and Schütze, 1999] Manning, C. and Schütze, H. (1999). *Foundations of Statistical Natural Language Processing*. MIT Press.
- [Minda and Smith, 2001] Minda, J. P. and Smith, J. D. (2001). Prototypes in category learning: the effects of category size, category structure, and stimulus complexity. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, 27(3):775.
- [Minsky, 1967] Minsky, M. L. (1967). *Computation: finite and infinite machines*. Prentice-Hall, Inc.

- [Murphy, 1988] Murphy, G. L. (1988). Comprehending complex concepts. *Cognitive science*, 12(4):529–562.
- [Newell, 1980] Newell, A. (1980). Physical symbol systems. *Cognitive science*, 4(2):135–183.
- [Nosofsky, 1986] Nosofsky, R. M. (1986). Attention, similarity, and the identification–categorization relationship. *Journal of experimental psychology: General*, 115(1):39.
- [Nosofsky et al., 1994a] Nosofsky, R. M., Gluck, M. A., Palmeri, T. J., McKinley, S. C., and Gauthier, P. (1994a). Comparing modes of rule-based classification learning: A replication and extension of shepard, hovland, and jenkins (1961). *Memory & cognition*, 22(3):352–369.
- [Nosofsky et al., 1994b] Nosofsky, R. M., Palmeri, T. J., and McKinley, S. C. (1994b). Rule-plus-exception model of classification learning. *Psychological review*, 101(1):53.
- [Overlan et al., 2017] Overlan, M. C., Jacobs, R. A., and Piantadosi, S. T. (2017). Learning abstract visual concepts via probabilistic program induction in a language of thought. *Cognition*, 168:320–334.
- [Piantadosi and Jacobs, 2016] Piantadosi, S. T. and Jacobs, R. A. (2016). Four problems solved by the probabilistic language of thought. *Current Directions in Psychological Science*, 25(1):54–59.
- [Piantadosi et al., 2012] Piantadosi, S. T., Tenenbaum, J. B., and Goodman, N. D. (2012). Bootstrapping in a language of thought: A formal model of numerical concept learning. *Cognition*, 123(2):199–217.

- [Piantadosi et al., 2016] Piantadosi, S. T., Tenenbaum, J. B., and Goodman, N. D. (2016). The logical primitives of thought: Empirical foundations for compositional cognitive models. *Psychological review*, 123(4):392.
- [Rehder and Hoffman, 2005] Rehder, B. and Hoffman, A. B. (2005). Eyetracking and selective attention in category learning. *Cognitive psychology*, 51(1):1–41.
- [Rescorla and Wagner, 1972] Rescorla, R. A. and Wagner, A. R. (1972). A theory of Pavlovian conditioning: Variations on the effectiveness of reinforcement and non-reinforcement. In Black, A. H. and Prokasy, W. F., editors, *Classical conditioning II: Current research and theory*, pages 64–99. Appleton-Century-Crofts, New York.
- [Romano et al., 2018] Romano, S., Salles, A., Amalric, M., Dehaene, S., Sigman, M., and Figueira, S. (2018). Bayesian validation of grammar productions for the language of thought. *PLOS ONE*, 13(7):1–20.
- [Romano et al., 2013] Romano, S., Sigman, M., and Figueira, S. (2013). : A language of thought with turing-computable kolmogorov complexity. *Papers in Physics*, 5:050001.
- [Rosch, 1999] Rosch, E. (1999). Principles of categorization. *Concepts: core readings*, 189.
- [Rosch and Mervis, 1975] Rosch, E. and Mervis, C. B. (1975). Family resemblances: Studies in the internal structure of categories. *Cognitive psychology*, 7(4):573–605.
- [Rosch et al., 1976] Rosch, E., Simpson, C., and Miller, R. S. (1976). Structural bases of typicality effects. *Journal of Experimental Psychology: Human perception and performance*, 2(4):491.

[Russell and Norvig, 2002] Russell, S. and Norvig, P. (2002). Artificial intelligence: a modern approach.

[Schyns et al., 1998] Schyns, P. G., Goldstone, R. L., and Thibaut, J.-P. (1998). The development of features in object concepts. *Behavioral and brain Sciences*, 21(1):1–17.

[Shannon, 1948] Shannon, C. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27:379–423, 623–656.

[Shepard et al., 1961] Shepard, R. N., Hovland, C. I., and Jenkins, H. M. (1961). Learning and memorization of classifications. *Psychological monographs: General and applied*, 75(13):1.

[Solomonoff, 1964] Solomonoff, R. J. (1964). A formal theory of inductive inference. part i. *Information and control*, 7(1):1–22.

[Stewart et al., 2015] Stewart, N., Ungemach, C., Harris, A. J., Bartels, D. M., Newell, B. R., Paolacci, G., Chandler, J., et al. (2015). The average laboratory samples a population of 7,300 Amazon Mechanical Turk workers. *Judgment and Decision making*, 10(5):479–491.

[Tano et al., 2020] Tano, P., Romano, S., Sigman, M., Salles, A., and Figueira, S. (2020). Towards a more flexible language of thought: Bayesian grammar updates after each concept exposure. *Phys. Rev. E*, 101:042128.

[Tenenbaum et al., 2011] Tenenbaum, J. B., Kemp, C., Griffiths, T. L., and Goodman, N. D. (2011). How to grow a mind: Statistics, structure, and abstraction. *science*, 331(6022):1279–1285.

- [Ullman et al., 2012] Ullman, T. D., Goodman, N. D., and Tenenbaum, J. B. (2012). Theory learning as stochastic search in the language of thought. *Cognitive Development*, 27(4):455–480.
- [Wagner, 1970] Wagner, A. R. (1970). Stimulus selection and a “modified continuity theory”. In *Psychology of learning and motivation*, volume 3, pages 1–41. Elsevier.
- [Westphal-Fitch et al., 2012] Westphal-Fitch, G., Huber, L., Gómez, J. C., and Fitch, W. T. (2012). Production and perception rules underlying visual patterns: effects of symmetry and hierarchy. *Philosophical Transactions of the Royal Society of London B: Biological Sciences*, 367(1598):2007–2022.
- [Yildirim and Jacobs, 2015] Yildirim, I. and Jacobs, R. A. (2015). Learning multisensory representations for auditory-visual transfer of sequence category knowledge: a probabilistic language of thought approach. *Psychonomic bulletin & review*, 22(3):673–686.